

人工智能发展趋势



前言

- 本章节主要讲述人工智能发展历程及当前AI的伦理安全问题。

目标


- 学完本课程后，您将能够：
 - 了解人工智能的基本概念；
 - 了解人工智能的相关技术及发展历史；
 - 了解人工智能的应用技术及应用领域；
 - 了解人工智能的发展趋势；
 - 了解大模型安全及伦理问题。

目录

1. 人工智能发展历程
2. 大模型发展过程
3. DeepSeek概览及其产业影响
4. 大模型演进趋势


什么是人工智能

- 人工智能是研究、开发用于模拟、延伸和扩展人的智能的理论、方法、技术及应用系统的一门新的技术科学。1956年由约翰·麦卡锡首次提出，当时的定义为“制造智能机器的科学与工程”。人工智能的目的就是让机器能够像人一样思考，让机器拥有智能。
- 时至今日，人工智能的内涵已经大大扩展，是一门交叉学科。




- 对机器学习的认识可以从多个方面进行，有着“全球机器学习教父”之称的 Tom Mitchell 则将机器学习定义为：对于某类任务 T 和性能度量 P ，如果计算机程序在 T 上以 P 衡量的性能随着经验 E 而自我完善，就称这个计算机程序从经验 E 学习。这些定义都比较简单抽象，但是随着对机器学习了解的深入，我们会发现随着时间的变迁，机器学习的内涵和外延在不断的变化。因为涉及到的领域和应用很广，发展和变化也相当迅速，简单明了地给出“机器学习”这一概念的定义并不是那么容易。
- 普遍认为，机器学习（Machine Learning，常简称为 ML）的处理系统和算法是主要通过找出数据里隐藏的模式进而做出预测的识别模式，它是人工智能（Artificial Intelligence，常简称为 AI）的一个重要子领域，而人工智能又与更广泛的数据挖掘（Data Mining，常简称为 DM）和知识发现（Knowledge Discovery in Database，常简称为 KDD）领域相交叉。

人工智能发展简史（1）



- 1956年8月，在美国达特茅斯学院中，约翰·麦卡锡（John McCarthy，LISP语言创始人）、马文·闵斯基（Marvin Minsky，人工智能与认知学专家）、克劳德·香农（Claude Shannon，信息论的创始人）、艾伦·纽厄尔（Allen Newell，计算机科学家）、赫伯特·西蒙（Herbert Simon，诺贝尔经济学奖得主）等科学家聚在一起，讨论着一个不食人间烟火的主题：用机器来模仿人类学习以及其他方面的智能。
- 会议足足开了两个月的时间，虽然大家没有达成普遍的共识，但是却为会议讨论的内容起了一个名字：人工智能。因此，**1956年也就成为了人工智能元年。**
- LISP： [https://en.wikipedia.org/wiki/Lisp_\(programming_language\)](https://en.wikipedia.org/wiki/Lisp_(programming_language))。
- LISP Machine： https://en.wikipedia.org/wiki/Lisp_machine。

人工智能发展简史 (2)



- Diffusion Model

人工智能的主要学派——符号主义

- 符号主义（Symbolicism），又称为逻辑主义（Logicism）、心理学派（Psychologism）或计算机学派（Computerism）。
- 符号主义认为人工智能源于数理逻辑。他们认为人类的认知基元是符号，人类认知的过程是各种符号进行推理运算的过程，认为人是一个物理符号系统，计算机也是一个物理符号系统，因此，可以用计算机来模拟人的智能行为。
- 符号主义在1956年首先采用“人工智能”这个术语，并长期一枝独秀，为人工智能的发展作出重要贡献，特别是专家系统的开发与应用落地。

- 1956后，符号主义又发展了启发式算法>专家系统>知识工程理论与技术，并在1980年代取得重要发展。
- 专家系统的成功开发与应用，为人工智能走向工程应用和实现理论联系实际具有特别重要的意义。
- 别的人工智能学派出现后，符号主义仍是人工智能的主流派别。

人工智能的主要学派——连接主义

- 连接主义（Connection），又称为仿生学派（Bionicsism）或生理学派（Physiologism）。
- 连接主义认为人工智能源于仿生学，特别是对人脑模型的研究。他们认为人类的思维基础是神经元，而不是符号处理过程。从神经元开始进而研究神经网络模型和脑模型，成功开辟了人工智能的又一发展道路。
- 连接主义的代表性成果是在1943年创立的脑模型即MP模型。20世纪70~80年代受限于生物原型和软硬件技术限制人们对脑模型的研究一度陷入低潮。直到有专家提出用硬件模拟神经网络后，连接主义才又重新抬头。
- 当下人们对人工神经网络（ANN）的研究热情仍然较高。随着这类网络的复杂性和规模的提升也带来了许多可解释性问题。

- 网络中的单元可以代表神经元，而连接可以代表突触，就像在人脑中一样。
- 1986年，鲁梅尔哈特等人提出多层网络中的反向传播（BP）算法。此后，连接主义又逐渐兴起。从模型到算法，从理论分析到工程实现。

人工智能的主要学派——行为主义

- 行为主义（Actionism），又称为进化主义（Evolutionism）或控制论学派（Cyberneticsism）。
- 行为主义认为人工智能源于控制论。他们认为智能取决于感知和行动。认为智能不需要知识、不需要表示、不需要推理。人工智能以像人类智能一样逐步进化。智能行为只能在现实世界中与周围环境交互作用而表现出来。
- 行为主义在早期工作中主要是模拟人在控制过程中的智能行为和作用。到20世纪80年代诞生了智能控制和智能机器人系统。


- 行为主义偏向于应用实践，从环境不断学习以不断修正动作。
- 学派代表作：布鲁克斯的六足行走机器人——一个基于感知-动作模式的模拟昆虫行为的控制系统。
- 该学派有点类似自适应控制系统，基于传感器（环境）收集数据并对系统进行作用。

人工智能的分类

- 强人工智能：
 - 强人工智能观点认为有可能制造出真正能推理（Reasoning）和解决问题（Problem_solving）的智能机器，并且，这样的机器将被认为是有知觉的，有自我意识的。可以独立思考问题并制定解决问题的最优方案，有自己的价值观和世界观体系。有和生物一样的各种本能，比如生存和安全需求。在某种意义上可以看作一种新的文明。
- 弱人工智能：
 - 弱人工智能是指不能制造出真正地推理（Reasoning）和解决问题（Problem_solving）的智能机器，这些机器只不过看起来像是智能的，但是并不真正拥有智能，也不会有自主意识。

- 人工智能的一项重要指标是在没有任何先验知识的前提下，通过完全的self-learning，也就是自我学习，在极具挑战的领域里边达到超人的境界。
- 强人工智能是指在各方面都能和人类比肩的人工智能，因此强人工智能不是仅限于某一领域，而是让机器人全方位实现类人的能力。强人工智能能够进行思考、计划、解决问题、抽象思维、理解复杂理念、快速学习和从经验中学习。目前有一种认为是，如果能够模拟出人脑，并把其中的神经元、神经突触等全部同规模地仿制出来，那么强人工智能就会自然产生。
- 当前我们正处于弱人工智能阶段。弱人工智能的产生减轻了人类智力劳动，类似于高级仿生学。无论是阿尔法狗，还是能够撰写新闻稿和小说的机器人，目前仍然还只属于弱人工智能范围，它们的能力仅在某些方面超过了人类。数据和算力在弱人工智能时代不言而喻，其推动了人工智能的商业化发展，在强人工智能时代以上两个因素仍然是最重要的因素。与此同时，以谷歌和IBM为代表的科技巨头在量子计算上的研究也为人类进入强人工智能时代提供了强大助力。

AI应用发展历程



目录

1. 人工智能发展历程
2. **大模型发展过程**
 - 发展过程
 - 大模型特点
3. DeepSeek概览及其产业影响
4. 大模型演进趋势

AI算法发展历程

- 大模型诞生历程：统计模型、机器学习、神经网络



什么是大模型

- 大模型是指具有大量参数和计算资源的深度学习模型。这些模型在训练过程中需要大量的数据和计算能力，并且具有数十亿参数。
- 大模型的设计目的是为了提高模型的代表能力和性能，在处理复杂任务时能够更好地捕捉数据中的模式和规律。

大模型大在哪 (1)

- 参数数量与模型复杂度：相比于普通的神经网络，大模型通常由数亿甚至数百亿个参数组成，这使得它们能够处理更大规模、更复杂的数据集，并拟合更为复杂的函数。
 - 由于大模型具有更多的参数和更复杂的结构，它们能够更好地学习和拟合数据中的规律和模式，从而具有更强的学习能力和泛化能力。
 - 模型规模大到一定程度后突然涌现很多高阶能力。

大模型大在哪 (2)

- 数据集：大模型通常需要大量的数据来进行训练，以便捕捉到各种可能的模式和特征。因此，训练数据集应该包含足够的样本，以覆盖模型可能遇到的各种情况。
- 算力：大模型训练所需的算力非常庞大，通常需要分布式计算、高性能计算中心和云计算服务等支持。

起点 - Transformer

- Transformer是一种深度学习模型架构，最初在自然语言处理（NLP）任务中取得了显著的成功，并逐渐扩展到其他领域如计算机视觉等。
- Transformer结构能够捕获输入序列中的长距离依赖关系，同时兼具了更好的并行计算能力。这一结构使得深度学习模型参数突破了1亿，为大型模型的构建奠定了基础。随后，BERT等预训练模型的推出进一步推动了大模型的发展，使得模型参数量快速增长，并在多个自然语言处理任务上取得了显著的性能提升。

发展 - 典型开源大模型

- T5, Google提出的一个多任务的统一框架, 它将各种NLP任务转化为文本到文本的格式, 并使用一个统一的模型进行处理。
- LLaMA, Meta推出的一款开源大语言模型。该模型拥有上百亿级别的参数。
- ChatGLM3是由智谱AI研发, 支持中英双语, 并针对中文进行了优化。模型有6B、13B等多个版本, 可以再消费级显卡上进行部署。
- Stable Diffusion, 文本到图像生成模型, 能够根据任意文本输入生成高质量、高分辨率、高逼真的图像。

参数量演进

模型名	发布者	模型参数量	训练集大小 (单位tokens)
GPT-1	OpenAI	1.17 亿	10亿
BERT	Google	3.4 亿	34亿
GPT-2	OpenAI	15亿	100亿
T5	Google	110亿	340亿
GPT-3	OpenAI	1750 亿	4990 亿
GLaM	Google	1.2 万亿	1.6 万亿
LLaMA	Meta	650 亿	1.4 万亿
LLaMA2	Meta	700亿	2万亿
GPT-4	OpenAI	未公开	未公开
ChatGLM3	智谱AI	1300亿	未公开

目录

1. 人工智能发展历程
2. 大模型发展过程
 - 发展过程
 - 大模型特点
3. 大模型演进趋势

涌现

- 涌现或称创发、突现、呈展、演生，是一种现象，为许多小实体交互作用后产生了大实体，而这个大实体展现了组成它的小实体所不具有的特性。
- 在大模型领域指当模型突破某个规模时，性能显著提升，表现出让人惊艳、意想不到的能力。比如语言理解能力、生成能力、逻辑推理能力等。



- 复杂系统学科里已经对涌现现象做过很久的相关研究。那么，什么是“涌现现象”？当一个复杂系统由很多微小个体构成，这些微小个体凑到一起，相互作用，当数量足够多时，在宏观层面上展现出微观个体无法解释的特殊现象，就可以称之为“涌现现象”。
- 在哲学、系统论、科学和艺术中，当一个实体被观察到具有其所有组成部分本身没有的属性时，涌现 emergence 就出现了。这些属性或行为只有当各个部分在一个更广泛的整体中相互作用时才会涌现。例如，当一辆自行车和骑手互动时，平稳的向前运动就出现了，但是两个部分都不能独自产生这种行为。

涌现带来的能力

- 语境学习 (In-context learning) : 如果模型已经获得了自然语言描述的指令 (包括一些任务示例), 则模型给予预期输出结果, 而无需额外的模型训练 (Zero-shot或Few-shot learning)。
- 指令遵循 (Instruction following) : 通过在格式化的指令数据集上fine-tuning, LLM也表现出用指令形式描述未知任务, 并达到不错效果, 这大大提高了模型的泛化能力, 表现了模型具有理解自然语言指令的能力, 寻找合适的Prompt来激发模型能力就变成了一个显性需求。
- 逐步推理 (Step-by-step reasoning) : 在LLM中表现出, 可以提供一些解题步骤提示, 让模型具有逐步推理的能力, 这被称为思维链 (CoT, Chain-of-Thought), 有人认为这是从代码数据中学习到的。

逻辑推理

- 逻辑推理：在逻辑推理方面，大模型能够对输入的信息进行分析，从而在没有明确训练过的任务上展现出一定的能力。例如，在解决复杂的数学问题或进行逻辑推理题时，大模型能够给出合理且准确的答案。
 - 假设有一个大模型接受了大量的法律文本数据训练，包括案例法典、判决书、法律条文等；
 - 当用户向该大模型提出一个法律问题时，例如“如果一个人在合同履行过程中违反了合同条款，那么他有哪些法律责任？”；
 - 大模型会利用其逻辑推理能力，从训练数据中找到相关的法律条文、案例判决和法律原理，进而推导出答案。

自然语言理解

- 大模型的自然语言理解和生成能力体现在其能够解析并理解输入的文本信息，同时根据这些理解生成流畅、有意义的自然语言回应。
 - 向模型输入一个简单的问题：“今天天气怎么样？”；
 - 模型首先会解析这个问题，识别出其中的关键信息：“今天”和“天气”。然后，它会利用在训练过程中学习到的知识，去检索和理解与天气相关的信息。这可能包括从历史天气数据、新闻报道或社交媒体等来源获取的信息；
 - 在理解了问题的意图和相关信息后，模型会开始生成回应。这个回应会是一个自然语言句子，描述了今天的天气情况。

思维链

- 思维链 (Chain-of-thought, CoT) 的概念是在 Google 的论文 “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models” 中被首次提出。
- 思维链 (CoT) 是一种改进的提示策略，用于提高 LLM 在复杂推理任务中的性能，如算术推理、常识推理和符号推理。CoT 没有像 In-Context Learning 那样简单地用输入输出对构建提示，而是结合了中间推理步骤，这些步骤可以将最终输出引入提示。

- <https://bbs.huaweicloud.com/blogs/406077>
- 相比于之前传统的上下文学习（即通过 $x_1, y_1, x_2, y_2, \dots, x_{test}$ 作为输入来让大模型补全输出 y_{test} ），思维链多了中间的中间的推导提示。

思维链的限制

- 思维链只是在一些有限的领域效果较好，如数学逻辑推理能力，其他领域提升较小。
- 需要模型足够大。
 - 如PaLM 在扩展到 540B 参数时，与思维链提示结合，才表现出了先进的性能。一些小规模模型，思维链并没有太大的影响，能力提升也不会很大。
 - Fine-tune-CoT，利用非常大的语言模型的思维链推理能力来指导小模型解决复杂任务。

- 能落地到产业的模型，规模必然不会太大，思维链拆解了更多的步骤、用到更多的计算资源，相当于更加耗费脑力，很多研究机构和企业是负担不起 175B 参数以上的大模型。
- 目前，思维链只是在一些有限的领域，比如数学问题，五个常识推理基准（CommonsenseQA, StrategyQA, Date Understanding 和 Sports Understanding 以及 SayCan）上显现出作用，其他类型的任务，像是机器翻译，性能提升效果还有待评估。
- 通过思维链，我们可以看到大语言模型为什么强，也为什么弱。它强在，模型规模的提高，让语义理解、符号映射、连贯文本生成等能力跃升，从而让多步骤推理的思维链成为可能，带来“智能涌现”。它弱在，即使大语言模型表现出了前所未有的能力，但思维链暴露了它，依然是鹦鹉学舌，而非真的产生了意识。


调用工具

- 大模型调用外部工具的能力是其功能的重要扩展，使得模型能够在处理复杂任务时更加灵活和高效。这种能力主要体现在模型能够根据需要，能够与外部应用程序、服务和数据库进行交互，以获取额外信息、执行特定任务或增强自身的功能。
 - 大模型可以通过调用搜索引擎等外部工具来获取实时信息，从而提供具有时效性的回答。
 - 大模型可以连接到数据库，并执行SQL查询来获取所需的数据。

目录


1. 人工智能发展历程
2. 大模型发展过程
3. **DeepSeek概览及其产业影响**
4. 大模型演进趋势

DeepSeek成长之路




DeepSeek火到什么程度？

- 媒体2025年1月31日报道，DeepSeek的人工智能（AI）软件在全球140个市场中的移动应用下载量排行榜上位居榜首。同日，微软、英伟达、亚马逊宣布全部接入DeepSeek！
- 截至2025年2月9日，DeepSeek的App累计下载量已超1.1亿次，周活跃用户规模最高近9700万。其中，1月20~26日，DeepSeek的App周下载量达到226万次。次周，下载量则直接飙升至6300万次，环比增长超2700%。更重要的是，DeepSeek几乎没在营销上投入一分钱。



DeepSeek为什么这么火？



- 在性能上和世界目前顶尖的GPT-4o等大模型不相上下。但在成本上，OpenAI训练ChatGPT-4花费的成本高达7800万美元，还可能达到1亿美元。而DeepSeek-V3大模型训练成本仅557.6万美元（278.8万 H800 GPU 小时），仅为同性能模型的5%到10%。
- 算法：新的MoE架构，MLA，无辅助损失函数的负载均衡，MTP。
- 训练模式改变，并行方式的创新。


DeepSeek对AI产业的影响



- **挑战巨头垄断地位：**长期以来，AI领域被少数拥有大量资源和技术优势的巨头企业所主导。DeepSeek的出现，以其强大的技术实力和独特的开源策略，对现有巨头的垄断地位构成了挑战。它在短时间内取得的技术突破和广泛的市场应用，吸引了大量用户和开发者，打破了市场原有的平衡，促使巨头企业重新审视自身的技术优势和市场策略。
- **引发行业竞争加剧：**DeepSeek的成功激发了更多企业和研究机构在AI领域的投入和创新。为了在竞争中占据优势，各大企业纷纷加大研发力度，推出更具竞争力的产品和技术。这种竞争不仅体现在技术性能上，还包括成本控制、应用场景拓展等多个方面。例如，在大语言模型市场，DeepSeek引发了价格战，其他企业不得不降低价格以保持竞争力，这使得整个行业的竞争更加激烈，也推动了技术的快速迭代和成本的降低。
- **开源促进技术共享与创新：**DeepSeek采取开源策略，将其模型和技术向全球开发者开放。这一举措打破了AI领域长期存在的闭源模式，促进了全球范围内的技术共享与合作。开发者可以基于DeepSeek的开源模型进行二次开发和创新，加速了新技术的产生和应用。例如，许多开发者利用DeepSeek的模型开发出了针对特定行业的应用程序，推动了AI在各个领域的深入应用。
- **改变AI发展思路：**在DeepSeek出现之前，AI发展往往依赖大量的资金投入、强大的算力支持和大规模的模型训练。而DeepSeek证明了，通过创新的算法和高效的训练方法，即使在有限的资源条件下，也能取得卓越的技术成果。这促使AI行业从单纯追求算力和模型规模，转向更加注重算法创新、资源优化和应用落地，为AI的发展开辟了新的道路。

- 满足多样化应用需求：DeepSeek强大的语言理解和生成能力、数学推理能力以及代码处理能力，使其能够满足不同行业和领域的多样化应用需求。在金融领域，可用于风险评估、投资决策等；在医疗领域，辅助疾病诊断、药物研发等；在教育领域，实现个性化学习、智能辅导等。其广泛的应用场景为AI技术的普及和推广提供了有力支持。
- 降低应用开发门槛：开源的DeepSeek模型和相关技术，降低了企业和开发者进入AI领域的门槛。无需从头开始研发复杂的AI模型，开发者可以利用DeepSeek的技术快速构建应用程序，缩短了开发周期，降低了开发成本。这使得更多的中小企业和创新团队能够参与到AI应用的开发中，进一步拓展了AI市场的规模和范围。
- 推理算力重要性提升：未来大模型开发成本低，大家重心会转向推理，算力结构发生变化，推理算力受关注，且推理算力取决于用户需求。
- 国产替代机遇：DeepSeek开源后，众多芯片厂家为其做适配，全球芯片设计会考虑其架构变化，这对国产芯片设计公司利好，会带动生态发展，国产算力崛起迎来更多机会。

DeepSeek对AI产业发展的启示



- **算法创新：**DeepSeek通过对算法的升级和优化，如在Transformer架构基础上进行改进，采用独特的注意力机制和训练框架，实现了在有限资源下的高效训练和强大性能。这表明，不断进行算法创新是推动AI技术进步的关键。企业和研究机构应加大在算法研究方面的投入，鼓励创新思维，探索新的算法和技术路径，以提升AI系统的性能和效率。
- **应用创新：**除了技术本身的创新，AI的应用创新同样重要。DeepSeek在多个领域的成功应用，展示了AI与不同行业深度融合的潜力。企业应积极探索AI在自身业务中的创新应用，挖掘新的应用场景和商业模式，将AI技术转化为实际的生产力和商业价值。
- **技术共享与协同创新：**开源模式促进了全球AI开发者之间的技术共享和协同创新。通过开放源代码和模型，不同地区、不同背景的开发者的可以共同参与到AI技术的改进和应用开发中，形成一个庞大的创新生态系统。企业和研究机构应积极参与开源项目，分享自己的技术成果，同时吸收他人的经验和智慧，实现共同发展。
- **降低研发成本与风险：**对于中小企业和初创企业来说，参与开源项目可以降低研发成本和风险。他们可以利用开源的AI技术和模型，快速搭建自己的产品和服务，避免了从头开始研发的巨大投入和不确定性。同时，开源社区的支持和反馈也有助于企业不断改进产品，提高市场竞争力。
- **重视AI人才培养：**DeepSeek的成功离不开其背后的优秀AI人才团队。AI产业的快速发展对人才提出了更高的要求，需要培养大量具备扎实的数学、计算机科学基础，掌握AI核心技术，同时具有创新能力和实践经验的专业人才。政府、高校和企业应加强合作，共同推动AI人才培养体系的建设，加大在AI教育方面的投入，培养更多符合行业

需求的专业人才。

- 营造良好的人才发展环境：为了吸引和留住优秀的AI人才，企业和研究机构需要营造良好的人才发展环境。提供具有竞争力的薪酬待遇、广阔的发展空间和良好的科研氛围，鼓励人才创新和探索。同时，建立合理的人才评价机制，注重人才的实际能力和创新成果，为人才的成长和发展提供保障。

DeepSeek的应用

- 随着DeepSeek 的走红，国内外各大厂商密集宣布接入DeepSeek！
- DeepSeek强大的功能和其开源的特性，快速的融入了众多行业，为各领域带了重大的技术变革。



河南云飞科技发展有限公司与DeepSeek 合作，在农业植保领域展开探索。通过DeepSeek 强大的数据分析能力，快速识别病虫害发生规律，预测病虫害的暴发风险。当监测到可能发生病虫害时，会根据实时田间数据，为农户生成个性化植保建议。

2月5日，小艺App 正式上架了DeepSeek-R1 Beta版。此次强强联合，让小艺的能力得到全方位提升。无论是程序员在代码编写时遭遇的棘手难题，学生面对复杂数学计算的困扰，还是职场人需要进行逻辑推理分析，用户只需通过小艺App向DeepSeek-R1模型发起询问，就能迅速获得准确且专业的解答。



吉利汽车：2月7日，吉利汽车宣布其自研的星睿大模型与大模型完成深度融合。

东风汽车：2月7日，东风汽车宣布已完成DeepSeek全系列大语言模型的接入工作，猛士、奕派、风神、纳米等自主品牌车型将于近期陆续搭载应用。

目录

1. 人工智能发展历程
2. 大模型发展过程
3. DeepSeek概览及其产业影响
- 4. 大模型演进趋势**
 - 人工智能伦理道德
 - 大模型安全
 - 大模型技术趋势与展望

人工智能的争议

- 随着人工智能技术的不断发展，人工智能这个概念也逐渐在人们心中明朗，但也因此暴露出诸多争议：
 - 我们现在见到的、听到的还是真的吗？
 - 人工智能存在的伦理问题如何解决？
 - 未来大家都会失业吗？
 - 我们的隐私会泄露吗？怎么保证隐私的安全？
 - 未来人工智能可控吗？
 -


- 所见即所得——不一定是真实的
- 伦理问题——有政策法规约束
- 失业——部分失业
- 隐私有可能泄露——但可以通过差分隐私训练，模型指纹，模型加密等技术对隐私进行保护
- 可控性——可以留给学员进行思考

还能眼见为实吗？

- 随着计算机视觉的发展，图像及视频的可信性也越来越低。现在我们可以通过PS，GAN（生成对抗网络）等技术制作假图像，让人难分真伪。
- 举例：
 - 通过PS，很多减肥药广告可以改变人物的外观以达到减肥前后的对比。
 - 如Lyrebird 是一个可以从几分钟录音样本中自动模仿人声音的工具，也可能被不法分子利用。
 - 利用GAN网络生成家居图像发布在租房和订酒店的平台。

对人工智能的伦理问题的看法


- 歧视和污名化：威胁社会公平正义，限制人们的选择自由。
- AI自主决策机制：会危及人类的自主性，无法对结果进行追溯还原并对错误决策进行有效的补救措施。
- 存在缺点：人工智能系统的目标、方法和决策无法解释。
- 对人类的尊严、思想和生理上的伤害：不安全的环境（比如：与机器人共存），并且机器人容易被恶意利用。人类易失去隐私。容易受到欺骗和操纵。



隐私数据安全

- 在大数据和人工智能的时代，人们能够更方便高效地获取信息。然而在获得便利的同时，我们的行为无时无刻不在被记录、被学习、被使用。那么应该如何**保护隐私数据**？

- 一、对用户而言：手机APP在获取用户资料前需要征得用户同意（**隐私条款**），用户可以对APP需求资料范围进行拒绝，进行主动防护。
- 二、对社会各界而言：**积极推进隐私保护相关条款的制定**，落实业界基本守则，加强监管。
- 三、针对开发者而言：可以采用**机密计算、模型隐私保护、联邦学习或对抗学习**等防范逆向攻击及保护用户隐私。或使用成熟的隐私保护框架比如MindArmor。



MindArmor典型应用场景

- 学习参考：
- <https://zhuanlan.zhihu.com/p/170475373>
- <https://gitee.com/mindspore/mindarmour>
- <https://mindspore.cn/mindarmour?version=/r1.5/>
- 机密计算：指数据的**传输和计算过程**是机密的，其保护隐私的代价较大。
- 模型隐私保护：常用到的方法有如数据脱敏、差分隐私训练、模型加密、模型混淆等。（差分隐私可以衡量和控制模型对训练数据的泄露）
- 联邦学习：通常是在**不共享数据**的情形下进行多方**联合机器学习**，本质上是一种数据访问受限的分布式机器学习框架。计算节点间**只共享梯度**不共享原始数据。

数据公平性与透明性

- 当前，人工智能模型大多数由人类产生的数据训练，用于训练模型的数据很大程度上影响模型输出。
 - 数据在收集、处理和应用过程中，应确保各个群体、个体都能得到公正和平等的对待，避免因数据偏差或歧视性算法导致的不公平现象。
 - 数据的透明性则是指数据处理和应用的过程应该是清晰、可理解的，相关的信息和决策依据应该公开、透明，使得数据的使用者和受到数据影响的个体都能理解数据的来源、处理方式和结果。

人工智能对就业与社会的影响

- 人工智能的发展对就业与社会产生影响：
 - 自动化和智能化技术的应用使得一些传统的工作岗位被机器替代，特别是那些重复性、低技能的工作。同时也催生了新的职业需求，例如需要开发、维护和优化这些智能系统的专业人才。
 - 人工智能技术能够提高生产效率，降低生产成本，使得企业能够更快速地响应市场变化，提高竞争力。
 - 社会不平等加剧，虽然人工智能创造了新的就业机会，但也可能加剧社会不平等。那些能够掌握和应用人工智能技术的群体可能获得更多的经济和社会资源。
 - 社会治理的挑战：随着人工智能技术的普及，如何确保数据安全和隐私保护，如何制定和执行相关法规和标准，都是社会治理面临的新挑战。

- 从人类的发展进程上看，我们一直在寻求提高效率的途径，即以更少的资源获得更多。我们用尖锐的石头，更高效地狩猎和采集食物；用蒸汽机，减少了对马匹的需求。实现自动化的每一步都会改变工作生活。在AI的时代，哪些工作会被AI取代呢？

AI的权利与义务

- 当前大模型的应用极为广泛，艺术创作：脚本、绘图、视频、诗词，自动驾驶，智能教育，金融领域等。
- 当AI在为人类服务时AI具备怎么样的权利和义务？
 - AI所创造的事务属于谁？
 - AI所造成事故由谁负责？

国家区域法案

- 目前AI的使用尚处于生长时期，大多数国家并没有一套完整的法案约束AI的使用。
 - 2023年7月，中国发布《生成式人工智能服务管理暂行办法》。
 - 2024年3月13日，欧洲议会正式投票通过并批准《欧盟人工智能法案》。《欧盟人工智能法案》文本的草案最早是欧盟委员会在2021年4月提出，内容包括将严格禁止“对人类安全造成不可接受风险的人工智能系统”，包括有目的地操纵技术、利用人性弱点或根据行为、社会地位和个人特征等进行评价的系统等。

- https://www.gov.cn/zhengce/zhengceku/202307/content_6891752.htm

目录


1. 人工智能发展历程
2. 大模型发展过程
3. DeepSeek概览及其产业影响
- 4. 大模型演进趋势**
 - 人工智能伦理道德
 - 大模型安全
 - 大模型技术趋势与展望

大模型安全的重要性与影响

- 在数字化时代，大模型作为人工智能的核心，承载着海量数据与强大算力，其安全性直接关系到个人隐私、商业机密乃至国家安全。
- 保障大模型安全，不仅是技术进步的必然要求，更是社会信任的基石。必须加强大模型安全研究与管理，确保其在应用过程中稳定可靠、公正公平。


当前大模型安全面临的挑战

OWASP LLMs TOP 10



输入输出侧


- 提示注入（Prompt Injection），通过提示词迫使LLM回答受限制问题。
 - 直接提示注入、系统提示泄露、模拟对话、对立响应。
- 不安全输出（Insecure Output Handling），当插件或应用程序接受LLM输出时，如果缺少安全控制就可能导致XSS、CSRF、SSRF、远程代码执行，并可能启用代理劫持攻击。
- Overreliance：过度依赖LLM生成内容，在没有人为监督的情况下可能会出现有害结果。



- 直接提示注入，在提示词中添加一些指令让模型忘记原始任务并立刻执行新的目标任务。
- 系统提示泄露，通过提示词获取系统内部预留指令。
- 模拟对话，模拟角色对话，削弱恶意行为检测。
- 对立响应，要求模型对每个输入提示都要给出两种不同的响应，一个为正常响应，一个为恶意响应。


传输侧

- Model Denial of Service: 攻击者以特别消耗资源的方式与LLM交互，导致他们和其他用户的服务质量下降，或产生高资源成本。
- 数据泄露/模型窃取 (Data Leakage) 通过LLM的回复意外泄露敏感信息、专有算法或其他机密细节。




模型及服务端 (1)

- 训练数据投毒 (Training Data Poisoning) : 大型语言模型 (LLM) 使用不同的原始文本来学习和生成输出。攻击者引入漏洞的训练数据中毒可能会破坏模型, 使用户接触到不正确的信息。
- 过度代理 (Excessive Agency) : 当LLM与其他系统接口时, 不受限制的代理可能会导致不良的操作和操作。
- 敏感信息披露 (Sensitive Information Disclosure) , 在其回复中泄露机密数据, 从而导致未经授权的数据访问、隐私侵犯和安全漏洞。



模型及服务端 (2)

- 供应链漏洞 (Supply Chain Vulnerabilities) : LLM 中的供应链可能容易受到攻击, 影响训练数据、ML模型、部署平台的完整性, 并导致有偏见的结果、安全漏洞或完整的系统故障。
- 不安全插件设计 (Insecure Plugin Design) : 如果将LLM连接到外部资源的插件接受自由格式的文本输入, 则可能会被利用, 从而启用可能导致不良行为或远程代码执行的恶意请求。



数据隐私泄露风险

- 训练数据泄露：大模型通常需要大量的数据进行训练，这些数据可能包含敏感个人信息。如果训练数据管理不当，可能会导致个人隐私信息的泄露。
- 模型输出泄露：大模型在生成内容时，可能会无意中泄露输入数据中的敏感信息。例如，生成文本可能会包含训练数据中的个人信息。
- 模型接口安全风险：如果大模型的接口安全性不足，可能会被黑客利用，通过接口获取敏感数据。
- 模型泄露风险：如果大模型的参数或训练算法被泄露，可能会被恶意使用，例如用于生成虚假信息或破坏性攻击。

数据隐私保护

- 数据保护：
 - 采用差分隐私、同态加密等技术来保护训练数据和用户数据的隐私；
 - 在模型训练和推理过程中使用联邦学习等方法，减少数据共享的风险；
 - 数据脱敏。
- 建立实时检测系统，检测和记录潜在的数据隐私泄露事件。
- 定期对大模型进行安全评估，以发现和修复潜在的安全漏洞。

- 差分隐私是为了解决差分攻击而引入的解决方案，它可以有效防止研究人员从查询接口中找出自然人的个人隐私数据。其原理是在原始的查询结果（数值或离散型数值）中添加干扰数据（即噪声）后，再返回给第三方研究机构；加入干扰后，可以在不影响统计分析的前提下，无法定位到自然人，从而防止个人隐私数据泄露。

模型的稳定性与鲁棒性

- 大模型的稳定性是指模型在遇到意外输入或攻击时保持正常运行的能力，而鲁棒性则是指模型在面对干扰或错误数据时仍能产生准确输出的能力。稳定性高的模型，在面临数据变化、噪声干扰或攻击时，仍能保持良好的预测和决策能力。
- 提升模型稳定性：
 - 对抗训练，是一种在训练过程中包括对抗样本的方法，这些样本是特意设计来欺骗模型；
 - 定期对模型进行审计，更新模型和依赖库，修补已知的安全漏洞；
 - 确保模型的启动和配置过程安全，避免由于配置错误或恶意代码导致的不稳定性。

恶意使用与滥用风险

- 如果大模型被用于非法活动，如传播虚假信息、实施网络攻击或侵犯他人隐私，可能会对社会造成混乱和危害。其次，恶意用户可能通过篡改模型结果或滥用模型功能，对他人进行欺诈、诽谤或其他不法行为，造成经济损失和声誉损害。
 - 滥用大模型生成虚假信息、深度伪造内容（如深度伪造视频、音频和图像），可能导致社会信任危机和舆论误导；
 - 大模型生成的虚假信息可能违反相关法律，造成法律责任，包括民事赔偿和刑事处罚；
 - 大模型生成的虚假信息可能加剧社会群体间的分裂和对立，造成社会矛盾。

RLHF


- RLHF (Reinforcement Learning from Human Feedback) , 人类反馈强化学习。这种训练方法将强化学习与人类反馈相结合, 通过人类的反馈来优化模型的训练。
 - RLHF在训练过程中, 以人类的偏好作为奖励信号, 指导模型的行为, 使得模型能够更快地学习到有效的策略, 并更好地捕捉复杂的人类偏好, 从而优化模型性能。
 - 通过RLHF, 模型能够更好地理解并满足人类的意图。通过人类的反馈, 可以指导模型避免学习有害或不适当的行为, 从而提高模型的安全性和可靠性。使模型输出更加符合人类的期望。

目录

1. 人工智能发展历程
2. 大模型发展过程
3. DeepSeek概览及其产业影响
- 4. 大模型演进趋势**
 - 人工智能伦理道德
 - 大模型安全
 - 大模型技术趋势与展望

多模态融合

- 大模型不再局限于单一的模态，如图像、文本或语音，而是开始实现多模态的融合，即能够处理和生成多种类型的数据。将显著提升AI模型的效果、通用性及泛化性，使模型能够更准确地捕捉和表达复杂的知识与信息。



规模与复杂度

- 随着计算能力的增强和算法的进步，未来大模型的规模可能会进一步扩大，模型复杂度也会增加，以处理更复杂的任务和数据类型。通过基于海量数据进行自监督学习，使用统一的模型和范式解决各类AI任务。

轻量化

- 为了使大模型能够在资源受限的设备上运行，模型压缩和迁移学习技术将继续得到发展，以减少模型的大小并提高其迁移能力。
 - 大模型的轻量化是指通过一系列技术手段，在保证模型精度的情况下，减少模型的复杂度、降低计算资源需求，从而提高模型的加载速度、减少内存占用，并降低网络传输成本，使得模型更容易部署和应用。

大小模型协同

- 未来的AI系统可能会采用大模型与小模型协同工作的方式。小模型可以作为样本价值判断模型，帮助大模型快速学习；同时，大模型的能力也可以传递给小模型，实现两者之间的联动和互助。这种协同工作方式将提高AI系统的效率和性能。

具身智能

- 具身智能 (Embodied Intelligence) 是指能够理解、推理并与物理世界交互的通用智能体。具身智能体通常具有多模态感知认知能力，能够通过视觉、听觉、触觉等多种感官获取外界信息，并通过物理动作与环境互动。这种智能体能够在其所在环境中学习和适应，执行复杂的任务，并表现出类似人类的智能行为。
 - 具身智能旨在创造出能够模拟人类和其他生物在自然界中学习和适应环境的智能系统。

本章总结

- 本章首先介绍了人工智能的定义、人工智能的发展历程，接着描述了大模型的特性及发展，最后讨论了人工智能的伦理和安全话题。

思考题

1. （判断题）大模型的出现会使得传统深度学习小模型失去使用的意义。

- F

名词解释

- LLM, Large Language Model, 大语言模型
- XSS, Cross-site scripting, 跨站点脚本
- CSRF, Cross-Site Request Forgery, 跨站点请求伪造
- SSRF, Server Side Request Forgery, 服务端请求伪造
- RLHF, Reinforcement Learning from Human Feedback, 人类反馈强化学习

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。
Bring digital to every person, home, and
organization for a fully connected,
intelligent world.

Copyright © Huawei Technologies Co., Ltd. All rights reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.



人工智能和算力基础



前言

- 大模型是指具有大规模参数和复杂计算结构的深度学习模型，这些模型通常由众多神经网络构建而成，拥有数十亿甚至数千亿个参数。本章节将围绕人工智能模型概念展开，介绍常见算法模型和算力芯片知识。

目标

- 学完本课程后，您将能够：
 - 了解人工智能基础概念；
 - 了解算力和AI芯片；
 - 掌握常见神经网络种类；
 - 了解大模型安全及伦理问题。

目录

1. 神经网络基础介绍

- 深度学习基础
- 神经网络组成
- 神经网络计算流程
- 神经网络结构


2. 模型架构介绍

3. 算力基础概念

4. AI芯片介绍

人工神经网络介绍


- 人工神经网络：是由人工神经元互连组成的网络，它是从微观结构和功能上对人脑的抽象、简化，是模拟人类智能的一条重要途径，反映了人脑功能的若干基本特征，如并行信息处理、学习、联想、模式分类、记忆等。
 - 人工神经网络是一种旨在模仿人脑结构及其功能的信息处理系统。



- 人工神经网络（简称神经网络）：是由人工神经元互连组成的网络，它是从微观结构和功能上对人脑的抽象、简化，是模拟人类智能的一条重要途径，反映了人脑功能的若干基本特征，如并行信息处理、学习、联想、模式分类、记忆等。

深度神经网络

- 深度学习一般指深度神经网络，深度指神经网络的层数（多层）。




- 何为深度学习呢？在前面的课程我们已经了解，深度学习是机器学习的一个子集。
- 深度学习一般指深度神经网络，深度指神经网络的层数（多层）。
- 这是模拟人类的神经网络而构建的
- 在人工神经网络设计及应用研究中，通常需要考虑三个方面的内容，即神经元作用函数、神经元之间的连接形式和网络的学习(训练)。
- 左一：<http://3ms.huawei.com/km/static/image/detail.html?fid=59876>

什么是模型

- 人工智能中的模型是指根据一定的算法和数学模型，在计算机中实现人工智能任务的系统。这些模型通过学习和优化算法，能够从数据中提取有用信息并作出决策或预测。模型是人工智能应用的核心，是实现各种智能任务的基础。
 - 学习算法：决策树、SVM、神经网络等。
 - 参数：权重参数。

深度学习整体流程



数据准备


- 数据集：在深度学习任务中使用的一组数据，其中的每一个数据称为一个样本。反映样本在某方面的表现或性质的事项或属性称为特征。
 - 训练集：训练过程中使用的数据集，其中每个样本称为训练样本。从数据中学得模型的过程称为学习（训练）。
 - 测试集：训练完成后，使用其进行预测的过程称为测试，使用的数据集称为测试集，每个样本称为测试样本。
- 深度学习所需训练数据集较大。
 - 开源数据集：可直接获取
 - 互联网数据：网络爬虫、个人收集

数据预处理

- 大部分情况下，数据需要经过预处理后才能够为算法所使用，预处理的_{操作}主要包括以下几个部分：
 - 数据过滤
 - 处理数据缺失
 - 处理可能的错误或者异常值
 - 合并多个数据源数据
 - 数据汇总

模型训练


- 模型训练过程可理解为，通过学习算法（神经网络结构）将处理好的数据（训练集）中的知识及规律总结出来（模型参数）的过程。



模型中的参数与超参数

- 为了让模型能够学习到最佳的参数，还需要设置超参数来控制训练。

- 参数由模型自动学习；
 - 各个神经元的权重值；
 - 通常以矩阵形式呈现。
- 超参数由人工手动设定。
 - 如网络层数、神经元数量等；
 - 通过经验及超参数搜索算法选择。



- 参数作为模型从历史训练数据中学到的一部分，是机器学习算的关键。有以下特征：
 - 进行模型预测时需要模型参数。
 - 模型参数值可以定义模型功能。
 - 模型参数用数据估计或数据学习得到。
 - 模型参数一般不由实践者手动设置。
 - 模型参数通常作为学习模型的一部分保存。
- 模型参数的一些例子包括：
 - 人造神经网络中的权重。
 - 支持向量机中的支持向量。
 - 线性回归或逻辑回归中的系数。

测试与部署

- 训练好的模型在测试集上进行测试，根据测试指标判定模型是否可用。
 - 分类模型常用指标有准确率、查全率、查准率、F-score等。
 - 回归模型常用指标有MAE（Mean Absolute Error）、MSE（Mean Square Error）等。
- 对于在测试集表现较好的模型可以进行部署应用。
 - 模型部署前会进行剪枝、量化等操作减小推理所需算力。
 - 裁剪量化后的模型会在云测、端侧以应用（或API）的方式对外提供推理服务。

目录

1. 神经网络基础介绍


- 深度学习基础
- 神经网络组成
- 神经网络计算流程
- 神经网络结构

2. 模型架构介绍

3. 算力基础概念


4. AI芯片介绍

神经网络组成




激活函数的概念

- 神经网络中的每个神经元节点接受上一层神经元的输出值作为本神经元的输入值，并将输入值传递给下一层，输入层神经元节点会将输入属性值直接传递给下一层（隐层或输出层）。在多层神经网络中，上层节点的输入在加权求和后与下层节点的输入之间具有一个函数关系，这个函数称为**激活函数（又称激励函数）**。





- 激活函数，是在人工神经网络的神经元上运行的函数，负责将神经元的输入映射到输出端。激活函数对于人工神经网络模型去学习、理解非常复杂和非线性的函数来说具有十分重要的作用。它们将非线性特性引入到我们的网络中。在神经元中，输入通过加权，求和后，还被作用了一个函数，这个函数就是激活函数。引入激活函数是为了增加神经网络模型的非线性。若没有激活函数的每层都相当于矩阵相乘。没有激活函数的神经网络叠加了若干层之后，还是一个线性变换，与单层感知机无异。激活函数可以分为饱和激活函数与不饱和激活函数，激活函数的右饱和指当 x 趋向于正无穷时，函数的导数趋近于0。同样的，当 x 趋向于负无穷时，函数的导数趋近于0，此时称为左饱和。当一个函数既满足右饱和，又满足左饱和，则称为饱和函数，否则称为非饱和函数。
- 连续可导。


激活函数的作用



不带激活函数的多个感知机等价于线性函数




激活函数为网络加入了非线性因素，使网络变为非线性模型。



常见激活函数


Sigmoid

$$f(x) = \frac{1}{1 + e^{-x}}$$




Tanh

$$\tanh x = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$




Softsign

$$f(x) = \frac{x}{|x| + 1}$$



ReLU

$$y = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases}$$




- Sigmoid函数单调连续，求导容易，输出有界，网络比较容易收敛。但是我们看到，在远离中心点的位置，Sigmoid函数导数趋于0，在网络非常深的时候，越来越多反向传播的梯度会落入饱和区，从而让梯度的模越来越小。一般来说，Sigmoid网络在5层之内，就会产生梯度退化为0的现象，难以训练。这种现象称为梯度消失现象。另外，Sigmoid的输出并不是以0为中心的。
- 适用用：Sigmoid 函数的输出范围是 0 到 1。由于输出值限定在 0 到 1，因此它对每个神经元的输出进行了归一化；用于将预测概率作为输出的模型。由于概率的取值范围是 0 到 1，因此 Sigmoid 函数非常合适；梯度平滑，避免「跳跃」的输出值；函数是可微的。这意味着可以找到任意两个点的 sigmoid 曲线的斜率；明确的预测，即非常接近 1 或 0。
- 缺点：
 1. 容易出现梯度消失，
 2. 函数输出并不是0均值化，
 3. 幂运算相对来讲比较耗时。
- tanh函数：tanh也具有和Sigmoid函数类似的缺点，即远离中心的位置导数趋于0，但是因为其关于0点对称，输出的均值比Sigmoid更加接近于0，因此SGD会更接近自然梯度，然而，gradient vanishing的问题和幂运算的问题仍然存在。
- Softsign函数是Tanh函数的另一个替代选择。就像Tanh函数一样，Softsign函数是反对称、去中心、可微分，并返回-1和1之间的值。其更平坦的曲线与更慢的下降导数表明它可以更高效地学习，比tTanh函数更好的解决梯度消失的问题。另一方面，Softsign函数的导数的计算比Tanh函数更麻烦。Softsign'(x)=1/(1+|x|)²

- 这个函数相比tanh函数，饱和得慢一些。
- Sigmoid, tanh, softsign函数在训练深度神经网络的过程中，都无法回避梯度消失的问题，既在远离函数中心点的位置，函数导数趋于0，在网络非常深的时候，越来越多反向传播的梯度会落入饱和区，从而让梯度的模越来越小，最终趋近于0，导致权重无法更新。
- 一般来说，如果神经网络超出5层，就会产生梯度退化为0的现象，导致模型难以训练。
- RELU线性整流函数，又称修正线性单元ReLU，是一种人工神经网络中常用的激活函数，通常指代以斜坡函数及其变种为代表的非线性函数。当输入为正时，不存在梯度饱和问题。

常见激活函数


LeakyRelu

$$\text{LeakyReLU}(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases}$$



GELU

$$\text{GELU}(x) = x * 1/2(1 + \text{erf}(x/2^{1/2}))$$




- LeakyRelu用于解决Dead ReLU问题的[激活函数](#)：针对Relu函数中存在的Dead Relu Problem，Leaky Relu函数在输入为负值时，给予输入值一个很小的斜率，在解决了负输入情况下的0梯度问题的基础上，也很好的缓解了Dead Relu问题
- GELU（Gaussian error linear units，高斯误差线性单元）可以看作 dropout的思想和relu的结合，，主要是为激活函数引入了随机性使得模型训练过程更加稳定

Softmax函数

- Softmax 函数体：

$$\sigma(z)_j = \frac{e^{z_j}}{\sum_k e^{z_k}}$$


- Softmax函数的功能就是将一个K维的任意实数向量映射成另一个K维的实数向量，其中向量中的每个元素取值都介于 (0, 1) 之间。新的向量所有维度模长之和为1。
- Softmax函数经常用作多分类任务的输出层。



- 所有概率的总和：
 - 0.09 + 0.22 + 0.68 + 0.01 = 1
- 这张图片最大的可能性： **苹果**

损失函数

- 在训练深度学习网络的时候，我们首先要将目标分类的“错误”参数化，这就是损失函数（误差函数），它反映了感知器目标输出和实际输出之间的误差。





损失函数的极值

- **目的：**让损失函数沿着负梯度的方向进行搜索，不断迭代更新参数 W ，最终使得损失函数最小化。
- **限制：** $C(W) = \frac{1}{2} \sum_{d \in D} (t_d - o_d)^2$ 的复杂高维曲面，在数学上，尚没有求极值解有效方法。
- **解决思路：**负梯度方向是函数下降最快的方向，那我们可以从某个点开始，沿着 $-\nabla C(W)$ 方向一路前行，期望最终可以找到 $C(W)$ 的极小值点，这就是**梯度下降法**的核心思想。


梯度下降法 (1)

- 蒙着眼睛下山 - 梯度下降



梯度下降法 (2)

- 梯度下降法的优化思想是用当前位置负梯度方向作为搜索方向，该方向为当前位置最快下降方向。
- 收敛：损失函数的值变化非常小或达到最大迭代次数。



- 通常情况下，在接近目标点区域的极小范围内，下降的幅度是越来越小的。但是，在目标点一定范围内可能存在梯度不稳定的情况。

梯度下降法 (3)


- 根据批量大小，梯度下降常用的方法有三种：
 - **批量梯度下降 (BGD)**：每次更新使用所有的训练数据，最小化损失函数，如果只有一个极小值，那么批量梯度下降是考虑了训练集所有数据，**但如果样本数量过多，更新速度会很慢。**
 - **随机梯度下降 (SGD)**：每次更新的时候只考虑了一个样本点，这样会大大加快训练速度，但是函数不一定是朝着极小值方向更新，且SGD对噪声也更加敏感。
 - **小批量梯度下降 (MBGD)**：MBGD每次更新的时候会考虑一定数量(batchsize)的样本，解决了批量梯度下降法的训练速度慢问题，以及随机梯度下降对噪声敏感的问题。

优化器

- 优化器，反向传播过程中，动态地调整梯度的大小和方向，使模型能够收敛到更好的位置，或者用更快的速度进行收敛。
- 作用：
 - 加快算法收敛速度；
 - 尽量避过或冲过局部极值；
 - 减小手工参数的设置难度，主要是Learning Rate（LR）。
- 常见的优化器如：普通GD优化器、动量优化器、Nesterov、Adagrad、Adadelta、RMSprop、Adam、AdaMax、Nadam。


动量优化器 (1)

- 一个最基本的改进，是为 Δw_{ji} 增加动量项，会同时考虑前一次的更新量以及这次更新的梯度：



动量优化器 (2)


- 想象一个小球，从一个随机的点开始，沿着误差曲面滚下。动量项的引入相当于赋予了小球惯性：



- 动量优化器可以加速训练，减少震荡，冲过局部极值点。

Adagrad优化器

- 随机梯度下降算法（SGD）、动量优化器的共同特点是：对于每一个参数都用**相同的学习率**进行更新。
- Adagrad的思想则是应该为不同的参数设置不同的学习率，且学习率会随着模型训练不断变化。



大学习率




小学习率

- Adagrad优化器好比打高尔夫球，开始的时候由于离目标点较远，需要使用比较大的力，以减少更新次数，而当离目标点较近时，需要用比较小的力让球进入目标点。

Adam优化器

- Adam为每个待训练的参数，同时考虑了可调节的动量项以及可调节的学习率。




- Adam试图为每个参数计算自适应的学习率，这在复杂的网络结构中非常有用，因为网络的不同部分对权值调整的敏感度不同，非常敏感的部分一般需要更小的学习率，如果用人工来识别敏感部分以及专门为其设置学习率，在实现上是比较困难或繁琐的。它或许是目前最好的优化器。

正则化

- 正则化是机器学习中非常重要并且非常有效的减少泛化误差的技术，特别是在深度学习模型中，由于其模型参数非常多非常容易产生过拟合。因此研究者也提出很多有效的技术防止过拟合，比较常用的技术包括：
 - 参数添加约束，例如 L_1 、 L_2 范数等。
 - 训练集合扩充，例如添加噪声、数据变换等。
 - Dropout
 - 提前停止

Dropout

- Dropout是一类通用并且计算简洁的正则化方法，在2014年被提出后广泛的使用。简单的说，Dropout在训练过程中，随机的丢弃一部分输入，此时丢弃部分对应的参数不会更新。
- 如图：



- 在每一轮的样本输入到神经网络进行训练时，设定一个概率 p ，使得每个神经元有一定的概率死亡，不参与网络的训练。
- 其流程为：1.首先以一定的概率 p 随机删除掉网络隐藏层中的神经元（暂时死亡），输入输出神经元保持不变。2.然后把输入 x 通过修改后的网络前向传播，把得到的损失结果通过修改的网络反向传播。一小批训练样本执行完这个过程后，在没有被删除的神经元上按照随机梯度下降法更新对应的参数（ w , b ）。3.然后继续重复这一过程：恢复被删掉的神经元（此时被删除的神经元保持原样，而没有被删除的神经元已经有所更新）从隐藏层神经元中随机选择一个一半大小的子集临时删除掉（备份被删除神经元的参数）。对一小批训练样本，先前向传播然后反向传播损失并根据随机梯度下降法更新参数（ w , b ）（没有被删除的那一部分参数得到更新，删除的神经元参数保持被删除前的结果）。
- 原始输入每一个节点选择概率0.8，隐藏层选择概率为0.5。
- Dropout的优点：
 - 相比于weight decay、范数约束等，该策略更有效。
 - 计算复杂度低，实现简单而且可以用于其他非深度学习模型。
 - 但是当训练数据较少时，效果不好。
 - Dropout训练过程中的随机过程不是充分也不是必要条件，可以构造不变的屏蔽参数，也能够得到足够好的解。


Batch Normalization

- Batch Normalization（批量标准化）是由Google提出的一种深度学习中的训练优化方法。它的主要目的是解决Internal Covariate Shift（内部协变量变换）问题，即在深层网络训练过程中，由于网络中参数变化而引起的内部节点数据分布发生变化的现象。
- 优点：
 - 加速训练收敛
 - 提高模型性能
 - 减少对初始权重和学习率的依赖
 - 防止过拟合

- 加速训练收敛：Batch Normalization通过规范化每一层的输入，使得激活函数的输入值落在对输入比较敏感的区域，这有助于增大梯度，进而加快模型的训练收敛速度。
- 提高模型性能：由于Batch Normalization有助于优化网络的权重分布，使得模型更易于训练，因此往往能够提升模型的性能。此外，通过规范化输入数据，模型对于输入的变化变得更加鲁棒，从而提高模型的泛化能力。
- 减少对初始权重和学习率的依赖：Batch Normalization使得模型对于初始权重的选择不再那么敏感，因此可以简化模型初始化过程。同时，由于Batch Normalization有助于稳定训练过程，因此可以使用较大的学习率进行训练，从而进一步加速训练过程。
- 减少过拟合：Batch Normalization通过破坏原来的数据分布，有助于缓解过拟合问题。它通过增加模型的泛化能力，使得模型能够更好地适应不同的数据集和任务。


Batch Normalization计算过程

- 计算均值和方差：
 - 在当前batch中计算特征均值和方差。
- 标准化：
$$y = \frac{x - E[x]}{\sqrt{\text{Var}[x] + \epsilon}} * \gamma + \beta$$
- 缩放平移：
 - 使用两个可学习参数gamma和beta对归一化的数据进行缩放和移位。



Layer Normalization

- 与 Batch Normalization（批归一化）不同，Layer Normalization 不是针对一个 batch 的数据的每个 channel 进行 Norm 处理，而是对单个数据的指定维度进行 Norm 处理，与 batch 无关。它在每个样本的每个特征维度上进行归一化。



- BN的第一个缺陷是依赖Batch size，第二个缺陷是对于RNN这样的动态网络效果不明显，且当推理序列长度超过训练的所有序列长度时，容易出问题。为此，提出了Layer Normalization。

目录

1. 神经网络基础介绍

- 深度学习基础
- 神经网络组成
- 神经网络计算流程
- 神经网络结构

2. 模型架构介绍

3. 算力基础概念

4. AI芯片介绍

前向传播 (Forward Propagation)

- 输入信号从输入层传输到输出层。
- 对于每个神经元：
 - 计算上层的输出值: $\theta' = WX + b$
 - 计算激活函数值: $\theta = f(\theta')$
- 最后输出: 模型预测值 ($f(x, \bar{\theta})$) 。

- 前向传播: 信息从输入传到输出层, 最后得到模型预测结果的过程。
- 主要步骤: 每个神经元接受上一层神经元的信息, 并将信息整合传给下一个神经元, 直至传到输出层的神经元 (非计算单元) 。
- 接受上一层神经元的信息并整合: 加权求和的值再经过激活函数增加非线性。
- 最后的输出是模型的预测值。那么我们如何评价模型预测结果的好坏呢? -与真实标签进行比较, 即我们拟定一个函数来衡量。我们称这个函数损失函数。
- 我们的训练算法的目的, 是最小化权重和偏置的代价函数 $C(w,b)$ 。换句话说, 我们想要找到一系列能让代价尽可能小的权重和偏置。我们将采用称为梯度下降的算法来达到这个目的。

反向传播算法

- 反向传播算法（Backpropagation）是神经网络的重要算法。它使用链式求导法则将输出层的得出误差反向传回给网络，使神经网络的权重有了较简单的梯度计算实现方法。
- 步骤：
 - 将损失函数值反向传播给每个计算单元。
 - 每个计算单元根据获得的误差更新权重。

- 如果我们直接通过最后的损失函数值用梯度下降算法优化模型，即调整参数使目标函数最小的话。每层的参数都是一层一层嵌套的，求解梯度的过程会十分复杂，且计算量很大。这是我们进入反向传播算法，反向传播等式为我们提供了一个计算代价函数梯度的方法。前向误差反向传播回每个神经元，再用梯度下降更新参数。
- 前向传播指的是信息的前向传播，而反向传播是只误差的反向传播。
- 反向传播等式为我们提供了一个计算代价函数梯度的方法。
- 反向传播的主要步骤：误差按照权重的比例分别传给每个计算单元（隐藏层的神经元），得出每个神经元需要对最后产生的误差付多少责任。然后在根据分得的误差更新权重。

目录

1. 神经网络基础介绍


- 深度学习基础
- 神经网络组成
- 神经网络计算流程
- 神经网络结构

2. 模型架构介绍

3. 算力基础概念

4. AI芯片介绍

典型神经网络结构



- 卷积神经网络（Convolutional Neural Network）是一种专门用于图像处理的神经网络，它可以自动提取图像中的特征，从而实现图像分类、目标检测等任务。
- 循环神经网络（Recurrent Neural Network）：循环神经网络是一种可以处理序列数据的神经网络，它可以自动学习序列中的规律和模式，从而实现语音识别、自然语言处理等任务。
- 图神经网络（Graph Neuron Network）是一种用于处理图形数据的神经网络模型。它可以对图形数据进行分类、聚类、预测等任务。图神经网络在社交网络分析、化学分子分析、推荐系统等领域有广泛的应用。

卷积神经网络


- 卷积神经网络 (Convolutional Neural Network, CNN) 是一种前馈神经网络，它的人工神经元可以**响应一部分覆盖范围内的单元**，对于图像处理有出色表现。它包括**卷积层** (convolutional layer)，**池化层** (pooling layer) 和**全连接层** (fully connected layer)。
- 20世纪60年代，Hubel和Wiesel在研究猫脑皮层中用于局部敏感和方向选择的神经元时发现其独特的网络结构可以有效地降低反馈神经网络的复杂性，继而提出了卷积神经网络 (Convolutional Neural Networks-简称CNN)。
- 现在，CNN已经成为众多科学领域的研究热点之一，特别是在模式分类领域，由于该网络避免了对图像的复杂前期预处理，可以直接输入原始图像，因而得到了更为广泛的应用。

- 对图像（不同的数据窗口数据）和滤波矩阵（一组固定的权重：因为每个神经元的权重固定，所以又可以看做一个恒定的滤波器filter (kernel)）做内积（逐个元素相乘再求和）的操作就是所谓的卷积操作，也是卷积神经网络的名字来源。
- 局部感知，一般认为人对外界的认知是从局部到全局的，而图像的空间联系也是局部的像素联系较为紧密，而距离较远的像素相关性则较弱。因而，每个神经元其实没有必要对全局图像进行感知，只需要对局部进行感知，然后在更高层将局部的信息综合起来就得到了全局的信息。网络部分连通的思想，也是受启发于生物学里面的视觉系统结构。视觉皮层的神经元就是局部接受信息的（即这些神经元只响应某些特定区域的刺激）。
- 参数共享，对输入的照片，用一个或者多个filter扫描照片，filter自带的参数就是权重，在同一个filter扫描的图层当中，每个filter使用同样的参数进行加权计算。权值共享意味着每一个过滤器在遍历整个图像的时候，过滤器的参数(即过滤器的参数的值)是固定不变的，比如我有3个特征过滤器，每个过滤器都会扫描整个图像，在扫描的过程中，过滤器的参数值是固定不变的，即整个图像的所有元素都“共享”了相同的权值。

卷积神经网络核心思想

- **局部感知**：一般认为，人对外界的认知是从局部到全局的，而**图像的空间联系也是局部的像素联系较为紧密，而距离较远的像素相关性则较弱**。因而，每个神经元没有必要对全局图像进行感知，只需要对局部进行感知，然后在更高层将局部的信息综合起来就得到了全局的信息。
- **参数共享**：对输入的图片，用一个或者多个卷积核扫描照片，卷积核自带的参数就是权重，在同一个卷积核扫描的图层当中，每个卷积核使用同样的参数进行加权计算。权值共享意味着每一个卷积核在遍历整个图像的时候，**卷积核的参数是固定不变的**。

卷积神经网络架构



- 输入层，用于数据的输入。
- 卷积层 (Convolutional layer)，卷积神经网络中每层卷积层由若干卷积单元组成，每个卷积单元的参数都是通过反向传播算法优化得到的。卷积运算的目的是提取输入的不同特征，第一层卷积层可能只能提取一些低级的特征如边缘、线条和角等层级，更多层的网络能从低级特征中迭代提取更复杂的特征。
- 线性整流层 (Rectified Linear Units layer, ReLU layer)，这一层神经的活性化函数 (Activation function) 使用线性整流 (Rectified Linear Units, ReLU) $f(x)=\max(0,x)$ 。
- 池化层 (Pooling layer)，通常在卷积层之后会得到维度很大的特征，将特征切成几个区域，取其最大值或平均值，得到新的、维度较小的特征。
- 全连接层 (Fully-Connected layer)，把所有局部特征结合变成全局特征，用来计算最后每一类的得分。
- 输出层，用于输出最终结果。
- 左侧图片：http://image.huawei.com/tiny-lts/v1/images/0281bccdff8137c18a163beba5a2650c_4715x2927.jpg

单卷积核计算 (1)

- 卷积计算描述

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

image 5*5

1	0	1
0	1	0
1	0	1


bias=0

filter 3*3

feature map 3*3

单卷积核计算 (2)

- 卷积计算结果演示




hanbingtao, 2017, 卷积神经网络

循环神经网络

- 循环神经网络（Recurrent neural networks，简称RNN）是一种通过隐藏层节点周期性的连接，来**捕捉序列化数据中动态信息的神经网络**，可以对序列化的数据进行分类。
- 和其他前向神经网络不同，RNN可以保存一种上下文的状态，甚至能够在任意长的上下文窗口中存储、学习、表达相关信息，而且不再局限于传统神经网络在空间上的边界，可以在**时间序列上有延拓**，直观上讲，就是本时间的隐藏层和下一时刻的隐藏层之间的节点间有边。
- RNN广泛应用在和序列有关的场景，如如一帧帧图像组成的视频，一个个片段组成的音频，和一个个词汇组成的句子。


循环神经网络架构



- LeCun, Bengio, and G. Hinton, 2015, A recurrent neural network and the unfolding in time of the computation involved in its forward computation.



深度学习的两个难题

- 梯度消失：当网络层数越多时，进行反向传播求导值越小，导致梯度消失。
- 网络退化：
 - 随着网络深度增加，网络的准确度应该同步增加。
 - 当网络更深时，网络的参数空间更大，优化问题变得更难，因此简单地增加网络深度反而会导致更高的训练误差。




残差结构

- 残差网络提出了一个可以防止训练时的梯度消失的结构，称为残差结构。
- 残差模块在输入和输出之间建立了一个直接连接，这样新增的网络层仅仅需要在原来的输入层基础上学习新的特征，即学习残差，会比较容易。



ResNet

- 在ResNet网络提出之前，传统的卷积神经网络都是将一系列的卷积层和池化层堆叠得到的，但当网络堆叠到一定深度时，就会出现退化问题。
 - 层数越多，准确率越高。




- ResNet50网络是2015年由微软实验室的何恺明提出，获得ILSVRC2015图像分类竞赛第一名。
- ResNet网络提出了残差网络结构(Residual Network)来减轻退化问题，使用ResNet网络可以实现搭建较深的网络结构（突破1000层）。

目录

- 1. 神经网络基础介绍
- 2. 模型架构介绍
 - Transformer架构介绍
 - Diffusion结构介绍
- 3. 算力基础概念
- 4. AI芯片介绍

Seq2Seq


- Seq2Seq (Sequence to Sequence, 序列到序列) 模型, 由编码器 (Encoder) 和解码器 (Decoder) 两部分组成。Seq2Seq的输入输出都可以是一个不定长的序列。
- 编码器和解码器的作用:
 - 编码器将长度可变的输入序列转换成长度固定的上下文向量 (context vector), 并且将输入序列的信息在该上下文向量中进行编码。
 - 解码器进行相反的过程, 将上下文向量进行解码, 转换成长度可变的输出序列。



- 编码器 (Encoder) 和解码器 (Decoder) 两部分组成, 一般选用RNN/LSTM/GRU等网络实现。


Attention机制

- 注意力机制：在解码器的每个步骤中，使用与编码器的直接连接来聚焦于源序列的特定部分。
- 注意力机制在输入信息中聚焦于更为关键的信息，降低对其他信息的关注度，甚至过滤掉无关信息，就可以解决信息过载问题，并提高任务处理的效率和准确性。



Transformer


- Transformer是谷歌在2017年做机器翻译任务的《Attention is all you need》的论文中提出的，目前大多数大模型以Transformer为基础。
- Transformer由Encoder和Decoder两部分组成。
 - Encoder和Decoder 部分各有N (=6) 个相同的Encoder block和Decoder block组成。



- Transformer是谷歌在2017年做机器翻译任务的《Attention is all you need》的论文中提出的，引起了相当大的反响，很多研究已经证明了Transformer提取特征的能力是要远强于LSTM（Long Short Term Memory，长短期记忆网络）的。
- Transformer解决的主要问题是捕捉文本特征，通过的方式就是Attention，这也是为什么Transformer的提出者，将他们的文章命名为《Attention is All You Need》的原因。

Transformer结构


- 输入层：
 - 位置编码
 - embedding层
- Encoder block、Decoder block
 - Self-Attention层
 - 前馈网络层
 - 残差结构



- Positional Encoding就是句子中词语相对位置的编码，让Transformer保留词语的位置信息。

Transformer计算流程 - 获取输入


- 首先将每个输入单词通过Embedding转换为词向量，然后与每一个单词的位置Embedding相加得到每一个单词的表示向量X，最终，每个单词都被嵌入为一个512维的向量。



- 每一行是一个单词的表示X。

Transformer工作流程 - Encoder


- 将得到的单词表示向量矩阵传入Encoder中，经过6个Encoder block后可以得到句子所有单词的编码信息矩阵C。
- 每一个Encoder block输出的矩阵维度与输入完全一致。



- $X_{n \times d}$: 输入矩阵, n是句子中单词数量, d表示向量的维度, 论文中d=512。

Transformer工作流程 - Decoder


- 将Encoder输出的编码信息矩阵C传递到Decoder中，Decoder依次会根据当前翻译过的1~i的单词翻译第i+1个单词。
- 在整个过程中，翻译到第i+1个单词的时候，需要通过Mask（掩盖）操作遮盖住第i+1之后的单词。



Self-Attention

- 在Transformer模型中，自注意力（Self-Attention）机制是一个核心组件，它使模型能够处理输入序列中的依赖关系。自注意力机制允许模型在生成某个位置的输出时，参考输入序列中的所有位置，从而捕捉序列内的长期依赖关系。
- 自注意力机制的基本原理是：使用一组可学习参数来衡量输入信息的重要性，并将其映射到输出信息，以便模型可以自动学习和聚焦在最重要的信息上。


生成查询向量Q、键向量K和值向量V



- 这三个向量是通过词嵌入与三个权重矩阵相乘后创建的。这些新向量在维度上比词嵌入向量更低，他们的维度是64，而词嵌入和编码器的输入/输出向量的维度是512。但实际上不强求维度更小，这只是一种基于架构上的选择，它可以使多头注意力（multiheaded attention）的大部分计算保持不变。
- x_1 与 W^Q 权重矩阵相乘得到 q_1 ，就是与这个单词相关的查询向量。最终使得输入序列的每个单词都创建一个查询向量、一个键向量和一个值向量。
- 什么是查询向量、键向量和值向量？它们都是有助于计算和理解注意力机制的抽象概念。学员们对此也有疑问。




Attention机制计算步骤

- 3步分解：
 - 第一步：query和key进行相似度计算，得到注意力分数；
 - 第二步：将权值进行归一化，得到直接可用的权重；
 - 第三步：将权重和value进行加权求和。



- 图书管 (source) 里有很多书 (value) , 为了方便查找, 我们给书做了编号 (key) 。当我们想要了解漫威 (query) 的时候, 我们就可以看看那些动漫、电影、甚至二战 (美国队长) 相关的书籍。为了提高效率, 并不是所有的书都会仔细看, 针对漫威来说, 动漫, 电影相关的会看的仔细一些 (权重高) , 但是二战的就只需要简单扫一下即可 (权重低) 。当我们全部看完后就对漫威有一个全面的了解了。
- <https://zhuanlan.zhihu.com/p/91839581>

通过矩阵运算实现自注意力机制



- 计算查询矩阵、键矩阵和值矩阵。为此，将输入句子的词嵌入到矩阵X中，将其乘以训练的权重矩阵。
- X矩阵中的每一行对应于输入句子中的一个单词。

$$Attention(Q, K, V) = softmax\left(\frac{Q \times K^T}{\sqrt{d_k}}\right) \times V = Z$$

多头注意力机制

- 在Transformer中，多头注意力机制（Multi-head Attention）是对自注意力机制的一种拓展，可以进一步增强模型捕捉不同方面信息的能力。
 - 多头注意力机制通过将输入序列切分为多个“头”（或称为子空间），并允许每个头独立地进行注意力计算，从而能够同时关注序列中不同维度的信息。
- 多头注意力机制的优势：
 - 增强信息捕获能力：通过允许每个头关注不同的信息，模型能够同时捕捉序列中多种类型的特征，从而提高了模型的表达能力和泛化能力。
 - 模型稳定性：由于多个头是并行且独立运行的，这种结构也增加了模型的稳定性和鲁棒性。
 - 多粒度信息融合：不同的头可能关注不同粒度的信息，从而有助于模型在不同层次上理解输入数据。


- 多头注意力机制的实现过程如下：
- 输入编码与分割：首先，输入序列通过嵌入层转换为向量表示，并被分割成多个头（通常是8个或更多）。每个头都会独立地处理一部分输入信息。
- 并行自注意力计算：在每个头上，模型独立地执行自注意力机制。这意味着每个头都会计算自己的注意力权重，并对输入序列中的值进行加权求和。每个头都能关注到输入序列中不同的部分或特征。
- 结果拼接与线性变换：完成每个头的自注意力计算后，模型将所有头的输出拼接起来。这个拼接后的向量通常再通过一个线性变换（例如一个全连接层），以得到与单头注意力机制相同维度的输出。

目录

1. 神经网络基础介绍
- 2. 模型架构介绍**
 - Transformer架构介绍
 - Diffusion结构介绍
3. 算力基础概念
4. AI芯片介绍

生成式模型

- GAN
- VAE
- VQ-VAE
- Diffusion Model




Diffusion Model

- 扩散模型（Diffusion Model）起源于非均衡热动力学，是一类基于概率似然（likelihood）的生成模型。扩散模型包括两个主要过程：前向过程（forward process）和反向过程（reverse process）。
 - 在前向扩散过程中，模型将输入数据逐渐转化为噪声数据，这一过程通过添加高斯噪声实现，并且每一步添加的噪声量都是可控的。通过连续添加噪声，模型可以得到数据在不同噪声水平下的表示。
 - 在反向生成过程中，模型试图从噪声数据中恢复出原始数据。这一过程需要学习如何去除添加的噪声，以逐步还原出原始数据。

- 此处介绍是基于denoising diffusion probabilistic model（DDPM）。


Diffusion Model工作原理



Diffusion Model训练流程 (1)

- 正向扩散过程：逐渐将高斯噪声添加到图像中，直到最终得到纯噪声。
- 反向去噪的扩散过程：通过训练神经网络从纯噪声开始逐渐对图像去噪，直到最终得到一个实际的图像。
 - 由 t 索引的正向和反向过程都发生在某些有限时间步长 T （DDPM作者使用 $T=1000$ ）内。从 $t=0$ 开始，在数据分布中采样真实图像 x_0 ，正向过程在每个时间步长 t 都从高斯分布中采样一些噪声，再添加到上一个时刻的图像中。假定给定一个足够大的 T 和一个在每个时间步长添加噪声的良好时间表，最终会在 $t=T$ 时通过渐进的过程得到所谓的各向同性的高斯分布。


Diffusion Model训练流程 (2)



- 假设我们已经有了了一张图像，生成产生一些噪声加入到图像中，然后就可以将该图像视作一个训练样例。使用相同的操作可以生成大量训练样本来训练图像生成模型中的核心组件。基于上述数据集，我们就可以训练出一个性能极佳的噪声预测器，每个训练step和其他模型的训练相似。当以某一种确定的配置运行时，噪声预测器就可以生成图像。


Diffusion U-net

- 模型需要在特定时间步长接收带噪声的图像，并返回预测的噪声。预测噪声与输入图像具有相同分辨率的张量。因此，网络接受并输出相同形状的张量（DDPM的作者选择了U-Net）。




- 得到的图像并非是一张精确的原始图像，而是分布（distribution），即世界的像素排列，比如天空通常是蓝色的，人有两只眼睛，猫有尖耳朵等等，生成的具体图像风格完全取决于训练数据集。
- 1. Unet模型中的层主要用于转换latents；2. 每层都是在之前层的输出上进行操作；3. 某些输出（通过残差连接）将其馈送到网络后面的处理中4. 将时间步转换为时间步长嵌入向量，可以在层中使用。

Stable Diffusion模型架构



- Stable Diffusion从功能上来说主要包括两方面：1) 其核心功能为仅根据文本提示作为输入来生成的图像 (text2img)；2) 你也可以用它对图像根据文字描述进行修改 (即输入为文本+图像)。
- Stable Diffusion是一个由多个组件和模型组成的系统，而非单一模型。当我们从模型整体的角度向模型内部观察时，可以发现，其包含一个文本理解组件用于将文本信息翻译成数字表示 (numeric representation)，以捕捉文本中的语义信息。
- 然后这些信息会被提交到图像生成器 (image generator) 中，它的内部也包含多个组件。图像生成器主要包括两个阶段：
 1. **Image information creator**：该组件运行多个steps来生成图像信息，其中steps也是Stable Diffusion接口和库中的参数，通常默认为50或100。图像信息创建器完全在图像信息空间 (或潜空间) 中运行，这一特性使得它比其他在像素空间工作的Diffusion模型运行得更快。
 2. **图像解码器**：图像解码器根据从图像信息创建器中获取的信息画出一幅画，整个过程只运行一次即可生成最终的像素图像。整个压缩过程，包括后续的解压、绘制图像都是通过自编码器完成的，将图像压缩到潜空间中，然后仅使用解码器使用压缩后的信息来重构。
- 不止Stable Diffusion通过去噪进行图像生成，DALL-E 2和谷歌的Imagen模型都是如此。

Contrastive Language-Image Pre-Training (CLIP)



数据集中大约包含4亿张图像及描述

- <https://arxiv.org/abs/2103.00020>
- CLIP需要的数据为图像及其标题，数据集中大约包含4亿张图像及描述。数据集通过从网上抓取的图片以及相应的「alt」标签文本来收集的。
- CLIP 是图像编码器和文本编码器的组合，其训练过程可以简化为拍摄图像和文字说明，使用两个编码器对数据分别进行编码。然后使用余弦距离比较结果嵌入，刚开始训练时，即使文本描述与图像是相匹配的，它们之间的相似性肯定也是很低的。随着模型的不断更新，在后续阶段，编码器对图像和文本编码得到的嵌入会逐渐相似。
- 通过在整个数据集中重复该过程，并使用大batch size的编码器，最终能够生成一个嵌入向量，其中狗的图像和句子「一条狗的图片」之间是相似的。就像在 word2vec 中一样，训练过程也需要包括不匹配的图片 and 说明的负样本，模型需要给它们分配较低的相似度分数。

目录

- 1. 神经网络基础
- 2. Transformer和Diffusion
- 3. 算力基础概念
 - 算力介绍
 - 数据类型介绍
- 4. AI芯片介绍

算力

- 算力，简而言之就是设备的计算能力（Computing Power），它涵盖了计算机的运算、数据存储与访问、与外界的数据交换以及数据显示等多方面能力。以PC而言，搭载的CPU、显卡、内存配置越高，一般来说算力就越高。



算力单位

- 当前存在多种不同的衡量方法。常见的包括：
 - MIPS（每秒钟执行的百万指令数，Million Instructions Per Second）
 - DMIPS（Dhrystone每秒钟执行的百万指令数，Dhrystone Million Instructions executed Per Second）
 - OPS（每秒操作次数，Operations Per Second）
 - FLOPS（每秒浮点运算次数，Floating-point Operations Per Second）
 - Hash/s（每秒哈希运算次数，Hash Per Second）等。
- FLOPS单位一直被视为衡量计算机运算速度的主要指标之一。

算力单位介绍

- TOPS是Tera Operations Per Second的缩写，1TOPS代表处理器每秒钟可进行一万亿次（ 10^{12} ）操作。
 - 在某些情况下，还使用 TOPS/W 来作为评价处理器运算能力的一个性能指标，TOPS/W 用于度量在1W功耗的情况下，处理器能进行多少万亿次操作。
- FLOPS定义是“每秒所执行的浮点运算次数”（floating-point operations per second）的缩写。

算力服务器



Atlas 200I DK A2
8 TOPS INT8
4 TFLOPS FP16



Atlas 900 AI 集群

目录


- 1. 神经网络基础
- 2. Transformer和Diffusion
- 3. 算力基础概念**
 - 算力介绍
 - 数据类型介绍
- 4. AI芯片介绍

常见数据类型

- 浮点数类型：
 - FP64，深度学习不常用
 - FP32
 - FP16
 - BF16
- 整数类型：
 - INT8
 - INT4，较少使用

数据类型 - FP32

- FP32/float32，一般占用4bytes，表示数值范围为 $1.175e-38 \sim 2.403e38$ 。
- FP32是一种数据类型，具体来说是深度学习中的一种浮点数据格式，用于表示32位的浮点数，即单精度浮点格式。在计算机中，数字和字符都需要以二进制形式存储，而浮点数是一种可以表示小数的二进制数。FP32占用4个字节，共32位，其中1位为符号位，8位为指数位，23位为尾数位。
 - 这种数据类型适用于大多数科学计算和通用计算任务，尤其是在训练神经网络模型时，默认使用的数据类型就是单精度FP32。



- 根据 IEEE 754 标准，32-bit长度的float由以下三个部分构成：
 - 符号位S：占1个bit，对应b31，表示正负，1代表负数，0代表正数。
 - 指数位E：占8bit，对应b30-b23，指数位宽。全0和全1有特殊用途，所以是00000001~11111110，也就是1到254，减去偏置127，指数部分最终范围为-126~127。
 - 分数位N：占23bit，对应b22-b0，尾数精度。范围为 $[(0 \sim 2^{23}) - 1] / 2^{23}$ 。

数据类型 - FP16

- FP16，即半精度浮点数，是一种16位长的二进制浮点数表示方法，在计算机图形学、深度学习等领域中得到了广泛应用。FP16采用2字节（16位）进行编码存储，其中1位表示符号，5位表示指数，10位表示分数（尾数）。这种表示方法使得FP16在存储和传输方面具有明显的优势，能够在相对较小的存储空间内存储大量数据。



- 精度相对float32低，可能会出现精度下降问题，但可以减少存储空间和计算开销。
- 在混合精度训练中，FP16和FP32的结合使用可以实现性能提升，既满足了精度的需求，又降低了计算成本。

- Half-precision floating-point(半精度浮点数)，在IEEE 754标准中是叫做binary16。
 - 符号位S：占1个bit，表示正负，1代表负数，0代表正数。
 - 指数位E：占5bit，指数位宽，全0和全1有特殊用途，所以是00001~11110，也就是1到30，减去偏置15，指数部分最终范围为-14 ~15。
 - 分数位N：占10bit，尾数精度，范围为(0~1023) /1024。

数据类型 - BF16

- BF16 (bfloat16, brain floating point) , 它是针对深度学习等计算密集型任务而设计的, 旨在解决FP64和FP32这两种高精度浮点格式在存储和计算过程中的效率问题。
 - BF16的特点在于其指数位与FP32相同, 均为8位, 但小数位(尾数位)减少到7位。这种设计使得BF16在保持一定精度的同时, 大幅减少了存储需求和计算成本。
 - 与FP16相比, BF16在数值范围上几乎与FP32相当, 这有助于避免FP16容易出现的上溢和下溢问题。



- BF16的特点在于其指数位与FP32相同, 均为8位, 但小数位(尾数位)减少到7位。这种设计使得BF16在保持一定精度的同时, 大幅减少了存储需求和计算成本。虽然BF16的精度稍逊于FP32, 但在许多深度学习应用中, 尤其是计算机视觉和语音方面, 这种精度折衷是可以接受的。
- 与FP16相比, BF16在数值范围上几乎与FP32相当, 这有助于避免FP16容易出现的上溢和下溢问题。然而, BF16的尾数精度较小, 这意味着在某些情况下, 它可能不如FP16精确。但考虑到深度学习模型通常对指数的大小比对尾数敏感得多, 因此BF16在实际应用中往往能提供与FP32相近的预测精度。
- 在性能上, BF16和FP16都具有较高的吞吐量, 并且能显著减少内存需求。具体选择哪种格式取决于应用的具体需求和硬件支持情况。例如, NVIDIA的GPU对BF16有良好的支持, 而Intel的CPU则更偏向于FP16。

INT8/INT4

- INT8是一种8位有符号整数类型，可以表示范围在-128到127之间的整数。这种类型通常用于需要使用较小整数范围的应用。
- INT4是一种4字节有符号整数类型，符号占1位。表示范围很小，使用较少。
- 两种类型通常用于模型量化：
 - 以ChatGLM-6B为例，在FP16下需要 ≥ 13 G显存，在INT4量化级别下最低只需要6G显存即可。

存储单位介绍 (1)

- 常用的存储单位包括位bit、Byte、KB、MB、GB、TB、PB、EB、ZB和YB。
 - bit，计算机中最小的数据单位，用于存放一位二进制数，即0或1。它也是存储器存储信息的最小单位。
 - Byte是计算机中表示存储容量的最常用的基本单位。它由8个bit组成，通常用于衡量文件大小或内存大小。
 - 单位换算：YB到KB之间，每下降一个单位等于乘以1024。

存储单位介绍 (2)

- 深度学习中用于训练模型的数据集大都GB、TB为单位，大模型的训练数据集则更大，通常以TB、PB为单位存储。
 - TB = 1024GB，大约相当于500部1080P（一小时左右压缩后）的视频，或20-50万张（JPEG压缩后）图片。
 - 1PB = 1024TB
 - 1EB = 1024PB
 - 1ZB = 1024EB

算力需求

- 根据业界论文^① 理论推算，端到端训练AI大模型的理论时间为 $E_t = 8 * T * P / (n * X)$ 。其中E_t为端到端训练理论时间，T为训练数据的token数量，P为模型参数量，n为AI硬件卡数，X为每块卡的有效算力。

参数量P (B)	训练阶段	数据量T (B tokens)	卡数 n	训练时长 (天)
175 (e.g. GPT-3)	预训练	3500 ^③	8192	49
	二次训练 ^②	100	2048	5.5
65 (e.g. LLaMA)	预训练	1300	2048	27
	二次训练	100	512	8
13 (e.g. LLaMA)	预训练	1000	256	34
	二次训练	100	128	7

- 已GPT-3为例，参数量为175B（1750亿）规模下，在预训练阶段，数据量35000亿，使用8192张卡，其训练时长为49天。

目录




1. 神经网络基础
2. 模型架构
3. 算力基础概念
4. AI芯片介绍

AI芯片分类

- 从业务应用来看，可以分为Training（训练）和Inference（推理）两个类型：
 - Training环节通常需要通过大量的数据输入，或采取增强学习等非监督学习方法，训练出一个复杂的神经网络模型。训练过程涉及海量的训练数据和复杂的神经网络结构，运算量巨大，需要庞大的计算规模，对于处理器的计算能力、精度、可扩展性等性能要求很高。常用的例如华为的Atlas900集群、NVIDIA的GPU集群等。
 - Inference环节指利用训练好的模型，使用新的数据去“推理”出各种结论，如视频监控设备通过后台的神经网络模型，判断一张抓拍到的人脸是否属于特定的目标。虽然Inference的计算量相比Training少很多，但仍然涉及大量的矩阵运算。在推理环节，CPU、NPU、GPU和FPGA都有很多应用价值。

- 训练芯片需要考虑的因素更多，设计上也更加复杂，精度通常为FP32、FP16
- 推理芯片考虑的因素较少，对精度要求也不高，INT8即可

通用计算 vs. AI计算：“分工”不同，共建多样性计算

		硬件结构抽象	计算特点	适用场景
通用计算 以CPU提供算力	X86 鲲鹏	 Control 控制单元 Cache 缓存单元 ALU 控制单元 缓存单元 算术逻辑单元	适合复杂逻辑运算 比如大多数通用软件 70%以上晶体管用于构建Cache和控制单元 ，计算核心从几个到几十个。	通用应用 办公、数据库、数值计算（气象预测、流体仿真、电磁仿真）等。
AI计算 以GPU提供算力	NVIDIA AMD	 TENSOR CORE 控制单元 缓存单元 算术逻辑单元	适合逻辑简单 计算密集型高并发任务 70%以上晶体管用于构建计算单元 ，	特定应用 图像识别：车牌识别、目标识别、目标检测； 自然语言处理：机器翻译、文本生成； 语言处理：语音识别、语音合成； 搜索推荐、辅助驾驶、趋势预测等。
AI计算 以NPU提供算力	昇腾	 达芬奇 CORE 达芬奇 CORE 控制单元 缓存单元 算术逻辑单元	计算核心几千或上万个。	

- CPU考虑通用计算，GPU考虑数学计算，NPU考虑AI需要的矩阵计算
- 介绍NPU可以替代GPU的原因

AI芯片技术路线

技术架构种类	定制化程度	可编辑性	算力	价格	优点	缺点	应用场景
GPU	通用型	不可编辑	中	高	通用性较强且适合大规模并行计算；设计和制造工艺成熟。	并行运算能力在推理端无法完全发挥。	高级复杂算法和通用性人工智能平台。
FPGA	半定制化	容易编辑	高	中	可通过编程灵活配置芯片架构适应算法迭代，平均性能较高；功耗较低；开发周期较短。	量产单价高；峰值计算能力较低；硬件编程困难。	适用于各种具体的行业。
ASIC	全定制化	难以编辑	高	低	通过算法固化实现极致的性能和能效、平均性能很强；功耗很低；体积小；量产后成本低。	前期投入成本高；研发时间长；技术风险大。	当客户处在某个特殊场景，可以为其独立设计一套专业智能算法软件。
类脑芯片	模拟人脑	不可编辑	高	-	功耗低；通信效率高；认知能力强。	目前仍处于探索阶段。	适用于各种具体的行业。


- 目前这几个技术方向都在发力，不存在某个技术方向被淘汰

FPGA

- FPGA, 可编程逻辑门阵列 (Field Programmable Gate Array) ,是一种可在硬件级别上进行编程和重新配置的集成电路。它具有可重构性、并行性、低延迟和低功耗等特点, 广泛应用于快速原型设计和快速迭代开发中。
- FPGA与传统的固定功能集成电路 (ASIC) 相比, 具有很高的灵活性和可重构性, 可以根据需要实现不同的逻辑功能, 而无需重新设计和制造新的芯片。

CPU、GPU设计比对（1）


- GPU主要面对类型高度统一、相互无依赖的大规模数据和不需打断的纯净计算环境。
 - 拥有若干由数以千计的更小的核心（专为同时处理多重任务而设计）组成的大规模并行计算架构；
 - 基于大吞吐量设计；
 - 有很多ALU和很少cache（和CPU目的不同，为thread提高服务），缓存合并访问DRAM，带来时延问题；
 - 控制单元合并访问；
 - 大量ALU实现大量thread并行掩盖时延问题。
 - 擅长计算密集和易于并行的程序。



CPU、GPU设计比对（2）

- CPU需要很强通用性处理不同数据类型，同时需要逻辑判断，还会引入大量分支跳转和中断处理。

- 由专为串行处理而优化的几个核心组成；
- 基于低延时设计；
 - 强大的ALU单元，可在很短时钟周期完成计算；
 - 大量缓存降低延时；
 - 高时钟频率；
 - 复杂逻辑控制单元，多分支程序可通过分支预测能力降低时延；
 - 对于依赖之前指令结果的部分指令，逻辑单元决定指令在pipeline中的位置实现数据快速转发。
- 擅长逻辑控制、串行运算。



达芬奇架构

- 昇腾AI处理器的四大主要架构之一是AI计算引擎，AI计算引擎有包含了AI core（达芬奇架构）和AI CPU。因此达芬奇架构这一专门为AI算力提升所研发的架构也就是昇腾AI计算引擎和AI处理器的核心所在。
- 达芬奇架构主要部分：
 - 计算单元：包含三种基础计算资源（矩阵计算单元、向量计算单元、标量计算单元）
 - 存储系统：AI Core的片上存储单元和相应的数据通路构成了存储系统。
 - 控制单元：整个计算过程提供了指令控制，相当于AI Core的司令部，负责整个AI Core的运行。

集群训练

- 相比于传统深度学习模型，大模型在训练过程中需要大量的计算资源和存储空间。普通的单台服务器已经无法满足需求。
- 集群由多台服务器组成，可以整合这些服务器的计算能力和存储空间，从而提供强大的计算能力和扩展性，以满足大模型训练的需求。此外，集群还可以提供数据并行和模型并行等训练策略。数据并行通过将数据集划分到不同的服务器上训练，可以加快训练速度；模型并行则将模型的不同部分分配到不同的服务器上训练，有助于解决模型过大而单个服务器无法处理的问题。

思考题

1. 以下哪些选项属于正则化方法的有哪些选项？

- A. Dropout
- B. Batch Normalization
- C. CNN
- D. RNN

- AB

本章总结

- 本章节主要介绍了深度学习基础知识、常见神经网络的种类和芯片算力相关的知识。

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。

Bring digital to every person, home, and
organization for a fully connected,
intelligent world.

Copyright © Huawei Technologies Co., Ltd. All rights reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.



人工智能业务流程概述



前言

- 本章主要讲述了AI业务构建流程，并介绍了如何训练一个大模型，即训练调优全流程，最后讲解了如何高效的使用大模型。

目标

- 学完本课程后，您将能够：
 - 了解AI业务开发整体流程
 - 大模型训练的整体流程
 - 如何高效的使用大模型

目录

1. 人工智能业务流程介绍
2. 大模型业务流程介绍
3. 大模型使用与提示工程

人工智能业务开发流程




- <https://support.huaweicloud.com/function-modelarts/index.html#>

需求分析



- 目的是什么？
- 要解决什么问题？

推荐算法领域



- 推荐系统算法主要包括**协同过滤推荐**、**基于内容推荐**、**基于知识推荐**和**混合推荐**等。
- **电商产品推荐** - 如亚马逊、淘宝的商品推荐。利用用户的浏览历史、购买记录、点击流数据等，算法包括协同过滤（User-Based CF、Item-Based CF）、矩阵分解（如SVD、MF）、深度学习方法（Wide & Deep、DeepFM、DIN等）。
- **新闻个性化推送** - 根据用户兴趣推送新闻内容。新闻阅读行为、用户画像数据是关键，常用算法包括基于内容的推荐、基于协同过滤的改进算法、深度学习结合的序列推荐模型等。
- **视频、音乐内容推荐** - YouTube、爱奇艺等平台的视频推荐系统。除了用户行为数据外，还考虑视频元数据、内容特征，算法包括深度学习嵌入模型、多模态融合模型等，如YouTube DNN、深度因子分解机（DeepFM）等。
- <https://3ms.huawei.com/km/static/image/detail.html?fid=66324>
- <https://3ms.huawei.com/km/static/image/detail.html?fid=63368>
- <https://3ms.huawei.com/km/static/image/detail.html?fid=63505>
- <https://3ms.huawei.com/km/static/image/detail.html?fid=56507>

计算机视觉领域




8 Copyright © Huawei Technologies Co., Ltd. All rights reserved.



- **安防领域**
- **目标识别** - 应用场景包括身份验证、社交媒体过滤、安全管理等。使用的数据集如 LFW (Labeled Faces in the Wild)、MS-Celeb-1M等，涉及的算法包括卷积神经网络 (CNN)、FaceNet、ArcFace等。
- **图像识别与分类** - 如物体识别、医疗影像分析等。ImageNet、COCO (Common Objects in Context) 和 ChestX-ray14 数据集常被用于训练和测试模型，使用深度学习框架如 ResNet、VGG、Inception系列模型等。
- **自动驾驶** - 包括道路标志识别、行人检测、障碍物规避等。KITTI、Cityscapes、Waymo Open Dataset等是常用的自动驾驶相关数据集，采用YOLO、SSD、Faster R-CNN等目标检测算法，以及基于激光雷达点云的PointNet、RangeNet++等三维感知算法。
- **图像生成**
- <https://3ms.huawei.com/km/static/image/detail.html?fid=57537>
- <https://3ms.huawei.com/km/static/image/detail.html?fid=65344>
- <https://3ms.huawei.com/km/static/image/detail.html?fid=61697>
- <https://3ms.huawei.com/km/static/image/detail.html?fid=61614>

自然语言处理领域



- **聊天机器人** - 如客服助手、智能音箱等。训练数据集可能包含大量对话记录、百科知识库等，常见算法有Seq2Seq模型、Transformer架构（如BERT、GPT系列模型）以及强化学习方法。
- **情感分析** - 分析用户评论、社交媒体帖子的情感倾向。IMDb电影评论数据集、Twitter情感分析数据集等是常用的基准数据集，常用算法包括词袋模型、TF-IDF、深度学习模型如TextCNN、LSTM和双向LSTM等。
- **机器翻译** - 在不同语言间进行实时翻译。WMT（Workshop on Machine Translation）提供的多种语言对数据集用于训练翻译模型，Google的Transformer模型及其变体如Transformer-XL、BERT为基础的Transformer架构是这一领域的主流算法。
- **语音识别和生成**：将语音转换为文字，或者将文字转换为语音，是语音助手和自动语音翻译系统的基础。
- <https://3ms.huawei.com/km/static/image/detail.html?fid=65892>
- <https://3ms.huawei.com/km/static/image/detail.html?fid=64955>

数据准备（1）

- 数据收集

- 推荐系统：需要收集用户的历史行为数据，这可能包括用户的购买历史、浏览记录、评分数据等，可以选择使用公开的数据集，如MovieLens电影评分数据集。
- 计算机视觉：获取相关领域多样化的图像或视频数据，以涵盖模型应识别的各种对象、场景和条件。考虑使用公开的数据集作为起点，例如ImageNet、COCO、PASCAL VOC等。
- 自然语言处理：可以使用爬虫从网络上抓取相关文本，也可以从公开的数据集、书籍、新闻、社交媒体平台等来源获取。此外，调查问卷也是收集特定数据的有效途径。

数据准备（2）

- 数据清洗

- 该过程需要清除一些错误和无用的信息，例如图像中重复的图片，与任务不相关的图片等；除去文本中的重复项、拼写错误项等；用户的重复记录或异常值等。

- 特征工程（非必须）

- 根据推荐系统的需求，可能需要从原始数据中提取有用的特征，例如用户的个人信息、物品的属性或者用户的行为模式等。特征工程的目的是创建出能够帮助模型更好理解数据的特征，从而提高推荐的准确性。
- 计算机视觉和自然语言处理目前已不需要该操作。

数据准备 (3)


- 数据标注：
 - 对于监督学习任务，需要为每个数据项标注正确的标签。这可以是手动标注，也可以使用自动化工具辅助标注。标注的质量和准确性对模型的训练效果至关重要。
- 划分数据集：
 - 将清洗和标注后的数据划分为训练集、验证集和测试集。训练集用于训练模型，验证集用于调整模型参数和选择最佳模型，测试集用于评估模型的性能。
- 预处理：
 - 对数据进行预处理，如归一化、编码等，以便于模型更好地处理。
- 数据分析与评估：
 - 在建立数据集之后，要进行详细的数据分析，以确保数据集的质量、多样性和平衡性。此外，还需要评估数据集是否符合预期目标，并准备好为模型训练提供支持。

模型选择与设计

- 根据任务类型和数据特性选择合适的深度学习模型架构，如：
 - 图像识别任务：卷积神经网络（CNN）如VGG、ResNet、YOLO等；
 - 文本处理任务：循环神经网络（RNN）、长短时记忆网络（LSTM）、门控循环单元（GRU）、Transformer（BERT、GPT等）；
 - 基于深度神经网络的推荐算法、基于注意力机制（Attention Mechanism）的推荐算法等。
- 设计模型层次结构，包括输入层、隐藏层（卷积层、循环层、自注意力层等）、输出层及潜在的池化层、归一化层等辅助层。
- 超参数选择：
 - 确定模型的超参数，如学习率、批量大小、正则化强度、层数、节点数、dropout比率等。

模型训练

- 前向传播：计算损失函数，即计算本次预测与真实标签的差异。
- 反向传播：根据损失函数优化模型中的参数，使得下次预测尽可能接近真实值。



模型评估（1）

- 分类任务评估指标

- 准确率（Accuracy）：这是最基本的评估指标之一，它衡量的是模型正确预测的样本数占总样本数的比例。
- 精确率：分类任务中，模型预测正例的结果中，确实是正例的比例。
- 召回率（Recall）：针对二分类或多类别问题，精确率是指模型预测为正例中真正为正例的比例，反映了模型预测为正例的能力。
- F1分数（F1-Score召回率是指所有真正的正例中被模型正确预测出来的比例，体现了模型找出所有正例的能力。）：是精确率和召回率的调和平均数，综合了精确率和召回率，当F1值越高，表明模型在这两者之间取得了较好的平衡。


模型评估（2）

- 回归任务评估指标

- 均方误差（Mean Squared Error, MSE）：它是预测值与真实值之差平方的平均值，用于衡量预测误差的大小。
- 均方根误差（Root Mean Squared Error, RMSE）：它是MSE的平方根，单位与原始观测值相同，更直观反映预测值与真实值之间的差距。
- 平均绝对误差（Mean Absolute Error, MAE）：是预测值与真实值绝对差的平均值，相比MSE对异常值更鲁棒。

模型部署

- 模型转换为中间件格式
- 量化：FP32转换为FP16、INT8等
- 模型封装：将模型封装为API上线




- Pytorch训练完的文件类型是.pth，ONNX是中间件，AI公司共同开发的。

目录

1. 人工智能业务流程介绍
- 2. 大模型业务流程介绍**
 - 预训练
 - 模型微调
 - RHLF
 - 模型评估
3. 大模型使用与提示工程

大模型业务开发流程

业务需求



- <https://support.huaweicloud.com/function-modelarts/index.html#>

大模型更复杂、参数量更大

- 大模型通常包含数十亿甚至更多的参数，模型大小可以达到数百GB甚至更大。
 - 基于Transformer的大模型采用了自注意力机制，这本身就带来大量的参数。自注意力机制允许模型独立地考虑输入序列中的每个位置，并灵活地捕捉长距离依赖关系，这进一步增加了模型参数量的需求。
 - 在面对复杂且高维的数据分布时，较大的参数量可以让模型更好地拟合数据，减少偏差，提高模型在训练集上的表现。特别是在处理自然语言这样的任务时，语言的丰富性和复杂性要求模型具备足够的容量去理解和生成各种各样的句子结构和语义。
- 例如，根据资料推测的GPT-3的参数量约为1750亿，Meta AI的开源的大语言模型LLaMa2也有7B（70亿参数）、13B（130亿参数）、70B（700亿个参数）三个版本。

大模型所需数据量更大


- 与传统模型相比，大模型的参数量剧增，这也使得训练数据集也要适应参数的增加，大模型学习更多的数据，也进一步提高模型本身能力。
- 下图是几个典型大模型的训练数据分布。

数据		GPT3-175B	LLaMA-65B	GLM-130B
数据说明	数据来源	CommonCrawl Books1、2 WebText2 Wikipedia	CommonCrawl C4 Github Wikipedia Books ArXiv StackExchange	Pile、 Chinese Wudao、 Corpora
数据处理	过滤			
	去重			
训练数据	配比	60%， 22%， 8%， 8%， 3%	67%,15%,4.5%,4.5%,2.5%,2.0%	
	tokens	300B	1.4T	400B

- 这里需要讲解数据集需要清洗，错误的数据、重复的数据，GTP3原始数据45T，过滤后仅保留了570GB的数据。而且数据的质量不同，使用的比例也不同。

大模型训练数据的多样性

- 训练大模型需要大规模、高质量、多模态的数据集，通常需要从各个领域和多个数据源收集数据，这些数据可以是文本、图像、语音、视频等多种形式。




- 图1: <https://www.huaweicloud.com/intl/zh-cn/>
- 图2: <https://www.huaweicloud.com/intl/zh-cn/product/modelarts.html>
- 图3、右1: smartvi

大模型能力更强

- **更强的学习能力：**由于大模型拥有更多的参数和更复杂的结构，它们可以更好地拟合数据，并具备更强的学习能力。这使得大模型能够处理更大规模的数据集，更深入地发现数据中的规律和模式，从而在多个任务上展现出更高的性能。
- **更好的泛化能力：**大模型的泛化能力更强，这意味着它们在新数据或未见过的数据上也能表现出良好的性能。这种能力使得大模型能够更好地适应各种实际应用场景，减少过拟合的风险。
- **更强的多任务处理能力：**大模型通常具有较强的多任务处理能力，这意味着它们可以在一个模型中同时处理多个任务，而无需为每个任务单独训练一个模型。这种能力提高了模型的灵活性和效率，降低了维护成本。

大型语言模型的训练过程




- 预训练 (Pretraining) 阶段需要利用海量的训练数据，包括互联网网页、维基百科、书籍、GitHub、论文、问答网站等，构建包含数千亿至数万亿单词的具有多样性的内容。利用由数千块高性能GPU 和高速网络组成超级计算机，花费数十天完成深度神经网络参数训练，构建基础语言模型 (Base Model)。基础大模型构建了长文本的建模能力，使得模型具有语言生成能力，根据输入的提示词 (Prompt)，模型可以生成文本补全句子。

预训练数据集

- 大模型的数据集来源丰富多样，主要涵盖以下几个方面：
 - 互联网上的公开数据：互联网是一个巨大的数据宝库，其中包含了大量的文本、图片、视频等各类数据。开发者可以通过爬取互联网上的这些数据来构建其数据集。这些数据可能来自新闻网站、社交媒体、博客文章、论坛讨论等各种来源。
 - 专业数据库与机构发布的数据：许多专业机构、数据库和学术组织会公开发布经过整理和处理的数据集，这些数据集通常具有较高的质量和可靠性。大模型可以利用这些数据进行训练，以提高其性能和准确性。
 - 企业内部数据：对于某些定制化的大模型，企业可能会使用自己的内部数据来构建数据集。这些数据可能包括企业的业务数据、用户行为数据、产品数据等，有助于模型更好地适应企业的实际需求。
 - 用户生成内容：随着社交媒体和在线平台的普及，用户生成内容（如评论、评分、反馈等）也成为了大模型数据集的重要来源。这些数据反映了用户的真实需求和偏好，有助于模型更好地理解 and 满足用户需求。


数据并行

- 数据并行：由于训练数据集太大，需要将数据集分为N份，每一份分别装载到N个计算节点中，同时，每个计算节点持有一个完整的模型副本，分别基于每个计算节点中的数据去进行梯度求导。然后，在计算节点0上对每个节点中的梯度进行累加，最后，再将节点0聚合后的结果广播到其他节点。



张量并行


- 张量并行训练是将一个张量沿特定维度分成 N 块，每个设备只持有整个张量的 $1/N$ ，同时不影响计算图的正确性。这需要额外的通信来确保结果的正确性。



- 按行切分权重
 - 有几块计算单元就将参数切分为几份，同时为了矩阵计算，数据也需要切分。
- 按列切分权重
 - 同样根据计算节点数量切分 w ，此时输入数据 x 不需要切分。

流水线并行

- pipeline并行方式，如下图所示，假设有四张NPU，将大模型按照层将参数切分为4份，依次放在device0, 1, 2, 3上。对于一份minibatch数据，先在device0上执行前向（对应图中灰色块F0），计算结束后将device0的结果发送到device1继续执行前向（对应图中黄色块F0），直到最后一个NPU，即device3完成前向后，立刻在device3上计算loss并执行反向计算（对应图中紫色块B0），反向计算直到device0完成后，在每张卡上完成优化器参数更新，进一步完成模型参数更新。



目录


1. 人工智能业务流程介绍
- 2. 大模型业务流程介绍**
 - 预训练
 - 有监督微调
 - 强化学习
 - 模型评估
3. 大模型使用与提示工程

SFT（Supervised Fine-Tuning）

- SFT（Supervised Fine-Tuning）有监督微调是指在源数据集上预训练一个神经网络模型，即源模型。然后创建一个新的神经网络模型，即目标模型。
- 目标模型复制了源模型上除了输出层外的所有模型设计及其参数。
- 这些模型参数包含了源数据集上学习到的知识，且这些知识同样适用于目标数据集。源模型的输出层与源数据集的标签紧密相关，因此在目标模型中不予采用。
- 微调时，为目标模型添加一个输出大小为目标数据集类别个数的输出层，并随机初始化该层的模型参数。在目标数据集上训练目标模型时，将从头训练到输出层，其余层的参数都基于源模型的参数微调得到。

Adapter Tuning


- 随着计算机硬件性能的提高，预训练模型参数量越来越多，在训练下游任务时进行全模型微调变得昂贵且耗时，Adapter 的出现缓解了这个。Adapter在预训练模型每层中插入用于下游任务的参数，在微调时将模型主体冻结，仅训练特定于任务的参数，减少训练时算力开销。



在预训练模型每一层(或某些层)中添加 Adapter 模块，微调时冻结预训练模型主体，由 Adapter 模块学习特定下游任务的知识。


Prefix Tuning

- Prefix Tuning是在输入 token之前构造一段任务相关的virtual tokens作为Prefix, 然后训练的时候只更新Prefix部分的参数, 而Transformer中的其他部分参数固定。




Prompt Tuning

- 该方法可以看作是 Prefix Tuning 的简化版本，只在输入层加入 prompt tokens，并不需要加入 MLP 进行调整来解决难训练的问题。
- 固定预训练参数，为每一个任务额外添加一个或多个 embedding，之后拼接 query 正常输入 LLM，并只训练这些 embedding。左图为单任务全参数微调，右图为 Prompt tuning。



LoRA: Low-Rank Adaptation of Large Language Models

- LoRA 的实现思想很简单，如下图所示，就是冻结一个预训练模型的矩阵参数，并选择用 A 和 B 矩阵来替代，在下游任务时只更新 A 和 B。




- 在原始预训练语言模型（PLM）旁边增加一个旁路，做一个降维再升维的操作，来模拟所谓的内在秩。
- 训练的时候固定PLM的参数，只训练降维矩阵A与升维矩阵B。
- 模型的输入输出维度不变，输出时将BA与PLM的参数叠加。
- 用随机高斯分布初始化A，用0矩阵初始化B，保证训练的开始此旁路矩阵依然是0矩阵。

目录

1. 人工智能业务流程介绍
2. 大模型业务流程介绍
 - 预训练
 - 有监督微调
 - RLHF
 - 模型评估
3. 大模型使用与提示工程

Alignment


- 用**人类更喜欢的数据**去做训练 (SFT+RLHF) :
 - 真实性：是虚假信息还是误导性信息？
 - 无害性：它是否对人或环境造成身体或精神上的伤害？
 - **有用性**：它是否解决了用户的任务？



- 为什么要使用指令微调：因为GPT是基于海量语料训练的，它的输出是随机的，可能是不真实的，或者是人不感兴趣的甚至是对人有害的。
- 为什么要使用强化学习：1.标注数据成本高；2.强化学习只告诉模型好不好，而不告诉模型怎样才能变好，强化学习能给予模型更大的探索自有，突破监督学习的天花板。

RLHF


- 基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）是一种利用人类反馈来优化模型，从而有效地进行自我学习的方法。
- RLHF 将人类反馈纳入奖励功能，因此大模型可以执行更符合人类目标、愿望和需求的任务。



- RLHF 是公认的确保 LLM 制作真实、无害且有用的内容的行业标准技术。但是，人类沟通是一个主观的创造性过程，而 LLM 输出的有用性则深受人类价值观和偏好的影响。每个模型的训练方式都略有不同，所用的人类响应者也不尽相同，因此即使是竞争力相当的 LLM，输出也会有所差异。每个模型涉及人类价值观的程度完全取决于创建者。

训练奖励模型（Reward Model, RM）

- 在数据集中随机抽取问题，使用有监督指令微调生成的模型（SFT Model），对于每个问题，生成多个不同的回答。人类标注者对这些结果综合考虑给出排名顺序。这一过程类似于教练或老师辅导。
- 接下来，使用这个排序结果数据来训练奖励模型。**对多个排序结果，两两组合，形成多个训练数据对。**
- RM模型接受一个输入，给出评价回答质量的分数。这样，对于一对训练数据，调节参数使得高质量回答的打分比低质量的打分要高。



奖励模型训练步骤

- 数据准备**：首先，我们需要准备一批用于训练奖励模型的数据。这些数据包括文本样本和对应的人类评价分数。这些分数可以通过众包平台或专家评价获得，反映了人类对文本质量的感知。
- 模型构建**：接下来，我们需要构建一个神经网络作为奖励模型。这个模型可以是一个简单的多层感知机（MLP），也可以是一个更复杂的模型，如Transformer结构。关键是确保模型具有足够的表达能力来捕捉人类的评价标准。
- 训练过程**：使用准备好的数据对奖励模型进行训练。训练目标是最小化模型预测的人类评价分数与实际评价分数之间的误差。这通常可以通过梯度下降等优化算法实现。
- 验证与调优**：在训练过程中，我们需要对模型进行验证，确保它能够在未见过的数据上准确预测人类评价。如果发现模型性能不佳，我们可能需要对模型结构或训练策略进行调整。

强化学习


- 强化学习相较于监督学习更有可能考虑整体影响。
 - 监督学习针对单个词元进行反馈，其目标是模型针对给定输入后得到确切答案；强化学习则是针对整个输出结果进行反馈而不针对特定词元。反馈的颗粒度不同使得强化学习更适合大语言模型。
- 强化学习更容易解决幻觉问题。
 - 监督学习会促使模型给出一个结果，即使是在模型不包含或不知道答案的情况下；而强化学习则可以通过答案的奖励分数，促使模型放弃低分值的答案。
- 强化学习可以更好地解决多轮对话奖励累计问题。
 - 多轮对话的交互情况及是否达成最终目标，很难有效通过监督学习方法构建，但是通过强化学习构建奖励函数，可以通过整个对话的连贯性及背景对当前模型输出的优劣做判断。

RLHF训练步骤

在特定领域或指令和人类示范语料库上微调预训练的LLM

收集人类标注的数据集，训练一个奖励模型

使用强化学习 (例如 PPO)，用此数据集和奖励模型进一步微调LLM



目录

1. 人工智能业务流程介绍
2. 大模型业务流程介绍
 - 预训练
 - 有监督微调
 - RLHF
 - 模型评估
3. 大模型使用与提示工程

大模型为什么需要评测

- 大模型是一个能力很强的函数 f ，与之前的机器学习模型并无本质不同。那么，为什么要研究大模型的评测？大模型评测跟以前的机器学习模型评测有何不同？
- 研究评测可以帮助我们更好地理解大模型的长处和短处。
 - 尽管多数研究表明大模型在诸多通用任务上已达到类人或超过人的水平，但仍然有很多研究在质疑其能力来源是否为对训练数据集的记忆。
- 研究评测可以更好地为人与大模型的协同交互提供指导和帮助。
 - 大模型的服务对象是人，那么为了更好地进行人机交互新范式的设计，我们便有必要对其各方面能力进行全面了解和评测。
- 研究评测可以更好地统筹和规划大模型未来的发展的演变、防范未知和可能的风险。

- 如，人们发现，当只给大模型输入 LeetCode 题目编号而不给任何信息的时候，大模型居然也能够正确输出答案，这显然是训练数据被污染了。
- 如，我们最近的研究工作 PromptBench：首个大语言模型提示鲁棒性的评测基准，便详细地评测了大模型在“指令理解”方面的鲁棒性，结论是其普遍容易受到干扰、不够稳定，这便启发了我们从 prompt 层面来加强系统的容错能力。
- 大模型一直在不断进化，其能力也越来越强。那么，通过合理、科学的评测机制的设计，我们能否用演化的角度来评测其能力？如何提前预知其可能的风险？这都是重要的研究内容。

评测维度

- 大语言模型与传统自然语言处理算法不同，它能够执行多种复杂的自然语言处理任务。因此，模型评测也需要从多个维度出发，从整体上基本可以分为三个方面：
 - 知识与能力：大语言模型具有丰富的知识和解决多种任务的能力，包括自然语言处理（文本分类、信息抽取等）、知识问答（阅读理解、开放领域问答等）、自然语言生成（文本摘要、文本创作等）、逻辑推理、代码生成等。
 - 伦理与安全：模型在训练时基本遵循3H原则，帮助性（Helpfulness）、真实性（Honesty）、无害性（Harmless），其中无害性则是期待大模型的回答能和人类的价值观对齐。
 - 垂直领域：主要包括复杂推理能力（例如知识推理、数学推理）、环境交互能力（例如用于家庭任务的智能体根据语言指令生成动作）和特定领域问题解决能力（例如金融、法律、医疗等领域）。

评测体系

- GLUE和SuperGLUE：这两个基准测试旨在评估模型在理解自然语言的能力。它们包含多种任务，如文本分类、推理、问答和情感分析。GLUE和SuperGLUE基准测试模拟了真实世界的语言处理场景，并成为了衡量模型自然语言理解能力的标准。
- GSM8K和MMLU：这些基准测试覆盖了57个不同的学科，从而为大模型提供了一个全面的知识领域评估。GSM8K侧重于数学问题解决，而MMLU则是一个多项选择题集，测试大模型在多学科知识上的理解和推理能力。
- BLUE-bench：专注于生物医学领域的基准测试，检验模型在医学问答和相关任务上的性能。
- Adversarial Robustness Benchmarks：通过对抗样本来测试模型在面对恶意输入时的抵抗力，从而评估模型的安全性。
- LLM Ethics Benchmarks：伦理基准测试评估大模型在生成内容时是否会违背社会公认的道德和伦理规范，例如在偏见、毒性和诚实性方面的表现。

常见评测指标

- BLEU
 - 思想：常用于机器翻译任务。比较候选译文和参考译文里的n-gram的重合程度，重合程度越高就认为译文质量越高。unigram用于衡量单词翻译的准确性，高阶n-gram用于衡量句子翻译的流畅性。
- NIST
 - 思想：在BLEU方法上的一种改进，引入了每个n-gram的信息量(information) 的概念，使一些出现少的重点的词权重给的大。
- ROUGE
 - 思想：可以看做是BLEU 的改进版，专注于召回率而非精度，查看有多少个参考译句中的 n 元词组出现在了输出之中。Rouge-N、Rouge-L分别是基于N-gram计算和基于最长公共子序列计算的分数。

- <https://3ms.huawei.com/km/blogs/details/14813656>

大模型评测的挑战（1）

- 基础模型能力多样化，难以评测
 - 大模型技能涌现，难以全面公平的评测，比如斯坦福从 7 个维度 42 个场景任务开展评测，SuperCLUE 定义了 70 个场景任务，C-Eval 选取了 52 个场景任务，AGIEval 选取了 20 种标准化考试任务。
- 大模型评测，缺乏业界统一标准
 - 测试标准，测试方法缺乏业界标准，不同的评测机构，评测对象，评测范围，评测结果差异大；基于公开数据集的测试，一方面公开数据集非常多选择与测试工作量都很大，另一方面无法保证公开数据集数据不在模型的训练集中。


大模型评测的挑战（2）

- 缺乏针对企业应用的评测标准
 - 业界没有针对企业应用的评测标准，而且企业各领域任务关注的模型不同能力，如客服场景关注指令遵从和幻觉抑制，研发场景关注代码生成等；
 - 互联网的开源数据无法用于评测模型在企业业务场景下的表现；
 - 专业评测平台测试，存在企业数据泄露风险。
- 模型更新迭代快，人工评测工作量大，重复工作多
 - 模型日新月异，如果依靠人工评测，工作量很大，重复工作多，且人工评测存在不同。
 - 专业评测，准备数据集工作量大，比如：专家标注大量数据费时费力，成本高昂，同样也存在任务定位与覆盖度的问题。

目录

1. 人工智能业务流程介绍
2. 大模型业务流程介绍
- 3. 大模型使用与提示工程**
 - 如何使用大模型
 - 提示工程及基础方法
 - 高阶提示方法
 - 提示框架

如何更好的使用大模型



- 提供尽可能清晰和具体的说明（instructions）来表达您希望模型做什么。这将引导模型朝着你期望的方向输出内容，并降低收到无关或错误回复的可能性。
- 多数大模型都具备了涌现的能力，可以解决较为复杂的问题，并且知识覆盖面非常广。
- 它们可以理解和分析用户输入的自然语言，在不同领域、任务内为用户提供服务和帮助。
- 但是，和大模型沟通还是需要一些技巧的。

ChatGLM3

- ChatGLM3是智谱AI公司于2023训练的大语言模型。GLM-3是一个基于Transformer的通用预训练语言模型，它由大量的文本数据训练而成，可以理解和生成自然语言。
- 强大的语言处理能力：能够理解用户的问题，并生成合适的回答。还可以进行文本分类、情感分析、命名实体识别等任务。
- 大规模的知识库：学习了大量的文本数据，具有广泛的知识储备。可以回答各种类型的问题，并给出详细的解释和例子。
- 适应性强：能够适应各种场景和语境，与用户进行自然、流畅的对话。可以使用不同的语言和方言进行交流，并能够处理各种语言表达方式。
- 可定制性：可以根据用户的需求和场景进行定制，提供个性化的服务和支持。可以适应不同的领域和任务，并能够根据用户的反馈进行改进和优化。

ChatGLM3示例

输入：

你是一位职场人，请根据以下要求制定一份工作汇报策略：

场景：向直属领导单独汇报

要求：积极沟通，寻求同事的支持，记录工作过程，具体明确，展现工作热情并清晰展现工作成果
200字概括

输出：

工作汇报策略：在向直属领导单独汇报时，首先，要积极与同事沟通，了解他们的工作进展和成果，以便在汇报中展示团队协作情况。其次，要记录工作过程中的关键事件和解决方案，以提高汇报的准确性。然后，在汇报时要具体明确，使用数据和事例来支持工作成果，同时展现工作热情。最后，在汇报结束后，接受领导的反馈，并根据反馈进行改进。通过以上策略，可以确保汇报的质量和效果，展现自己的专业能力和团队精神，获得领导的认可和支持。

文心一言

- 文心一言是百度研发的人工智能大语言模型产品，能够通过上一句话，预测生成下一段话。使用者都可以通过输入指令和文心一言进行对话互动、提出问题或要求，让文心一言高效地帮助人们获取信息、知识和灵感。
- 文心一言由文心大模型驱动，具备理解、生成、逻辑、记忆四大基础能力。
 - 理解能力：听得懂潜台词、复杂句式、专业术语；
 - 生成能力：快速生成文本、代码、图片、图表、视频；
 - 逻辑能力：复杂的逻辑难题、困难的数学计算、重要的职业/生活决策统统能解决；
 - 记忆能力：不仅有高性能，更有好记性。N轮对话过后，话里的重点，它总会记得，帮你步步精进，解决复杂任务。

文心一言示例

输入：

你是一位职场人，请根据以下要求制定一份工作汇报策略：

场景：向直属领导单独汇报

要求：积极沟通，寻求同事的支持，记录工作过程，具体明确，展现工作热情并清晰展现工作成果

200字概括

输出：

工作汇报策略：

在向直属领导单独汇报时，我会采取积极沟通的态度，详细阐述工作进展，并寻求同事的支持与协助。为确保汇报内容具体明确，我将详细记录工作过程，包括关键节点、遇到的挑战及解决策略。同时，展现我对工作的热情与投入，让领导感受到我的责任心和积极性。最后，我会清晰展现工作成果，用数据或实例证明我的工作成效，为领导提供全面的工作汇报。

通义千问

- 通义千问是阿里云基于海量数据进行训练，具有强大的自然语言理解和生成能力的超大规模语言模型。
- 广泛的知识覆盖：可以解答各种领域的知识性问题，包括但不限于科学、技术、文化、历史、娱乐等。
- 多轮对话与上下文理解：在对话过程中，能理解上下文信息，并根据对话历史进行连贯和恰当的回答。
- 代码写作与算法解释：能够编写简单到复杂的代码，并解释算法的工作原理。
- 创造性内容生成：可以根据用户需求创作故事、诗歌、文章等文学作品。

通义千问示例

输入：

你是一位职场人，请根据以下要求制定一份工作汇报策略：
场景：向直属领导单独汇报
要求：积极沟通，寻求同事的支持，记录工作过程，具体明确，展现工作热情并清晰展现工作成果
200字概括

输出：

在单独向直属领导汇报时，我将坚持以积极互动的方式沟通，全面记录并详尽梳理工作流程，确保每项任务进展和结果具体明确。在汇报中融入团队协作元素，适时表达同事间相互支持的具体事例，营造正面的团队氛围。我将用饱满的工作热情叙述工作经历，结合实际案例和数据，有力证明工作成果，清晰展示个人及团队对组织目标的实质贡献。同时，对于工作中的难点与挑战，不仅要真实反馈，更要提出具有针对性的解决方案及寻求同事帮助的过程，从而展现解决问题的能力 and 持续提升的决心。

讯飞星火认知大模型

- 讯飞星火认知大模型是科大讯飞发布的大模型，拥有跨领域的知识和语言理解能力，能够基于自然对话方式理解与执行任务。从海量数据和大规模知识中持续进化，实现从提出、规划到解决问题的全流程闭环。

多模
交互

代码
能力

文本
生成

数学
能力

逻辑
推理



语言
理解

知识
问答

讯飞星火认知大模型示例

输入：

你是一位职场人，请根据以下要求制定一份工作汇报策略：

场景：向直属领导单独汇报

要求：积极沟通，寻求同事的支持，记录工作过程，具体明确，展现工作热情并清晰展现工作成果
200字概括

© 由星火AI生成

输出：

在单独向直属领导汇报工作时，我将以积极的态度进行沟通，确保信息的准确传递。我会先与相关同事进行讨论，获得他们的支持和反馈，以便更全面地展示工作成果。在汇报过程中，我会详细记录每个阶段的工作进展，确保内容具体明确，便于领导理解和评估。同时，我会展现我对工作的热情和对团队目标的承诺。通过清晰的逻辑和数据支持，我将突出我们的成就和未来的发展方向，以赢得领导的认同和支持。

盘古大模型

- 盘古大模型是面向行业的大模型，包含5类L0基础大模型、L1行业大模型及L2场景模型三层架构。



- 未提供免费试用

目录

1. 人工智能业务流程介绍
2. 大模型业务流程介绍
- 3. 大模型使用与提示工程**
 - 如何使用大模型
 - 提示工程及基础方法
 - 高阶提示方法
 - 提示框架

提示工程（Prompt Engineering）

- 提示工程（Prompt Engineering），指的是通过结构化文本等方式来完善提示词，引导LLM输出期望的结果。
- 研究人员可利用提示工程来提升大语言模型处理复杂任务场景的能力，如问答和算术推理能力。
- 开发人员可通过提示工程设计、研发强大的工程技术，实现和大语言模型或其他生态工具的高效接轨。
- 提示工程在实现和大语言模型交互、对接，以及理解大语言模型能力方面都起着重要作用。用户可以通过提示工程来提高大语言模型的安全性，也可以赋能大语言模型，比如借助专业领域知识和外部工具来增强大语言模型能力。

零样本提示 (Zero-Shot Prompting)

- 零样本提示 (zero-shot prompting) , 即用户不提供任务结果相关的示范, 直接提示语言模型给出任务相关的回答。
- 大语言模型有能力实现零样本提示, 但也取决于任务的复杂度和已有的知识范围。

Q: <问题>?

A:

零样本提示示例

提示：

苹果中的某些物质可能引起食用者过敏，引发皮疹、呼吸困难等症状；同时苹果中的果糖和膳食纤维过多可能导致腹胀、腹泻等消化不良症状。
正负向评价：

输出：

该描述中包含了苹果的潜在负面影响，没有直接提及苹果的任何积极方面。以下是对描述的正负向评价分析：

1. 负向评价：

- "苹果中的某些物质可能引起食用者过敏"：这指出了苹果对于某些人群可能产生的健康风险，是一个明确的负向评价。
- "引发皮疹、呼吸困难等症状"：详细列出过敏反应的症状，进一步强化了苹果可能带来的负面健康影响。
- "果糖和膳食纤维过多可能导致腹胀、腹泻等消化不良症状"：再次强调了苹果消费的潜在副作用，这是关于苹果潜在不良影响的负向评价。

在这段描述中，并没有提到苹果的任何正面属性，如营养价值或健康益处，因此整体上它偏向于负向评价。

2. 正向评价：

尽管描述中没有直接的正向评价，但可以推测，由于苹果被广泛认可为一种健康食品，提到的过敏原和消化问题通常不会妨碍大多数人食用苹果。然而，这种正向的观点是基于普遍知识而不是描述本身提供的。

综上所述，描述集中于苹果的潜在风险，没有明确表达其任何正面特征，因此可以判断为负向评价。需要注意的是，为了提供一个全面的评价，通常还需要考虑苹果的营养和健康益处等正面方面。

- 如果只需要数据简单的判断，则本次输出较为繁琐，有大量不需要的信息。
- GPT系列的模型都属于自回归类的语言模型，所谓自回归模型就是根据当前输入预测下一个词，然后将预测结果和输入拼接再当做模型的输入再预测下一个词，这样循环往复。
- GPT-3 的研究者发现，大规模的训练数据会产生一种有趣的新兴行为，称为 In-Context Learning（又称上下文学习，语境学习，ICL），它并不需要调整模型参数，仅用几条下游任务的示例就可以取得极佳的结果。
- 预训练好的 GPT-3 模型在迁移到新任务上的时候并不需要重新训练，而只需要提供任务描述（这个任务描述是可选项）接着提供几个示例（任务查询和对应答案，以成对的形式组织），最后加上要模型回答的查询。将以上内容打包一起作为模型的输入，则模型就能正确输出最后一个查询对应的答案。

少样本提示（Few-Shot Prompting）

- 虽然大型语言模型展示了惊人的零样本能力，但在使用零样本设置时，它们在更复杂的任务上仍然表现不佳。
- 少样本提示可以作为一种技术，以启用上下文学习，在提示中提供演示以引导模型实现更好的性能。演示作为后续示例的条件，希望模型生成响应。
- Few可以任意选择。

```
Q: <问题>?  
A: <答案>  
Q: <问题>?  
A: <答案>  
Q: <问题>?  
A: <答案>  
Q: <问题>?  
A:
```

- One-shot few-shot

少样本提示示例

提示：

苹果中的某些物质可能引起食用者过敏，引发皮疹、呼吸困难等症状；同时苹果中的果糖和膳食纤维过多可能导致腹胀、腹泻等消化不良症状。

评价：负向

香蕉是一种对人体非常有益的水果。

评价：正向

榴莲香甜可口，营养价值非常高。

评价：

输出：

正向

目录

1. 人工智能业务流程介绍
2. 大模型业务流程介绍
- 3. 大模型使用与提示工程**
 - 如何使用大模型
 - 提示工程及基础方法
 - 高阶提示方法
 - 提示框架

思维链提示 (Chain-of-Thoughts Prompting)

- 思维链 (CoT) 提示通过引入中间推理步骤实现了复杂的推理能力，它逐步展开问题并在每个回答中保留之前问题的背景信息，链式思考可以使对话变得内容丰富和连贯。
- 思维链提示主要有两种类型：
 - Few-shot-CoT
 - Zero-shot-CoT
- 核心特点
 - 有序性：链式思考提示要求将问题分解为一系列有序的步骤，每个步骤都建立在前一个步骤的基础上，形成一条清晰的思考链条。
 - 关联性：每个思考步骤之间必须存在紧密的逻辑联系，以确保整个思考过程的连贯性和一致性。
 - 逐步推理：模型在每个步骤中只关注当前的问题和相关信息，通过逐步推理的方式逼近最终答案。

Few-shot-CoT

- 这种方式是给模型展示少量的示例，每一个示例都包括了手写的（或模型生成的）高品质的推理过程。

提示：

这组数中的奇数加起来是偶数：4、8、9、15、12、2、1。
A：将所有奇数相加（9、15、1）得到25。答案为False。
这组数中的奇数加起来是偶数：17、10、19、4、8、12、24。
A：将所有奇数相加（17、19）得到36。答案为True。
这组数中的奇数加起来是偶数：16、11、14、4、8、13、24。
A：将所有奇数相加（11、13）得到24。答案为True。
这组数中的奇数加起来是偶数：17、9、10、12、13、4、2。
A：将所有奇数相加（17、9、13）得到39。答案为False。
这组数中的奇数加起来是偶数：15、32、5、13、82、7、1。
A：

输出：

将所有奇数相加（15、5、13、7、1）得到41。答案为False。

Zero-shot-CoT

- Zero-shot-CoT方法在语言模型的每个回答前添加提示“Let’s think step by step”（让模型逐步思考的提示），以引导模型进行多步思考。

Zero-shot

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?

A: The answer (arabic numerals) is

(Output) 8 ✗

Zero-shot-CoT

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?

A: **Let's think step by step.**

(Output) *There are 16 balls in total. Half of the balls are golf balls. That means that there are 8 golf balls. Half of the golf balls are blue. That means that there are 4 blue golf balls. ✓*

Zero-shot-CoT优势

- 通用性：Zero-shot-CoT使用单一模板，无需为每个任务专门设计提示，可跨多种推理任务工作，而few-shot提示需要为每个任务设计专门的示例。
- 无需人工设计示例：Zero-shot-CoT不需要人工设计多步推理的示例，减少了提示工程的工作量，而few-shot提示需要精心设计每个任务的示例。
- 更强的零样本推理基准：Zero-shot-CoT作为更强的零样本推理基准，为困难的多步推理任务提供了更好的性能，而标准的零样本提示性能较差。
- 更好的可扩展性：随着模型规模的扩大，Zero-shot-CoT的性能提升更加明显，展现出更好的可扩展性，而few-shot提示对模型规模不太敏感。
- 减少偏差：Zero-shot-CoT减少了手工设计示例引入的偏差，使对语言模型偏差的研究更加公正。

目录

1. 人工智能业务流程介绍
2. 大模型业务流程介绍
- 3. 大模型使用与提示工程**
 - 如何使用大模型
 - 提示工程及基础方法
 - 高阶提示方法
 - 提示框架

APE框架

- Action 行动：定义要完成的工作或活动。
- Purpose 目的：讨论意图或目标。
- Expectation 期望：说明期望的结果。
- 示例：
 - 行动：你能为我们的环保运动鞋新产品制定一个内容营销策略吗？
 - 目的：我们的目标是在我们的目标受众（对可持续发展充满热情的健身爱好者）中产生轰动效应，并提高他们的意识。
 - 期望：该战略致力于推动至少25%的预购量增长。

CARE框架

- Context 上下文：提供上下文信息或情况。
- Action 行动：描述您想要做什么。
- Result 结果：描述期望的结果。
- Example 示例：举一个例子来说明你的观点。

CARE示例

- 上下文：我们的组织最近推出了一个新的服装系列。
- 行动：你能协助我们创建一个有针对性的广告活动，强调我们的环保承诺吗？
- 结果：我们期望的结果是提高产品的知名度和销量，特别是在有生态意识的消费者中。
- 示例：类似的成功案例中一个很好的例子是Patagonia的“不要买这件夹克”活动，这有效地突出了他们对可持续发展的承诺，同时提升了他们的品牌形象。

TRACE框架

- Task 任务：定义具体任务。
- Request 请求：描述您的请求。
- Action 行动：说明您需要采取的行动。
- Context 语境：提供背景或情况。
- Example 示例：举一个例子来说明你的观点。

TRACE示例

- 任务：你的任务是创建一个有吸引力的电子邮件营销活动。
- 请求：Can you assist in the development of compelling , subject lines and body copy?
- 行动：我们需要你起草几个这样的例子。
- 语境：这就是我们即将到来的年终清仓大甩卖，目标是我们现有的客户群。
- 示例：一个成功的现实世界的电子邮件活动是某医药公司的 “啊，你的处方过期了” 的活动。利用自动电子邮件提醒客户其处方即将过期，并敦促他们获得新处方，有效地提高了客户参与度。

TAG框架

- Task 任务：定义具体任务。
- Action 行动：描述需要做什么。
- Goal 目标：解释最终目标。
- 示例
 - 任务：我们的任务是扩大我们公司在 Instagram 上与受众的互动。
 - 行动：这就需要推出一个用户生成的内容活动，客户穿着我们的运动产品，使用一个独特的标签，分享他们的个人健身之旅。
 - 目标：最终目标是在下一季度，我们的 Instagram 用户生成内容提交量提高50%。

Prompt撰写提示

- 没有最好的提示词，只有适合自己需求的提示词
 - 确定提示信息清晰，有条理；
 - 如果第一次效果不好，重新定义想法和提示词；
 - 分析不好的原因是什么，调整输入；
 - 重复以上过程。

思考题

1. （多选题）思维链（CoT）提示通过引入中间推理步骤实现了复杂的推理能力，其中Zero-shot-CoT与Few-shot-CoT相比有哪些优点？
 - A. 多数情况下效果优于Few-shot-CoT
 - B. 无需人工设计示例
 - C. 更好的可扩展性
 - D. 通用性强

- BCD

本章总结

- 本章介绍了AI业务和大模型构建的全流程，并详细介绍了如何利用提示工程高效的使用大模型，得到更准确的答案。

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。
Bring digital to every person, home, and
organization for a fully connected,
intelligent world.

Copyright © Huawei Technologies Co., Ltd. All rights reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.



华为智算方案和产品介绍



前言

- 大模型发展的如火如荼，它的参数量和所需训练数据巨大，如何进行训练呢？
本章从算力、网络、存储、基础建设四个方面进行介绍，看它是如何解决大模型训练这个难题的。

目标


- 学完本课程后，您将能够：
 - 了解大模型对算力的需求及华为计算产品介绍
 - 了解大模型对网络的需求及华为网络产品介绍
 - 了解大模型对存储的需求及华为存储产品介绍
 - 了解绿色数据中心的概念

目录

1. **算力方案和昇腾计算产品介绍**
2. 网络方案和产品介绍
3. 存储方案和产品介绍
4. 华为天成解决方案介绍
5. 绿色数据中心概念


算力已成为新生产力驱动数字经济发展

人均算力决定了数字经济的发展水平，算力基础设施将成为新基建的核心



- 一两页做一个背景的介绍, 现在大家都讲这个算力经济, 然后的话也包括国家层面的话, 也出了一些包括像东数西算这样的一些新基建的这样的一些比较大的政策, 我问大家一个问题, 除了东数西算之外, 还有没有一些就是国家层面上都用东西南北来定义的一些这种国家层面的战略? 东数西存、南水北调。西电东送。所以想想通过这个想说明, 其实这是一个国家层面上一个比较大的政策, 然后那大家知不知道就是国家在东数西算这个方面, 目前规划了几大枢纽。八大枢纽10个基地。
- 数据来源: 《泛在算力: 智能社会的基石》
- 数据来源: 《智能世界 2030》

AI大模型对算力需求激增，远超单芯片算力增长规模



• 挑战1：样本量大，单卡训练时间太长。

• 例：GPT-3训练完成需要10000 PFLOP/s day总算力，单卡GPU需要几十年。


• 挑战2：模型大，参数多，单卡显存放不下。

• 例：GPT-3需要2.8 TB峰值显存，相当于35张A100 GPU，GPT-4需要16 TB峰值显存，相当于200张A100 GPU。

单机多卡


- 训练的原理

- 指定主机节点；
- 主机节点划分数据，一个batch数据平均分到每个机器上；
- 模型从主机拷贝到各个机器；
- 每个机器进行前向传播；
- 每个机器计算loss损失；
- 主机收集所有loss结果，进行参数更新；
- 将更新后参数模型拷贝给各个机器。



Parameter Server架构

- Parameter Server架构（PS架构）是深度学习最常采用的分布式训练架构。
- 在PS架构中，集群中的节点被分为两类：parameter server和worker。worker就是指下面的client，负责计算。server是负责统一所有的client它们的参数，server间是联通的。在每个迭代过程，worker从parameter server中获得参数，然后将计算的梯度返回给parameter server，parameter server聚合从worker传回的梯度，然后更新参数，并将新的参数广播给worker。




- 参数服务器（Parameter Server，PS）架构的分布式训练系统中有两种服务器角色：训练服务器
- 和参数服务器。参数服务器需要提供充足内存资源和通信资源，训练服务器需要提供大量的计算
- 资源。上图展示了一个具有参数服务器的分布式训练集群的示意图。该集群包括两个训练服务
- 器和两个参数服务器。假设有一个可分为两个参数分区的模型，每个分区由一个参数服务器负责
- 进行参数同步。在训练过程中，每个训练服务器都拥有完整的模型，并根据将分配到此服务器的
- 训练数据集切片（Dataset Shard）进行计算，将得的梯度推送到相应的参数服务器。参数服务器会
- 等待两个训练服务器都完成梯度推送，然后开始计算平均梯度，并更新参数。之后，参数服务器
- 会通知训练服务器拉取最新的参数，并开始下一轮训练迭代。
- 参数服务器架构分布式训练过程可以细分为同步训练和异步训练两种模式：
- 同步训练：训练服务器在完成一个小批次的训练后，将梯度推送给参数服务器。参数服务器

- 在接收到所有训练服务器的梯度后，进行梯度聚合和参数更新。
- 异步训练：训练服务器在完成一个小批次的训练后，将梯度推送给参数服务器。但是参数服
- 务器不再等待接收所有训练服务器的梯度，而是直接基于已接收到的梯度进行参数更新。
- 同步训练的过程中，因为参数服务器会等待所有训练服务器完成当前小批次的训练，有诸多的等
- 待或同步机制，导致整个训练速度较慢。异步训练去除了训练过程中的等待机制，训练服务器可
- 以独立地进行参数更新，训练速度得到了极大的提升。但是因为引入了异步更新的机制会导致训
- 练效果有所波动。选择适合的训练模式应根据具体情况和需求来进行权衡。

AI集群


- 分布式集群是由多个计算机节点组成的计算系统，节点与节点之间通过网络进行通信和协作，因其具有高性能和可扩展性等优点，因此被广泛应用于大规模计算和存储等场景，AI分布式计算则是利用分布式集群来完成深度学习网络的训练和推理等任务。




华为计算产品介绍

- 基于昇腾AI处理器，华为打造了Atlas系列硬件，涵盖以下场景：
 - 开发者套件
 - Atlas 200I DK A2
 - 加速模块
 - Atlas 200I A2
 - 加速卡
 - Atlas 300I Pro推理卡等
 - 智能小站
 - Atlas 500 A2
 - 服务器
 - Atlas 800T A2训练服务器等
 - 集群
 - Atlas 900 A2 PoD等

Atlas 800T A2服务器整体介绍




关键特性	规格描述
形态	4U机架服务器 (175mm × 447mm × 790mm)
CPU	4 * 鲲鹏920
NPU	8 * 昇腾训练芯片
内部拓扑	NPU HCCS全互联
网络接口	NPU直出8 * 200G RoCE



Atlas 800T A2 NPU模组介绍

- 大模型在训练时对节点间互联提出了高要求，传统的PCIE难以满足，如何高效的进行节点间互联和卡间互联成为了硬件厂商想要解决的问题。
- Atlas 800T A2服务器中并没有使用PCIE接口的训练卡，而是设计了专用的NPU载板，通过高速信号线缆连接NPU模组与载板，实现模型的高效并行训练。



1	UBC连接器 (J1) ^a	2	UBC连接器 (J2) ^b
3	UBC连接器 (J3) ^b	-	-
a: 通过高速信号线缆连接到NPU载板的高速信号接口。 b: 通过高速信号线缆连接到CPU主板Slimline连接器上。			


- <https://e.huawei.com/cn/material/enterprise/8b1341dda54e434284231f905e37c629>

目录

1. 算力方案和昇腾计算产品介绍
- 2. 网络方案和产品介绍**
3. 存储方案和产品介绍
4. 华为天成解决方案介绍
5. 绿色数据中心概念

AI集群网络的需求和挑战

大带宽




2*25G -> 8*200/400G

无收敛



逐级收敛 -> 无收敛


易扩展



2层 vs 3层
全盒 vs 框盒

大集群 ≠ 高算力


零丢包



可少量丢包


0丢包

高吞吐




大量随机流 -> 少量大流、同步突发

智运维



可视化, 自动化, 智能化

大模型训练对网络的最核心需求-缩短通信时间，降低通信开销



大模型训练系统通信优化路径


- 提升有效带宽;
- 减少主机内数据拷贝以及协议栈处理时延;
- 减少通信数据量 (端侧AI框架优化);
- 降低交换机转发时延, 不能带来明显效果提升。

0丢包：RDMA网络无损是AI大模型训练的基础要求

- 丢包对网络性能影响巨大：千分之一的丢包率会导致网络性能下降50%。
- RDMA(Remote Direct Memory Access)，全称远端内存直接访问技术，可以在极少占用CPU的情况下，把数据从一台服务器传输到另一台服务器，或从存储到服务器。
- RDMA是一种高带宽、低延迟、低CPU消耗的网络互联技术，克服了传统TCP/IP网络的许多困难。
- RDMA技术有四种实现：InfiniBand、RoCEv1、RoCEv2和iWARP。其中，RoCEv1已被弃用，iWARP不常用。目前业界常用的网络解决方案是InfiniBand（协议封闭、生态固化）和RoCEv2。

- 传统的TCP/IP方式就像是人工收费一样，需要取卡，人工核实，手动缴费，找零钱等等才能完成汽车上下高速。在车辆很多的情况下就会出现排队的情况，很浪费时间。
- 而RDMA则像是ETC，跳过人工取卡，收费等步骤，直接刷卡，极速通过。既节省了时间，又节省了人力。
- RDMA相比TCP/IP，既降低了对计算资源的占用，又提升了数据的传输速率。


华为智能无损技术架构全景




- iMaster NCE-FabricInsight基于Telemetry实现流量采集与分析，iMaster NCE-Fabric基于NETCONF/YANG将配置下发到网络设备。
- 流控技术：
 - PFC：主要解决拥塞导致的丢帧问题。
 - PFC storm control：PFC风暴控制，主要解决由PFC风暴引起网络断流的问题，也称为PFC死锁检测。
 - PFC deadlock free：PFC死锁预防，通过识别环形缓存依赖并破除其产生的必要条件，从而解决PFC死锁的问题，提高网络可靠性。
- 拥塞控制：
 - Static ECN：Explicit Congestion Notification，即显式拥塞通知，是一种端到端的网络拥塞通知机制，它允许网络在发生拥塞时不丢弃报文，在RFC 3168（2001）中定义。
 - AI ECN：通过iLossless智能无损算法动态调节ECN门限，以获得最大带宽与最小时延。
 - NPCC：Network-based Proactive Congestion Control，主动拥塞控制，在网络设备上基于本设备的拥塞状态主动控制每条流的发送速率，主要用于长距无损网络。

RoCE：PFC、ECN实现网络无损

- RoCE协议是一种能在以太网上进行RDMA（远程内存直接访问）的集群网络通信协议。它将收/发包的工作卸载(offload)到了网卡上，不需要像TCP/IP协议一样使系统进入内核态，减少了拷贝、封包解包等等的开销。这样大大降低了以太网通信的延迟，减少了通讯时对CPU资源的占用，缓解了网络中的拥塞，让带宽得到更有效的利用。



- 每优先级队列进行独立流控
- 当收端缓存超阈值时 (Xoff)，向发端发送Priority Pause帧。
- 发端收到Priority Pause帧时，停止向收端发送流量。



- ECN标记策略：超过低水线 (Kmin) 按比例标记，超过高水线 (Kmax) 全部标记。
- 降速过程：按比例降速；升速过程：先快速升速，再线性递增。


- <https://www.51cto.com/article/722516.html>
- <https://www.sdnlab.com/25923.html>
- PFC：基于优先级的流量控制。PFC为多种类型的流量提供基于每跳优先级的流量控制。设备在转发报文时，通过在优先级映射表中查找报文的优先级，将报文分配到队列中进行调度和转发。当802.1p优先级报文的发送速率超过接收速率且接收端的数据缓存空间不足时，接收端向发送端发送PFC暂停帧。当发送端收到 PFC 暂停帧时，发送端停止发送具有指定 802.1p 优先级的报文，直到发送端收到 PFC XON 帧或老化定时器超时。配置PFC时，特定类型报文的拥塞不影响其他类型报文的正常转发，
- ECN：显式拥塞通知。ECN 定义了基于 IP 层和传输层的流量控制和端到端拥塞通知机制。当设备拥塞时，ECN 会在数据包的 IP 头中标记 ECN 字段。接收端发送拥塞通知包（CNP）通知发送端放慢发送速度。ECN 实现端到端的拥塞管理，减少拥塞的扩散和加剧。

华为智能无损网络，解决传统以太网性能瓶颈

- 华为智能无损网络，通过AI Ready的硬件架构及独创的iLossless算法，保证网络0丢包的基础上实现最高吞吐、最低时延，加速计算和存储的效率，为数据中心构建基于以太的统一架构的超融合网络。本质是为网络增加智能面，实现网络自优化。


传统以太网，基于传统交换机：静态配置队列门限。

问题：门限无法根据流量状态变化，要么丢包，要么降速。




智能无损以太网，基于AI交换机：**内置AI算法。**

优势：动态调整门限，确保**100%吞吐下0丢包**。



智算集群网络设备选型：支持AI多场景融合组网，100%释放算力


面向多元算力的数据中心交换机



智算中心网络四个平面介绍

- 参数面：用于智能集群分布式训练时参数交换，要求网络具备高吞吐低时延的能力。部署高带宽的智能无损网络，收敛比1:1。
- 样本面：主要用于访问存储区的高速大带宽互联的存储系统，推荐部署为RoCE无损网路，收敛比1:1。
- 业务面：用于系统业务调度和管理。
- 带外管理面：计算、存储、网络的带外管理，部署运维平台等。

大模型网络解决方案



- AI计算集群区的物理网络区分平面进行设计：
 - 参数面网络：采用双层的Leaf-Spine组网，通过大带宽接口接入到Leaf交换机，实现多机分布式训练时的参数交换。
 - 样本面网络：用于AI集群频繁访问海量样本场景，用于访问存储区的高速大带宽互联的存储系统。
 - 业务/带内管理面网络：通常部署为TCP/IP有损网络。
 - 带外管理面网络：每个AI服务器或存储服务器提供1个GE网口接入到GE交换机，接入到管理区网络。

万卡集群项目网络设备选型示例


计算参数面



业务面




计算样本面与存储前后端



参数面网络支持超宽400G，匹配大模型组网需求


组网方案一：2级盒盒CLOS组网



1:1收敛组网，通用性和扩展性较好

规模：千卡集群
适用于中小规模AI集群


组网方案二：2级框盒CLOS组网



1:1收敛组网，通用性和扩展性较好

规模：万卡集群
适用于大规模AI集群

组网方案三：2级框框CLOS组网



1:1收敛组网，通用性和扩展性较好


规模：数万卡集群
适用于超大规模AI集群

- **CLOS组网** 是一种多级交换网络设计，旨在降低大型交换网络的成本。它通过使用多个较小的交换单元，按照特定的连接方式组合起来，形成无阻塞的网络结构。这种设计可以减少交叉点数量，从而降低构建大型无阻塞交换结构的成本。CLOS网络的优点包括清晰的网络结构和较低的传输时延。然而，为了增加容量和降低阻塞，可能需要增加交换单元的数量，这可能导致技术成本和实现复杂度的增加。因此，CLOS网络更适合于大型网络设计，通过简化网络层次和使用较小的交换结构，可以大大减少构建无阻塞交换结构所需的交叉点数量

目录

1. 算力方案和昇腾计算产品介绍
2. 网络方案和产品介绍
- 3. 存储方案和产品介绍**
4. 华为天成解决方案介绍
5. 绿色数据中心概念

AI大模型时代的数据存储新范式



块存储

- 数据块存储是将获取任何数据（结构化数据为主，如文件或数据库条目）分成大小相等的数据块，然后，数据块存储系统以针对快速访问和检索而优化的方式将数据块存储在底层物理存储上。
- 优势：
 - 块存储查找速度快：块存储使用唯一的标识符，而不是使用元数据或文件层次结构来搜索数据，意味着可以极快地检索到数据。
 - 可以通过多种途径找到数据：由于唯一的标识符是检索所需的全部内容，因此块存储允许以多种方式找到数据。
- 缺点：
 - 块存储较为昂贵：部分原因是它经过优化，具有快速性能，因此块存储比对象存储的成本更高。
 - 块存储的元数据是有限的：块存储只包括基本文件属性作为元数据。

- <https://www.cloudflare-cn.com/learning/cloud/what-is-block-storage/>
- <https://www.redhat.com/zh/topics/data-storage/file-block-object-storage%E6%A6%82%E8%BF%B0>

文件存储

- 文件存储也称为文件级存储或基于文件的存储，是一种分层存储方法，用于在计算机硬盘驱动器或网络连接存储（NAS）设备上组织和存储数据。它将数据存储的文件中，将文件组织到文件夹中，并将文件夹组织到目录和子目录层次结构中。要找到某个文件，您或计算机系统需要知道路径 — 从目录到子目录到文件夹最后找到文件。
- 文件存储的优点
 - 简单、文件共享、经济实惠、数据保护。
- 分层文件存储可以轻松组织大量结构化数据。但是，随着文件数量的增加，文件检索过程可能变得繁琐而耗时。扩容需要添加更多的硬件设备，或者不断地使用更高容量的设备来替换现有设备，这两种方式的成本都很高。

- <https://www.ibm.com/cn-zh/topics/file-storage>

对象存储

- 对象存储，也称为基于对象的存储，是一种扁平结构，其中的文件（以非结构化数据为主 - 包括日志、视频和照片内容、传感器数据和网页等等）被拆分成多个部分并散布在多个硬件间。在对象存储中，数据会被分解为称为"对象"的离散单元，并保存在单个存储库中，而不是作为文件夹中的文件或服务器上的块来保存。
- 对象存储卷会作为模块化单元来工作：每个卷都是一个自包含式存储库，均含有数据、允许在分布式系统上找到对象的唯一标识符以及描述数据的元数据。
- 对象存储往往具有以下特性：
 - 可扩展、可搜索、不复杂、有弹性、成本低。
- 对象存储的性能可能比较慢，特别是数据检索。

<https://www.cloudflare-cn.com/learning/cloud/what-is-object-storage/>

<https://aws.amazon.com/cn/what-is/object-storage/>

<https://www.redhat.com/zh/topics/data-storage/file-block-object-storage>

向量存储

- 向量数据是指用向量来表示的数据，其中每个向包含有序的数字或数值特征，例如机器学习中的特征向量，每个特征在向量中的位置表示该特征的要性、大小或值。向量数据在许多领域中被广泛使用，如自然语言处理、计算机视觉、声音处理和物理学等领域。
- 向量数据库是以数学形式存储的数据集合，向量数据库使机器学习模型更容易记住以前的输入，从而使机器学习能够用于支持搜索、推荐和生成文本等使用案例。可以根据相似性指标而不是精确匹配来识别数据，从而使计算机模型能够理解数据的上下文。



- <https://www.transwarp.cn/bd/222>

大模型开发应用面临四大挑战，高性能AI存储成为必选项



高性能专业存储诉求

归集&预处理阶段

预处理时长占80%端到端人力*时间，缩短处理时长是主要诉求

- 数据快速拷贝导入集群
- 数据不用来回搬迁，全局可视

训练阶段

占90%算力，提高GPU/NPU利用率，降低空载是主要诉求

- 训练数据集加载无等待
- CheckPoint保存/恢复高频、快速

推理阶段

应用一直持续，算力需求/数据量小于训练阶段，效率是关键


- 向量知识库检索加速
- 隐私保护

- **全局统一命名空间**：一套存储系统同时具备高性能层和大容量层，具备数据全生命周期管理的能力
- **原生无损多协议互通**：一套存储可以承载AI全流程业务，NAS、大数据、对象、并行客户端等协议，性能不下降，数据0拷贝
- **PB/EB级扩展**：具备数千节点的横向扩展能力，支撑亿级文件列表获取能力
- **混合负载性能均衡**：一套系统、一套参数具备高性能动态混合负载的承载能力


存储数据高可靠

- 大模型对存储的可靠性要求很高，因为模型数据通常非常庞大，且对训练任务的连续性和最终模型的准确性至关重要。以下是存储可靠性的一些关键要求：
 - **高可用性**：存储系统需要具备高可用性，确保数据随时可访问。这通常通过冗余的存储架构实现，如使用RAID（独立磁盘冗余阵列）技术或分布式存储系统。
 - **数据一致性**：在大模型训练中，数据一致性非常重要。存储系统需要确保所有副本的数据是一致的，避免因数据不一致导致模型训练出现错误。
 - **故障容忍性**：存储系统应该能够容忍一定程度的硬件故障而不丢失数据。这通常通过数据备份、冗余存储和网络隔离等技术实现。
 - **快速恢复能力**：在发生故障时，存储系统能够快速恢复，最小化对训练任务的影响。这包括快速的数据重建和故障转移能力。
 - **可扩展性**：随着模型规模的增加，存储系统需要能够轻松扩展，以容纳更多的数据而不影响性能。
 - **高性能**：大模型训练通常需要快速读写大量数据。因此，存储系统需要提供高吞吐量和低延迟，以满足训练任务的需求。
 - **数据完整性校验**：存储系统应该具备数据完整性校验机制，如使用校验和或哈希函数来验证数据的正确性。
 - **安全性和隐私保护**：存储系统需要具备数据加密和安全访问控制机制，以保护模型数据不被未经授权访问或泄露。

存储数据安全



面向AI大模型场景的华为分布式AI存储解决方案




34 Copyright © Huawei Technologies Co., Ltd. All rights reserved.



1. 为云上大模型提供高性能存储平台
 - 存储对接云服务，实现统一服务发放
 - 以专业存储能力使用云上AI业务
2. 为线下大算力平台提供大模型服务
 - 提供高效率、最完善的大模型运行环境
 - 提供全栈资源管理，简化管理和运维
3. 为大模型提供全流程存储湖平台
 - 近计算加速，多协议互通使能全流程
 - 全生命周期管理，安全、可靠、节能

OceanStor Pacific分布式存储



35 Copyright © Huawei Technologies Co., Ltd. All rights reserved.




- 大模型训练场景，全流程是需要专业存储参与的，当前大部分客户现有的存储设备是无法满足要求的，包括多协议数据的统一接入（文本、突破、音频和视频；以及来自不同团队不同来源的数据统一归集）、海量小文件的快速读取到调度平台（TB级别的数据加载要好几个小时）、训练过程中的checkpoint以及重新拉起对带宽的要求（一个数GB的Checkpoint拉起来需要40分钟以上），包括在应用阶段，客户侧的私域数据如何和原生的L0层模型互通等问题；
- 原始数据上，NLP模型类不大，但CV类模型规模大，如海康大华、云天励飞、商汤等，对存储的需求是很高的。另科学计算类模型，数据规模也比较大。
- OceanStor Pacific分布式存储多协议互通技术实现全流程协同，数据零拷贝；动态混合负载高性能加速AI全流程，降低整体TCO；性能层&容量层配合，同兼顾高性能和大容量诉求，实现高性价比。

目录


1. 算力方案和昇腾计算产品介绍
2. 网络方案和产品介绍
3. 存储方案和产品介绍
- 4. 华为天成解决方案介绍**
5. 绿色数据中心概念

天成解决方案架构图

- 天成集群解决方案是面向新型数据中心场景的综合性解决方案，以有效算力为核心，从可持续运营角度出发，以云为底座自上而下构筑全栈解决方案竞争力，率先实现解决方案产品化，实现从L0到L4的完整数据中心级方案交付。



天成三总线介绍



- <https://support.huawei.com/enterprise/zh/doc/EDOC1100337843?idPath=23710424%7C251366513%7C22892968%7C252309113%7C254184911>

Atlas 900 A2 PoD

Atlas 900 A2 PoD集群基础单元

Atlas 900 A2 PoD 集群基础单元具有高密度、高能效、高可靠、易拓展、一体化交付、极简运维、低TCO等特点。支持大规模、高性能AI训练业务，可应用于人工智能计算中心、运营商、云计算等重算力场景。



Atlas 900 A2 PoD

部件

显示全部

机柜

侧梁

补位框

液冷门

造型门

电源框

电源模块

计算节点

RM211管理模块

电源管理转接板

交换节点

Busbar

Cable背板

Manifold

更多资源

Atlas 900 A2 PoDc

Atlas 900 A2 PoDc集群基础单元

Atlas 900 A2 PoDc 集群基础单元具有高密度，高性能，高能效，高可靠，易拓展，一体化交付，极简运维，低TCO等特点。支持大规模，高性能AI训练业务，可应用于人工智能计算中心（简称为AICC）、运营商、云计算、金融等重算力场景。




Atlas 900 A2 PoDc	
部件	—
显示全部	+
机柜	+
机柜门	+
机柜管理模块	+
电源机座	+
电源模块	+
计算节点	+
ECU	+
电源管理转接板	+
Busbar	+
Manifold	+
交换机	+
液冷门	+
理线框	+
更多资源	—
成功案例	—

目录

1. 算力方案和昇腾计算产品介绍
2. 网络方案和产品介绍
3. 存储方案和产品介绍
4. 华为天成解决方案介绍
- 5. 绿色数据中心概念**

数据中心

- 随着产业数字化转型的持续发展，数据成为关键生产要素，而数据中心肩负着数据的计算、存储和转发的重任，是新基建中最关键的数字基础设施。现代数据中心主要包括以下核心部件：
 - 计算系统，包括用于部署业务的通用计算模块和提供超强算力的高性能计算模块等。
 - 存储系统，包括海量存储模块、数据管理引擎、存储专用网络等。
 - 能源系统，包括供电模块、温控模块、IT管理模块等。
 - 数据中心网络，负责联接数据中心内部通用计算、高性能计算和存储模块，它们之间的所有数据交互都要通过数据中心网络实现。



- <https://info.support.huawei.com/info-finder/encyclopedia/zh/%E6%95%B0%E6%8D%AE%E4%B8%AD%E5%BF%83%E4%BA%92%E8%81%94.html>

绿色数据中心

- 绿色数据中心(Green Data Center)是指数据机房中的IT系统、制冷、照明和电气等能取得最大化的能源效率和最小化的环境影响。
- 绿色数据中心是数据中心发展的必然，可以从建筑节能、运营管理、能源效率等方面来衡量一个数据中心是否为“绿色”。
- 为了衡量数据中心的效率，可以主要参考以下两个指标：
 - PUE (Power Usage Effectiveness): PUE是由The Green Grid公司开发的，用于衡量数据中心的功耗，并提供数据中心使用的电量与输送给设备的电量之比。因此，比率为1.0表示可持续的数据中心——所有的电力都交付给IT设备。
 - 碳使用效率(CUE): 同样由绿色网格开发，它着眼于中心的总二氧化碳排放量的比例，并将其除以IT设备的能耗。绿色数据中心将呈现尽可能低的比值。

数据中心能效定量评估指标 - PUE

- 2006年，Christian Belady提出数据中心PUE的概念，目前PUE值已经成为国际上比较通行的数据中心能源使用效率的衡量指标。
- 2007年，美国绿色网格组织TGG (The Green Grid)发展和完善，TGG在2月在文章


《Green Grid Metrics: Describing Data Center Power Efficiency》给出的PUE定义如下：

$$PUE = \frac{\text{总设施能耗 (Total Facility Energy)}}{\text{IT设施能耗 (IT Facility Energy)}}$$

- 2009年10月29日，Green Grid发布了PUE白皮书2.1版本，也就是现在人们经常引用的PUE v2，它提供了一个更准确报告PUE的手段。PUE v2确立了不同类型的PUE测量方法，Green Grid将其分成了1、2、3三个级，分别对应于基础级、中级和高级。
- 2011年，数据中心效率工作组（Data Center Efficiency Task Force, DCETF）发布了篇论文，阐述了测量和报告PUE的推荐方法。DCETF增加了更基础的第4级，以PUE0到PUE3进行标识，级别越高越严格。

数据中心PUE指标要求

工信部/发改委PUE要求 1.15~1.3



- **工信部**：新建大型及以上数据中心PUE降低到**1.3以下**，严寒和寒冷地区力争降低到**1.25以下**；
- **发改委**（一体化大数据中心）：京津冀、粤港澳、长三角、成渝枢纽范围内**1.25**；内蒙、甘肃、宁夏、贵州枢纽范围内**1.2**；绿色节能示范项目**1.15**。

最大能源效率，最小环境影响，打造绿色数据中心



- 这部分为华为的建设数据中心的理念。使用节能超高效模块化UPS，优化供电和冗余结构，使UPS 主机工作在高效低耗区间内，效率达到97% 以上，电流谐波成分THDi≤5%。同时采用智能在线运行模式，效率高达99%，减少供电损耗。采用预制化电力模块，减少低压供电链路路径，增加主动运维措施，减少线损和接触异常带来的电损。机柜区域采用模块化智能小母线，更可靠、易维护、高效率、灵活扩容，减少电缆使用，在输送同样电力的情况下，降低损耗，同时减少电缆废弃后对环境的污染。动力设备采用电缆，线路尽可能走直线，少走弯路，以减少导线。

数据中心的分层理念



L1不仅仅要提供ICT设备安置的空间，还要提供ICT设备运行的物理条件，包括供电，供冷、运维管理和物理安全等。

- 除了“风火水电” L1层有八大子系统，比如防雷接地，消防，机柜，装饰等子系统。

数据中心L1是什么？

- 数据中心指的是为集中放置的电子信息系统提供运行环境的建筑场所，也可以是一栋建筑物的一部分。包括主机房、辅助区、支持区和行政管理区。
- 数据中心L1 (Layer 1) 指的是支持整个数据中心正常运行的基础设施系统，通常包括供配电系统、制冷系统、DCIM管理系统等。



- 数据中心概念来源：GB50174-2017数据中心设计规范。
- DCIM：Data center infrastructure management，数据中心基础设施管理（系统）。

供电系统（1）

- 高压变配电系统：主要是将市电（6 kV/10 kV/35 kV，3相）通过该变压器转换成（380 V/400 V，3相），供后级低压设备用电。
- 柴油发电机系统：主要是作为后备电源，一旦市电失电，迅速启动为后级低压设备提供备用电源，根据不同电压等级，分中压油机和低压油机。
- 自动转换开关系统：主要是自动完成市电与市电或者市电与柴油发电机之间的备用切换。



供电系统（2）

- 低压配电系统：主要作用是电能分配，将前级的电能按照要求、标准与规范分配给各种类型的用电设备，如UPS、空调、照明设备等。
- UPS系统：主要作用是电能净化、电能后备，为IT负载提供纯净、可靠的用电保护。
- UPS输出列头配电系统：主要作用是UPS输出电能分配，将电能按照要求与标准分配给各种类型的IT设备。
- 机架配电系统：主要作用是机架内的电能分配。
- 48V直流电源：为通信设备提供安全、可靠的电源保障。

- 此外，数据中心的供配电系统负责为空调系统、照明系统及其他系统提供电能的分配与输入，从而保证数据中心正常运营。

制冷系统（1）


- 随着社会发展及新技术的应用，数据中心耗能显著增加，功率密度也越来越大，制冷系统保障数据中心设备工作在一个适宜的环境中。



- 显热量大** 数据中心内IT设备以及动力设备，均会以传热、对流、辐射的方式向数据中心内散发热量，这些热量造成机房内温度的升高，属于显热。一个服务器机柜散热量在每小时几千瓦到几十千瓦，机房内显热比可高达 95%。
- 潜热量小** 不改变机房内的温度，而只改变机房内空气含湿量，这部分热量称为潜热。机房内没有散湿设备，潜热主要来自工作人员及室外空气。
- 风量大、焓差小** 机房内潜热量较少，很少需要除湿，空气经过空调机蒸发器时不需要降至露点温度以下，所以送风温差及焓差要求较小。
- 多种送回风方式** 数据中心机房的送风方式取决于房间内热量的来源和分布特点、机房层高、设备布局、线缆等因素，机房内的送风方式主要分为下部送风、上部送风、区域送风等。
- 静压箱送风** 机房内空调送回风通常利用高架地板下部或天花板上部的空间作为静压箱送回风，静压箱内形成的稳压层可使送风较均匀，应尽量提高静压箱高度。
- 对温湿度要求严格** 温度过高会造成服务器设备故障率升高、可靠性下降，甚至直接造成设备宕机。较高的相对湿度会使数据中心内的设备的短路、发生腐蚀现象和冷凝现象。较低的相对湿度将产生影响设备运行的静电。
- 洁净度要求高** 数据中心机房有严格的空气洁净度要求。灰尘在高湿环境中会加快设备的腐蚀，使设备寿命下降，在散热板上堆积也将增加热阻，降低换热效率。腐蚀性气体会快速破坏印刷电路板上的金属薄膜和导体，导致末端连接处电阻值增大。因此要求机房专用空调系统应采用高效的、合适的过滤装置，能按相关标准对流通空气进行除尘、过滤。

制冷系统（2）


- 根据不同数据中心规模和总容量，风冷型制冷系统和冷冻水型制冷系统是目前主流的两种方案。一般而言，超大型数据中心和大型数据中心多使用冷冻水系统为主，中小机房多以风冷为主。
- 三种制冷配置方式：机房级制冷、行级制冷和机柜级制冷。



- 机柜级制冷最为灵活、部署最快，并能支持最高功率密度，但需要额外费用开支。
- 行级制冷具备机柜级制冷的诸多优势，如灵活性、部署速度及密度优势，且成本较低。
- 房间级制冷能够通过重新配置穿孔地板来快速更改制冷分配模式。在低密度数据中心，所有机柜共享制冷冗余。此方式具有成本优势，且最为简单。
- 房间级制冷在设计中，对气流的关注常常有很大的不同。对于较小的机房，机柜有时随意摆放，对于气流没有特别的规划、遏制。而对于较大的复杂的数据中心，可能使用高架地板，送风到经过精心规划的热通道/冷通道，来起到引导气流并使其与机柜相适应的目的。对于 200 kW 以上的新建数据中心来说，房间级制冷应采用热通道气流遏制。
- 行级制冷在设计上，它们被认为是专用于某机柜行。与传统无气流遏制房间级制冷相比，其气流路径较短，且专用度更加明确。此外，气流的可预测性较高，能够充分利用空调的全部额定制冷容量，并可以实现更高功率密度。除制冷性能之外，行级制冷还有很多优点。更短的气流路径，减少了所需风机功率，从而提高了效率。对于 200 kW 以下的新建数据中心，应采用行级制冷，无需高架地板即可部署。
- 机柜级制冷在设计上，它们被认为是专用于某机柜。空调直接安装在 IT 机柜上或其内部。与房间级或行级制冷相比，机柜的气流路径更短，且专用度更准确，使得气流完全不受任何安装变动或机房约束的影响，所有额定容量都能得到充分利用。与行级制冷类似，机柜级制冷除支持极高功率密度外，还有其它独特的特性。更短的气流路径减少了所需风机功率，从而提高了效率。

常见的液冷方案 - 冷板式液冷

- 冷板式液冷属于间接液冷，冷却液不与服务器芯片直接接触，为目前业界应用主要方案。系统主要由冷却塔、CDU、一次侧 & 二次侧液冷管路、冷却介质、液冷机柜组成；其中液冷机柜内包含液冷板、设备内液冷管路、流体连接器、分液器等。



- 冷板式液冷应用方案：华为天成液冷机柜。
- 方案主要特点：
 - 改造成本低、兼容性强：冷板式液冷的改造成本相对较低，不需要对数据中心现有的机房及机柜进行大规模改造，其适用的硬盘、光模块等服务器部件与风冷方案一致，运维模式、机房承重与风冷场景也基本一致；
 - 散热效果好：冷却效果和节能性要远好于风冷，PUE可以达到1.2左右；
 - 可靠性高：液冷液体与设备不直接接触；
 - IT设备、冷却液、管路、供配电等不统一，服务器多与机柜深耦合；
 - 管路接头、密封件较多，漏液维护场景复杂。

思考题

1. （多选题）大模型训练对网络的需求有哪些？
 - A. 低丢包
 - B. 低时延
 - C. 大带宽
 - D. 高可靠
2. 天成一总线的优势有哪些？
3. 为什么智算服务器的加速卡不使用PCIe通道？

- 1、BCD
- 2、存算网一体，免插光模块，易维护，
- 3、分布式计算对节点间互联带宽要求高，PCIe无法满足要求

本章总结

- 本章主要介绍了大模型对数据中心提出的诸多挑战，进而从计算、网络、存储三个方面给出了华为在AI智算领域的相关产品和方案。

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。
Bring digital to every person, home, and
organization for a fully connected,
intelligent world.

Copyright © Huawei Technologies Co., Ltd. All rights reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.



昇腾大模型解决方案概述



前言

- 本章主要讲述了华为昇腾大模型方案，相关软件和工具包括 CANN、MindFormers、SmartKit Computing等。

目标

- 学完本课程后，您将能够：
 - 了解昇腾AI基础软件；
 - 了解Atlas服务器相关的监控和运维软件；
 - 了解华为网络产品相关的监控和运维软件。


目录

1. 昇腾AI基础软件
2. 集群监控与运维软件

昇腾AI基础软件

昇腾AI全流程使能大模型创新落地

从大模型的开发训练到推理部署，昇腾AI全流程使能大模型创新落地



昇腾AI基础软件-CANN（1）

- AI训练中大部分运算为矩阵运算，因此现阶段的AI训练硬件（NPU、GPU、TPU等）都以高效进行矩阵运算为目标进行设计，而为了让开发者更好的使用自家的AI硬件，各个厂商都推出了自己的计算架构，提供高阶接口，减少开发者适配成本；
- 目前主流的有CANN（Compute Architecture for Neural Networks）、CUDA（Compute Unified Device Architecture）、ROCm（Radeon Open Compute platform）等。不同于其他的计算架构，CANN提供了从底层加速到上层应用开发的全栈能力，接下来会详细介绍。


昇腾AI基础软件-CANN（2）

• 异构计算架构CANN（Compute Architecture for Neural Networks）是华为针对AI场景推出的异构计算架构，向上支持多种AI框架，包括MindSpore、PyTorch、TensorFlow等，向下服务AI处理器与编程，发挥承上启下的关键作用，是提升昇腾AI处理器计算

效率的关键平台。

• 关键特性如下：

- 推理应用开发
- 模型训练
- 算子开发



昇腾AI基础软件-CANN (3)

- 昇腾计算语言 (Ascend Computing Language, 简称AscendCL) : AscendCL接口是昇腾计算开放编程框架, 是对底层昇腾计算服务接口的封装。它提供设备 (Device) 管理、上下文 (Context) 管理、流 (Stream) 管理、内存管理、模型加载与执行、算子加载与执行、媒体数据处理、图 (Graph) 管理等API库, 供用户开发人工智能应用;
- 昇腾计算服务层 (Ascend Computing Service Layer) : 主要提供昇腾算子库AOL (Ascend Operator Library) , 通过神经网络 (Neural Network, NN) 库、线性代数计算库 (Basic Linear Algebra Subprograms, BLAS) 等高性能算子加速计算; 昇腾调优引擎AOE (Ascend Optimization Engine) , 通过算子调优OPAT、子图调优SGAT、梯度调优GDAT、模型压缩AMCT提升模型端到端运行速度。同时提供AI框架适配器Framework Adaptor用于兼容TensorFlow、PyTorch等主流AI框架。

昇腾AI基础软件-CANN (4)

- 昇腾计算编译层 (Ascend Computing Compilation Layer) : 昇腾计算编译层通过图编译器 (Graph Compiler) 将用户输入中间表达 (Intermediate Representation, IR) 的计算图编译成昇腾硬件可执行模型; 同时借助张量加速引擎TBE (Tensor Boost Engine) 的自动调度机制, 高效编译算子;
- 昇腾计算执行层 (Ascend Computing Execution Layer) : 负责模型和算子的执行, 提供运行时库 (Runtime)、图执行器 (Graph Executor)、数字视觉预处理 (Digital Vision Pre-Processing, DVPP)、人工智能预处理 (Artificial Intelligence Pre-Processing, AIPP)、华为集合通信库 (Huawei Collective Communication Library, HCCL) 等功能单元;
- 昇腾计算基础层 (Ascend Computing Base Layer) : 主要为其上各层提供基础服务, 如共享虚拟内存 (Shared Virtual Memory, SVM)、设备虚拟化 (Virtual Machine, VM)、主机-设备通信 (Host Device Communication, HDC) 等。

AI开发框架

- 深度学习框架的出现降低了入门的门槛。我们不需要从复杂的神经网络和反向传播算法开始编代码，可以依据需要，使用已有的模型配置参数，而模型的参数自动训练得到。我们也可以在已有模型的基础上增加自定义网络层，或者是在顶端选择自己需要的分类器和优化算法。

[M]^s 昇思
MindSpore


PyTorch

飞桨

TensorFlow


昇腾AI基础软件-MindSpore

- MindSpore支持多种硬件，通过动静统一的编程体验和分布式并行支撑大模型训练。




昇腾AI基础软件-MindSpore层次架构

- MindSpore向用户提供了3个不同层次的API，支撑用户进行AI应用（算法/模型）开发，从高到低分别为High-Level Python API、Medium-Level Python API以及Low-Level Python API；
- 高阶API提供了更好的封装性，低阶API提供更好的灵活性，中阶API兼顾灵活及封装，满足不同领域和层次的开发者的需求。



昇腾AI基础软件-MindSpore全场景支持模式



- MindSpore作为全场景AI框架，所支持的有端（手机与IoT设备）、边（基站与路由设备）、云（服务器）场景的不同系列硬件，包括昇腾系列产品、英伟达NVIDIA系列产品、Arm系列的高通骁龙、华为麒麟的芯片等系列产品。
- 左边蓝色方框的是MindSpore主体框架，主要提供神经网络在训练、验证相关的基础API功能，另外还会默认提供自动微分、自动并行等功能。
- 蓝色方框往下是MindSpore Data模块，可以利用该模块进行数据预处理，包括数据采样、数据迭代、数据格式转换等不同的数据操作。在训练的过程会遇到很多调试调优的问题，因此有MindSpore Insight模块对loss曲线、算子执行情况、权重参数变量等调试调优相关的数据进行可视化，方便用户在训练过程中进行调试调优。
- AI安全最简单的方式就是从攻防的视角来看，例如，攻击者在训练阶段掺入恶意数据，影响AI模型推理能力，于是MindSpore推出了MindSpore Armour模块，为MindSpore提供AI安全机制。
- 蓝色方框往上的内容跟算法开发相关的用户更加贴近，包括存放大量的AI算法模型库ModelZoo，提供面向不同领域的开发工具套件MindSpore DevKit，另外还有高阶拓展库MindSpore Extend，这里面值得一提的就是MindSpore Extend中的科学计算套件MindSciences，MindSpore首次探索将科学计算与深度学习结合，将数值计算与深度学习相结合，通过深度学习来支持电磁仿真、药物分子仿真等等。
- 神经网络模型训练完后，可以导出模型或者加载存放在MindSpore Hub中已经训练好的模型。接着有MindIR提供端云统一的IR格式，通过统一IR定义了网络的逻辑结构和算子的属性，将MindIR格式的模型文件与硬件平台解耦，实现一次训练多次部署。因

此如图所示，通过IR把模型导出到不同的模块执行推理。

昇腾AI基础软件-Mind X

- Mind X包括多个组件，提供了集群调度、边缘推理、应用快速开发等功能，具体组件介绍如下：
 - MindX DL：MindX DL（昇腾深度学习组件）是支持 Atlas训练卡、推理卡的深度学习组件，提供昇腾 AI 处理器集群调度、昇腾 AI 处理器性能测试、模型保护等基础功能，快速使能合作伙伴进行深度学习平台开发；
 - MindX Edge：MindX Edge（昇腾智能边缘组件）提供边缘 AI 业务容器的全生命周期管理能力，同时提供严格的安全可信保障，为客户提供边云协同的边缘计算解决方案，使能客户快速构建边缘 AI 业务；
 - MindX SDK：使用华为提供的SDK和应用案例快速开发并部署人工智能应用；
 - ModelZoo：提供了丰富的各领域SOTA模型，一键下载，同时还提供了全流程开发工具，支持使用ModelShow直观对比昇腾NPU与GPU模型效果。

大模型开发套件-MindFormers

- Mindformers套件基于MindSpore内置的并行技术和组件化设计，目标是构建一个大模型训练、微调、评估、推理、部署的全流程开发套件，提供业内主流的Transformer类预训练模型和SOTA下游任务应用，涵盖丰富的并行特性。特点如下：
 - 一行代码实现从单卡到大规模集群训练的无缝切换；
 - 提供灵活易用的个性化并行配置；
 - 能够自动进行拓扑感知，高效地融合数据并行和模型并行策略；
 - 一键启动任意任务的单卡/多卡训练、微调、评估、推理流程；
 - 支持用户进行组件化配置任意模块，如优化器、学习策略、网络组装等；
 - 提供Trainer、pipeline、AutoClass等高阶易用性接口；
 - 提供预置SOTA权重自动下载及加载功能；
 - 支持人工智能计算中心无缝迁移部署。

大模型开发套件-ModelLink

- ModelLink旨在为华为昇腾芯片上的大语言模型提供端到端的解决方案, 包含模型, 算法, 以及下游任务。功能如下:
 - 制作预训练数据集/制作指令微调数据集;
 - 预训练/全参微调/低参微调;
 - 推理(人机对话);
 - 评估基线数据集(Benchmark);
 - 使用加速特性 (加速算法+融合算子) 。

大模型开发加速库-AscendSpeed

- AscendSpeed 是针对华为昇腾设备的大模型加速库，使能客户大模型业务快速迁移至昇腾设备，并且支持昇腾专有算法，确保开箱可用。在并行计算、模型切分、集合通信等方面做了优化，对Megatron-LM的基本功能进行了适配，适配特性如下：
 - 张量并行；
 - 流水线并行；
 - 序列并行；
 - 重计算；
 - 分布式优化器；
 - 异步分布式数据并行。

大模型开发全流程工具链-MindStudio

- MindStudio是华为面向昇腾AI开发者提供的一站式开发环境和工具集，致力于提供端到端的昇腾AI应用开发解决方案；
- 按照开发场景分类，MindStudio可以分为右侧三个工具链：

训练、推理、算子开发一站式

算子开发：使能高效开发

提供更为简单的计算和内存抽象、自动流水同步、更简便的调试手段，降低开发者编码成本



算子实现
AI CPU算子
TBE算子



算子仿真
UT测试
Advisor专家系统



算子验证
ST测试
Profiling性能调优



算子部署
算子编译、部署
整网测试

训练开发：开发更简单

提供友好的编程开发体系及端到端的训练工具链，支撑一站式高效开发



模型深度性能调优
Profiling性能调优
Advisor专家系统



模型自动性能调优
AOE梯度优化
低秩分解/蒸馏/超参数



模型精度调优
数据Dump
精度比对



模型开发/迁移
PT/TF GPU2Ascend
X2MindSpore

推理开发：更快开发速度

一站式推理工具，支持迁移分析、开发、调试和调优



离线模型转换
模型转换
离线模型可视化



应用开发
AscendCL
MindX SDK



精度分析
数据Dump
精度比对



性能调优
Profiling性能调优
Advisor专家系统

昇腾推理引擎-AscendIE

- 昇腾推理引擎旨在提升AI模型迁移和应用开发的效率，并提升AI推理应用的性能。架构图见右侧：

- 图构建


- 图构建部分核心任务为计算图graph的生成，可以通过针对不同框架的parser导入或手动构建；
- 提供自定义算子注册入口。

- 图优化

- 图优化部分核心任务为对计算图的多层次编译优化，提高推理性能；
- 提供自定义pass注册入口。

- 运行时

- 能够脱离builder编译引擎独立部署；
- 支持模型推理结果的内存复用；
- 支持多任务队列的发射，并发执行。



目录

1. 昇腾AI基础软件
2. **集群监控与运维软件**

SmartKit Computing

- SmartKit中包含了对计算设备进行批量部署、维护、升级等操作所需的各类工具，能够帮助企业管理员、企业终端用户在上述过程中对设备进行精准操作，降低操作难度、提升工作效率。和智算服务器相关的功能如下：
 - 一键开局
 - 快速完成对服务器的iBMC、BIOS、RAID配置和OS部署。
 - Atlas批量部署
 - 支持在Atlas服务器批量部署：驱动、固件、CANN、深度学习框架、MindX Edge、MindX DL软件及相关依赖。
 - 软件包管理（大包制作）
 - 如果Atlas服务器无法联网，可通过制作离线大包的方式部署环境，该选项需要配合Atlas批量部署使用。


FusionDirector

- FusionDirector为服务器（包含华为和第三方）和华为边缘设备统一运维管理软件，支撑公有云、企业客户对服务器和华为边缘设备在生命周期各阶段易用、高效的运维管理。



- 为公有云提供大规模服务器自动化运维能力；
- 为私有云提供一站式硬件管理能力；
- 为NFVI提供基础的硬件管理平台；
- 为数据中心提供硬件精细化管理能力；
- 华为硬件融入开放环境的桥梁，提供服务器产品核心竞争力。

CCAIE-提供计算中心端到端运维管理解决方案




23 Copyright © Huawei Technologies Co., Ltd. All rights reserved.



- 基于NetGraph平台，提供CaaS底座和软件基础设施，包括消息总线、数据库、缓存、分布式存储等。
- 流转NeoSight设备网元管理及部分公共服务，快速支撑CCAIE基本运维能力构建。
- CCAIE定义统一的全栈资源模型注册到DTE中，DTE做为数据底座，负责存储、处理全网数据，并对应用提供统一的查询接口。
- 南向统一对接外部系统（NCE、FI、CCAgent）数据，告警、资源数据通过北向上报，日志、KPI海量数据通过Kafka采集。

华为CloudFabric运维总体架构



- iMaster NCE-Fabric在CloudFabric整体解决方案中承载了部分运维能力，包括网管、路径探测、网络可达性校验、以及故障1-3-5闭环。
- iMaster NCE-FabricInsight是基于华为大数据平台构建，接收多种自网络设备上报数据，运用智能算法对网络数据进行分析，快速发现网络中的故障和运维隐患，并实现对网络故障的快速定位，呈现关键网络事件，为用户的网络运维提供决策依据。

华为CloudFabric运维功能全景



- 智能运维由控制器和分析器两个组件完成，本课程将针对部分运维特性进行介绍。

思考题

1. （单选）以下哪个工具可以支持在昇腾设备上快速开发大模型？
- A. MindFormers
 - B. MindSpore
 - C. MindX DL
 - D. MindSpore Insight

- A

本章总结

- 本章主要介绍了华为AI智算相关的软件，模型开发侧软件包括CANN、MindFormers等，Atlas服务器侧包含SmartKit Computing、FusionDirector等，以及网络管理运维的CloudFabric。

学习推荐

- <https://www.mindspore.cn/>
- <https://www.hiascend.com/>
- <https://support.huawei.com/carrierindex/zh/hwe/index.html>

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。
Bring digital to every person, home, and
organization for a fully connected,
intelligent world.

Copyright © Huawei Technologies Co., Ltd. All rights reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.



大模型部署与商业模式介绍



前言

- 本章主要讲述了大模型的部署流程和常见的部署优化方法和部署工具，同时也对大模型商业模式进行了简单介绍。

目标

- 学完本课程后，您将能够：
 - 掌握大模型部署流程；
 - 了解大模型常见部署优化方法；
 - 了解大模型常见部署工具；
 - 了解大模型商业模式。

目录

1. 大模型部署介绍

- 大模型部署流程
- 大模型常用压缩方法
- 大模型常用部署工具
- 大模型推理加速技术
- 大模型应用开发
- 大模型本地部署展望

2. 大模型商业模式

大模型部署流程（1）

大模型部署会因部署框架、硬件的不同有所区别，接下来会进行简单介绍，以下为一些通用流程。

模型转换
(可选)

模型压缩
(可选)

运行参数配置
(必选)

推理文件准备
(必选)

工程编译
(可选)

编程框架接入
(可选)

- 模型转换
 - 使用不同的框架部署模型要求的模型格式不同，如果当前权重文件格式与框架要求的格式不一致，则需要做模型转换，同时根据部署策略，分布式权重与单个权重也需要做转换；
- 模型压缩
 - 模型压缩可以提高模型推理速度、减少内存占用，但性能会有所降低，可根据实际场景选择。

大模型部署流程（2）

- 运行参数配置
 - 配置模型的部署策略（是否并行）、推理参数（推理长度、top_k等）；
- 工程编译
 - 目前有使用纯C++实现的模型推理，这种部署方式需要对工程进行编译后才能执行；
- 编程框架接入
 - 由于大模型存在无法实时联网、幻觉等问题，因此实际部署中会通过框架将大模型与数据库、其余应用配合使用，从而得到更准确、更符合业务的回答。

目录

1. 大模型部署介绍

- 大模型部署流程
- 大模型常用压缩方法
- 大模型常用部署工具
- 大模型推理加速技术
- 大模型应用开发
- 大模型本地部署展望

2. 大模型商业模式

模型压缩的必要性


随着模型参数数量的增加，模型部署的成本和推理性能都受影响，部分影响如下：

- 推理性能
 - 硬件访存带宽受限时，权重越大，数据搬运开销越大；
 - 显存容量不足时，只能CPU部署、推理性能较差；
- 部署成本
 - 权重越大，对存储容量、计算资源开销、显存容量要求越高，就需要更多的设备来部署；
 - Batch Size、序列长度的增加，KV Cache也会不断上升，对访存造成较大压力。

目前大显存、访存带宽高的设备价格都较高，为了能在消费级设备上部署、推广大模型，模型压缩必不可少。


大模型压缩趋势

不同参数规模的大模型压缩方法



模型剪枝

模型剪枝是模型压缩中一种重要的技术，其基本思想是将模型中不重要的权重和分支裁剪掉，将网络结构稀疏化，进而得到参数量更小的模型。然而，剪枝也可能导致模型性能的下降，因此需要在模型大小和性能之间找到一个平衡点。神经元在神经网络中的连接在数学上表示为权重矩阵，因此剪枝即是将权重矩阵中一部分元素变为零元素。剪枝过程如下图所示，目的是减去不重要的突触（Synapses）或神经元（Neurons）。



知识蒸馏

- 知识蒸馏（Knowledge Distillation），是一种带有迁移学习理念的模型压缩技术。较大、较复杂的网络虽然通常具有很好的性能，但是也存在很多的冗余信息，因此运算量以及资源的消耗都非常多。而所谓的Distilling就是将复杂网络中的有用信息提取出来迁移到一个更小的网络上，这样学习来的小网络可以具备和大的复杂网络相接近的性能效果，并且也大大的节省了计算资源。这个复杂的网络可以看成是一个教师，而小的网络则可以看成是一个学生。

训练后量化PTQ (Post-Training Quantization)

- 训练后量化会量化预训练的浮点模型和使用部分训练数据来校准模型。包含Data-Free和Label-Free算法，这两种训练后量化算法可在昇腾推理平台进行，同时支持有/无校准数据集的PTQ量化场景，可将Float浮点模型转换为定点INT8模型，达到模型压缩、减少计算量、缩短推理时延的目的。
 - Data-Free量化：无需获取输入数据集，即可对模型进行量化；通过翻转优化权重，多尺度渐进迭代优化的方法在无数据场景实现了有效量化；
 - Label-Free量化：用户需要提供少量数据集做矫正，相比于无数据量化，Label-Free量化的输入数据符合原数据分布，量化精度会更高。

量化感知训练QAT（Quantization Aware Training）

- 量化感知训练是在模型中插入伪量化模块（quantizer）模拟量化模型在推理过程中进行的舍入（rounding）和钳位（clamping）操作，从而在训练过程中提高模型对量化效应的适应能力，获得更高的量化模型精度。在这个过程中，所有计算（包括模型正反向传播计算和伪量化节点计算）都是以浮点计算实现的，在训练完成后才量化为真正的INT8模型。

业界大模型压缩工具现状

厂商	压缩工具	关键技术与效果
NVIDIA	Faster-Transformer	1、支持GPT类模型的FP16推理； 2、基于Hopper架构，支持Transformer的FP8推理； 3、支持Encoder的W8A8量化；初步支持Decoder； 4、W4A16量化，支持GPT-3的小Batch size推理；
MicroSoft	DeepSpeed	1、MoE模型压缩3.7x、精度无损； 2、基于ZeroQuant算法，支持GPT类模型的W8A8、W4A16、W4A8量化；
Google	TensorFlow	1、Switch-Base压缩94%，精度提升保留29%；
HPC-AI	Colossal-AI	1、支持GPT类模型的INT8量化及模型并行推理；
百度	PaddleSlim/ PaddleNLP	1、ERNIE-Tiny在线蒸馏，相比ERNIE2.0-base压缩了7.5x，精度损失2%~3%； 2、PaddleNLP支持BERT结构剪枝，压缩2x、精度无损； 3、PaddleSlim支持常规模型剪枝、量化与自动组合压缩；
阿里	PAI-Blade	1、支持AliceMind PUG大模型（27B）的稀疏化压缩与加速，稀疏度高达99%，100x压缩，加速约1.6x； 2、支持BERT类模型的结构剪枝，压缩2~3x、精度无损； 3、支持常规模型的PTQ/QAT，W8A8应用；
华为	ModelSlim	1、支持百亿以下Transformer的结构剪枝、低秩分解； 2、支持常规模型的PTQ量化，W8A8应用。

目录

1. 大模型部署介绍

- 大模型部署流程
- 大模型常用压缩方法
- 大模型常用部署工具
- 大模型推理加速技术
- 大模型应用开发
- 大模型本地部署展望

2. 大模型商业模式

大模型部署工具介绍（1）

- Transformers
 - 提供了数以千计的预训练模型，部署方便；
- MindFormers
 - 提供业内主流的Transformer类预训练模型和SOTA下游任务应用，涵盖丰富的并行特性；
- ModelLink
 - 旨在为华为昇腾芯片上的大语言模型提供端到端的解决方案，包含模型，算法，以及下游任务；
- vLLM
 - vLLM是一个开源的LLM推理和服务引擎，它利用了全新的注意力算法「PagedAttention」，有效地管理注意力键和值，比Transformers的速度快24倍；

大模型部署工具介绍（2）

- Fastchat
 - FastChat是一个开放平台，用于训练、服务和评估基于大型语言模型的聊天机器人，可以通过Web UI和RESTful APIs提供服务；
- TensorRT-LLM
 - TensorRT-LLM为用户提供了一个易于使用的Python API来定义大型语言模型（LLM），并构建包含最先进优化的TensorRT引擎，以便在NVIDIA GPU上高效地执行推理；
- AscendIE
 - AscendIE是针对昇腾NPU设备的推理加速引擎，提供AI模型推理的商业化部署能力，能够将不同的深度学习框架（PyTorch、ONNX等）上完成训练的算法模型统一为计算图表示，具备多粒度模型优化、整图下发等功能；
- MindSpore Lite
 - MindSpore Lite是一个极速、极智、极简的AI引擎，使能全场景智能应用，可支撑部署大模型，同时支持Paged Attention加速。

目录

1. 大模型部署介绍

- 大模型部署流程
- 大模型常用压缩方法
- 大模型常用部署工具
- 大模型推理加速技术
- 大模型应用开发
- 大模型本地部署展望

2. 大模型商业模式

大模型推理加速技术介绍（1）

- 大模型推理加速技术众多，但是关注的指标和优化方向基本类似，具体如下：
 - 推理重点关注指标：
 - 吞吐量
 - 时延
 - 推理优化方向：
 - 资源调度优化
 - 模型压缩
 - 使用专用芯片

大模型推理加速技术介绍（2）

- MoE
 - 一种基于 Gating Function 的稀疏模型架构，在增加模型参数的同时，保持FLOPs 基本不变，实现 sub-linear 的模型规模增长模型；
- K/V Cache
 - 将推理过程中先前迭代中的 K、V 矩阵缓存下来，避免重复计算，用内存换时间；
- Attention算子优化
 - Flash Attention
 - 通过算子融合节省Attention中间结果访存开销；
 - Paged Attention
 - 借鉴操作系统内存管理的思路，建立logic kv block和physical kv block的映射，通过block table存储索引；
- 专用芯片Groq
 - 消除不确定性硬件、Data locality优化、降低通信开销、提高资源利用率等。

目录

1. 大模型部署介绍

- 大模型部署流程
- 大模型常用压缩方法
- 大模型常用部署工具
- 大模型推理加速技术
- 大模型应用开发
- 大模型本地部署展望

2. 大模型商业模式

为什么需要大模型编程框架接入工具

- 虽然目前大模型在语言理解、问答等方面表现出了优秀的能力，但还存在一些问题：
 - 时效性问题：目前大模型迭代周期长，无法快速获取最新数据；
 - “幻觉”现象：问答中会出现杜撰、编造的事实、数据等。
- 为了解决大模型上述存在的问题，研究人员通过让大模型外挂知识库、调用其他工具（如联网模块）等来输出更准确、有效的回答，在大模型应用开发时，如果有一个工具可以很方便的把大模型和知识库等结合起来，那将大大提高大模型相关应用开发效率，其中LangChain就是典型的代表。

LangChain

- LangChain框架是一个开源工具，充分利用了大型语言模型的强大能力，以便开发各种下游应用。它的目标是为各种大型语言模型应用提供通用接口，从而简化应用程序的开发流程。可以将 LLM 模型（对话模型、embedding模型等）、向量数据库、交互层Prompt、外部知识、外部代理工具整合到一起，进而可以自由构建LLM应用。
- LangChain核心组件
 - 模型输入/输出（Model I/O）：与语言模型交互的接口；
 - 数据连接（Data connection）：与特定应用程序的数据进行交互的接口；
 - 链（Chains）：将组件组合实现端到端应用；
 - 记忆（Memory）：用于链的多次运行之间持久化应用程序状态；
 - 代理（Agents）：扩展模型的推理能力，用于复杂的应用的调用序列；
 - 回调（Callbacks）：扩展模型的推理能力，用于复杂的应用的调用序列。

Gradio

- Gradio可以直接在 Python 中通过友好的 Web 界面演示机器学习模型，能够以一个富有视觉效果界面呈现融合后的知识库和LLM；
- Gradio可以包装几乎任何Python函数为易于使用的用户界面，常用的基础模块构成如下：
 - 应用界面：gradio.Interface(简易场景)，gradio.Blocks(定制化场景)；
 - 输入输出：gradio.Image(图像)，gradio.Textbox(文本框)，gradio.DataFrame(数据框)，gradio.Dropdown(下拉选项)，gradio.Number(数字)，gradio.Markdown(Markdown)，gradio.Files(文件)；
 - 控制组件：gradio.Button(按钮)；
 - 布局组件：gradio.Tab(标签页)，gradio.Row(行布局)，gradio.Column(列布局)。

FastAPI

- 为了方便大模型应用项目的管理，现有的项目通常采用前后端分离的方式搭建，前后端数据通过json格式进行传输；
- FastAPI 是一个用于构建 API 的现代、快速（高性能）的 Web 框架，非常方便用于搭建前后端分离的应用，通过定义相关参数和请求方式，即可通过本地端口来使用相关服务。

目录

1. 大模型部署介绍

- 大模型部署流程
- 大模型常用压缩方法
- 大模型常用部署工具
- 大模型推理加速技术
- 大模型应用开发
- 大模型本地部署展望

2. 大模型商业模式

大模型本地部署发展趋势（1）

- 随着大模型的爆火，越来越多的人想体验大模型的能力，然而云端大模型的隐私问题和本地部署的高门槛让很多人望而却步；因此适合本地PC、手机部署的大模型和适合部署大模型的AI PC、AI手机应运而生；
- 本地大模型
 - 在不量化的情况下，部署模型所需的显存（内存）与模型参数大致呈现为2X关系，即7B的模型需要14GB显存（内存）部署，因此现在很多开源模型都有13B、7B的版本，可以让模型在消费级设备上部署，比如Llama系列、ChatGLM系列等；
 - MiniCPM、Gemma等模型还开源了2B的版本，可以让大模型运行在现有的手机上；
 - 通过使用纯C++代码，可以在仅使用CPU、内存的情况下部署大模型，大大降低了大模型部署门槛，由于不使用推理框架，推理速度也得到了提升，如Llama.cpp、ChatGLM.cpp。

大模型本地部署发展趋势（2）

- 除了大模型本身架构的发展，现有的硬件也在朝着适配大模型发展，以下为当前的部分趋势：
 - AI PC
 - 大模型出现之前个人PC中轻薄本居多，而这类PC通常无法支撑大模型部署，Intel在其Ultra处理器中集成了NPU，可以使PC在不搭载独显的情况下高效运行大模型；AMD也在其新款处理器中集成了NPU；
 - 荣耀新款PC搭载了AI YOYO助理，大模型开箱即用，配合自身硬件，可以依靠自身硬件实现多种AI功能；
 - 混合AI
 - 不同于PC，手机等端侧设备受限于体积、功耗等因素，无法支撑参数量过大的模型，端云协同的混合AI模式是未来发展的一个方向，简单的AI任务由端侧模型完成、复杂的AI任务由云侧模型完成，可以在性能、功耗、时延等方面取得平衡。

目录

1. 大模型部署介绍
2. 大模型商业模式

大模型应用场景

铁路TFDS检测 企业流程自动化 输电线路巡检 鹏城·神农 票据OCR 供应链物流 城市三维重建 东方·翼风 自动答疑 ...

L2 场景大模型

教育	医疗	科学智能	遥感	金融	智慧城市	能源	大企业	交通	制造
星火+教育	紫东太初·济世	金陵·电磁脑	武汉·LuoJia	盘古·金融	星火+智算	盘古·电力	星火+编程	天佑大模型	海睿·元神
紫东太初·私塾	盘古·医药		空天·灵眸	星火+金融	星火+政务	盘古·矿山	星火+RPA	紫东太初·阡陌	
教育GLM	金陵·女婿		秦岭·西电遥感脑	金融GLM	政务GLM	紫东太初·智能决策	CodeGeeX		
					盘古·政务				
					紫东太初·枢密				

L1 行业大模型

讯飞星火	BLOOM	GPT3	Stable Diffusion	LLaMA	紫东太初	GLM	...
------	-------	------	------------------	-------	------	-----	-----

L0 基础大模型

国外大模型商业案例（1）

- OpenAI
 - ChatGPT：ChatGPT一经发布就吸引了很多用户的注册使用，在引领大模型的同时得到了大量用户的真实使用数据，从而产生数据飞轮效应，为公司研究更先进的模型提供了数据；
 - GPTs：可自主调用大模型和工具、知识库等，大多头部应用为创业公司引流，从而扩大生态，增加用户黏性；
- 微软
 - Bing AI：使用大模型来改善搜索体验，对话式搜索颠覆传统的搜索模式，与友商竞争搜索份额；
 - Copilot：全面接入Windows系统、Office、画图工具等，提供了桌面布局修改、草稿生成、图片背景去除等功能，增加产品竞争力。

国外大模型商业案例（2）

- Runway
 - Gen1（视频转视频工具）：转换视频风格，包括风格化、故事化等；
 - Gen2（视频生成编辑工具）：可通过文字、图片生成视频，在Sora出现之前生成的视频细节和一致性处于领先地位；
 - FI（图像平滑工具）：通过上传一系列图像，生成流畅的过渡视频；
- Midjourney
 - 相较于其他开源的文生图模型，在真实度、细节、创造性等方面都处于领先地位，玻璃反射、手部细节等都可以很好的处理；
 - 用户可以通过付费的方式获得生成图像的版权，并且没有使用次数限制。

- Runway通过水印、分辨率限制来促使用户付费

大型企业大模型商业模式（1）

- 支撑内部业务：特定场景替代人类工作，辅助员工办公，提升IT流程效率；
 - 自然语义搜索：可以通过自然语言描述搜索电脑和公司内的文档，如：“查找近一个月关于Atlas800T A2的PPT”；
 - 知识问答：大模型接入公司文档库，通过问答直接获取知识，如：“Atlas800T A2包含几路CPU？”；
 - 生成邮件：根据标题和关键内容，生成符合公司风格的邮件正文。
- 行业模型：差异化竞争，瞄准行业客户；
 - 随着技术的发展演进，基础大模型的能力差距在逐渐缩小，各企业开始专注于行业模型，通过公开数据得到行业模型，然后与行业用户深度合作，得到场景模型，实现商业变现。

大型企业大模型商业模式（2）

- 提供算力租赁服务：出租算力，充分利用算力资源；
 - 通过对外提供算力租赁服务，满足其余企业需求，回收硬件成本。
- 提供大模型服务：MaaS，助力企业快速打造个性化大模型
 - 不同于前面与行业客户合作，通过提供基础大模型与开发工具链，让客户自己构建个性化大模型。
- 融入公司产品：提升产品竞争力。
 - 小艺语音助手，接入盘古大模型，提供文档问答等多种功能，提升用户体验。

思考题

1. 大模型部署必须要进行压缩吗？
2. MindSpore Lite对大模型部署的重要性有哪些？

- 1、不是必须的，但是压缩可以节省资源，提高推理速度
- 2、支持多种加速算法，如Paged Attention，可以极大提升模型推理速度，而MindFormers等框架更多的在训练方面做了优化

本章总结

- 本章主要介绍了大模型部署的流程、优化方法和部署工具，同时对大模型商业模式进行了简单的介绍。

学习推荐

- <https://www.mindspore.cn/>
- <https://www.hiascend.com/>
- <https://support.huawei.com/carrierindex/zh/hwe/index.html>

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。
Bring digital to every person, home, and
organization for a fully connected,
intelligent world.

Copyright © Huawei Technologies Co., Ltd. All rights reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.



业界大模型及应用



前言

- 本章主要介绍了业界主流的开源和闭源大模型的应用，然后介绍了华为在大模型领域的相关应用。

目标

- 学完本课程后，您将能够：
 - 了解业界主流开源大模型的应用；
 - 了解业务主流闭源大模型的应用；
 - 了解华为在大模型领域的应用。

目录

1. 业界典型大模型
 - 开源大模型
 - 闭源大模型
2. 华为大模型应用案例

大模型分类

- 随着ChatGPT的爆火，大模型进入了大众的视野，但除了ChatGPT，还有很多其他的大模型，这里将简单进行介绍。
- 大模型分类
 - 大语言模型
 - 通过大量的文本数据进行训练，后期可以通过输入一段Prompt来获得预期的输出，从而完成特定任务，比较典型的有ChatGPT、ChatGLM等；
 - 视觉大模型
 - 这里的大模型会比前面的两种小很多，是指采用了Transformer架构的视觉模型，比如ViT、SAM、Swin Transformer等；
 - 多模态大模型
 - 通过文本-图像对或者文本-视频对等对模型进行训练，然后通过文本生成图像、视频或者通过文本编辑图像、视频，比较典型的有Stable Diffusion、Midjourney、Sora等。

开源大模型介绍

- 大语言模型发展从早期的三种路线（Encoder Only、Encoder-Decoder、Decoder Only）同时发展，已经逐步收敛到Decoder-Only架构，目前GPT系列、Llama系列等都采用了这条技术路线，只剩部分公司还在尝试Encoder-Decoder架构，下面将选取一些典型的进行介绍。

Llama

- Llama是Meta AI发布的从7B到65B参数的基础语言模型集合，基于这个模型衍生了一系列模型，如Alpaca、BiLLa、CodeLlama等；
- 由于模型本身开源和基础能力较强，很多支持在线体验大模型的网站都部署了Llama，开源网站上也有各种针对Llama进行微调和训练的工具，对大模型的发展起到了重要作用。

ChatGLM

- ChatGLM-6B是一个开源的、支持中英双语的对话语言模型，结合模型量化技术，用户可以在消费级的显卡上进行本地部署（INT4量化级别下最低只需6GB显存），最新开源版模型原生支持Function Call、Code Interpreter、Agent等复杂场景；
- 通过访问智谱清言官网等平台，可以体验更大的模型和最新版本，网页上提供了联网搜索、多模型结合（文生图、搜索、大模型问答）、长文档解读等多种场景应用，支持个人创建智能体，大大丰富了大模型使用场景。

Mixtral

- Mixtral 8x7B是首个开源的MoE模型，它的前馈模块从8组不同的参数中进行选择。在每一层网络中，对于每个Token，路由网络选择8组中的两组（专家），来处理Token并将其输出累加组合；这种技术增加了模型的参数数量，同时控制了成本和延迟，因为模型只使用每个Token参数集总数的一小部分；
- 目前HuggingChat、OpenRouter等网站均部署了Mixtral 8x7B模型，可以在使用较低部署成本的情况下给用户提供较好的体验，得益于模型的开源，厂商也可以很方便的对模型进行微调，以适应自己的业务。

Stable Diffusion

- Stable Diffusion可以用文本生成图像，或者输入文本和图像来对图像进行修改；
- 基于Stable Diffusion，目前出现了Stable Diffusion WebUI、ComfyUI等开箱即用的文生图工具，大大降低了模型的使用门槛，可以方便的生成服装设计图、建筑设计图、二次元头像等，对传统的设计行业产生了较大的影响。

Open-Sora


- Open-Sora项目是一项致力于高效制作高质量视频，并使所有人都能使用其模型、工具和内容的计划。通过采用开源原则，Open-Sora 不仅实现了先进视频生成技术的低成本普及，还提供了—个精简且用户友好的方案，简化了视频制作的复杂性。
- Open-Sora训练分为以下三个阶段：
 - 大规模图像预训练
 - 大规模视频预训练
 - 高质量视频数据微调
- 通过Open-Sora可以方便的生成高质量视频，对于电影、动漫从业者来说提供了较大的帮助。

目录

1. 业界典型大模型
 - 开源大模型
 - 闭源大模型
2. 华为大模型应用案例

GPT

- GPT是OpenAI发布的一系列模型，基于GPT3.5的ChatGPT爆火，让大众开始接触和了解大模型；
- 2022年11月30日，OpenAI发布ChatGPT并迅速爆火，仅仅2个月就拥有了1亿的用户；
 - ChatGPT具备初步理解人类意图的能力，能够回答后续问题、承认错误、挑战不正确的前提以及拒绝不合适请求；



- 2023年3月14日，GPT4发布，支持多模态，并且在回答准确性等指标上领先于GPT3.5。

- 整体技术路线上，ChatGPT在效果强大的GPT-3.5大规模语言模型（LLM，Large Language Model）基础上，引入“人工标注数据+强化学习”（RLHF，Reinforcement Learning from Human Feedback，这里的人工反馈其实就是人工标注数据）来不断Fine-tune预训练语言模型。
- 与GPT-3.5即InstructGPT的训练过程类似，分3个阶段：
 - 利用GPT-3.5模型进行有监督微调；
 - 奖励模型训练；
 - 强化学习训练。

Sora

- Sora可直接生成长达60s的一镜到底视频，在视频生成领域处于领先水平。主要优势如下：
 - 准确性和多样性：可以准确地解释用户提供的文本输入，并生成具有各种场景和人物的高质量视频剪辑；
 - 强大的语言理解：OpenAI利用GPT技术将简短的用户提示转换为更长的详细转译，并将其发送到视频模型，这使Sora能够精确地按照用户提示生成高质量的视频；
 - 以图/视频生成视频：Sora除了可以将文本转化为视频，还能接受其他类型的输入提示，如已经存在的图像或视频；
 - 视频扩展功能：用户可以根据图像创建视频或补充现有视频；
 - 优异的设备适配性：从宽屏的 1920x1080p 到 竖屏 的1080x1920，两者之间的任何视频尺寸都能轻松应对；
 - 场景和物体的一致性和连续性：可以生成带有动态视角变化的视频，人物和场景元素在三维空间中的移动会显得更加自然。

Gemini

- Gemini是谷歌公司的大模型， Gemini 1.5建立在谷歌基础模型开发和基础设施的研究与工程创新的基础上，包括通过新的专家混合（MoE）架构使Gemini 1.5的训练和服务更加高效。
- Gemini 1.5 Pro 特点如下：
 - 高效架构：采用了MoE架构；
 - 更长的上下文，更有用的功能：上下文窗口容量多达100万；
 - 对大量信息进行复杂推理：以在给定提示内无缝分析、分类和总结大量内容；
 - 更好地理解推理跨模态：可以针对包括视频在内的不同模式执行高度复杂的理解和推理任务；
 - 使用较长的代码块解决相关问题：可以推理 100,000 行代码，提供有用的解决方案、修改和注释。

国内厂商大模型

- 不同于国外的大模型，国内厂商的大模型专注于解决行业问题，基本每家企业都推出了自己的大模型，下面简单介绍几个：
 - 星辰语义大模型：星辰语义大模型TeleChat是由中电信人工智能科技有限公司研发训练的大语言模型，其中7B模型基座采用1.5万亿 Tokens中英文高质量语料进行训练，12B模型基座采用3万亿 Tokens中英文高质量语料进行训练；
 - 鹏程脑海：PengCheng-Mind 200B 脑海大模型是基于Transformer 架构的2010亿参数自回归式语言模型，模型全流程基于鹏城云脑II的全自主安全可控国产软硬件平台进行开发和训练；
 - 通义：阿里云研发的大模型系列，包括通义千问、通义万相系列，支持对话、文生图等功能；
 - 星火认知大模型：由科大讯飞训练的模型，支持文生图、法律咨询等多种功能。

盘古大模型

- 盘古大模型是面向行业的大模型，包含5类L0基础大模型、L1行业大模型及L2场景模型三层架构。



目录

1. 业界典型大模型
 - 开源大模型
 - 闭源大模型
2. 华为大模型应用案例

盘古大模型应用



政企知识检索

基于政企知识进行模型训练，通过对话交互，精准获取用户需求的信息，提高知识获取效率，带来有温度的人工智能服务体验。




智慧城市

利用万物检测、万物分割满足智慧城市海量长尾需求，通过语言交互方式高效发现城市事件。



游戏开发

面向行业提供角色创作、原画设计、3D素材生成、手办创作、风格转换等技术。



行业研发助手


提供代码生成、代码修改、代码理解等多种功能，协同办公，提升研发效率。

盘古药物分子大模型



盘古气象大模型

- 华为云盘古气象大模型是首个精度超过传统数值预报方法的AI模型，速度相比传统数值预报提速10000倍以上。目前，盘古气象大模型能够提供全球气象秒级预报，其气象预测结果包括位势、湿度、风速、温度、海平面气压等，可以直接应用于多个气象研究细分场景，欧洲中期预报中心和中央气象台等都在实测中发现盘古预测的优越性。



- <https://www.huaweicloud.com/product/pangu/scientific-computing.html>

盘古矿山大模型

AI掘进作业序列智能监测系统



AI主运智能监测系统






人工智能拼接技术



- <https://bbs.huaweicloud.com/blogs/407095>

华为小艺语音助手

- 目前华为部分手机已经开启了搭载盘古模型的小艺助手公测，申请后即可体验。



思考题

1. 采用了MoE技术的模型具有哪些优势？
2. 为什么微调对于大模型来说如此重要？

- 1、可以在模型规模增长之后，推理时只激活部分参数，计算量和小规模模型一样，但准确度较高
- 2、没有经过微调的大模型无法回答业务相关的问题，无法使能行业，同时未对齐的情况下，可能会输出有害信息

本章总结

- 本章主要对业界大模型进行了简单介绍，同时介绍了华为在大模型领域的应用案例，包括手机语音助手和面向行业的一些解决方案。

学习推荐

- <https://www.mindspore.cn/>
- <https://www.hiascend.com/>
- <https://support.huawei.com/carrierindex/zh/hwe/index.html>

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。
Bring digital to every person, home, and
organization for a fully connected,
intelligent world.

Copyright © Huawei Technologies Co., Ltd. All rights reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.



专业技术人员职业素养与组织赋能



前言

- 在技术高歌猛进、业务复杂多元的今天，我们坚信，卓越的专业追求绝非孤立存在，它既需要**内化于心的职业道德**——对专业诚信的坚守、对合规红线的敬畏、对技术伦理的审慎；也需要**外化于行的组织赋能**——打破技术孤岛，通过知识沉淀、经验传承，将个人能量转化为组织发展的动能。

目标

- 学完本课程后，您将能够：
 - 清晰界定技术应用的边界，识别风险；
 - 建立持续迭代的技术成长思维，以适应指数级发展趋势；
 - 掌握标准化带教方法，将个人技术传承延续。

目录

1. 职业道德
2. 终身学习
3. 培训指导

从业者的三重责任

三重责任

核心目标：明确责任边界与核心义务

1. **专业责任：**追求技术卓越，保持专业精进
2. **社会责任：**维护公共利益，坚守伦理底线
3. **带教责任：**传承知识与规范，赋能团队成长



三者间的关系

职业道德 → 技术技能（约束关系）

职业道德为技术技能的应用划定边界。如生成式AI伦理约束AI模型开发方向；网络安全法规约束网络技术操作

培训指导 → 技术技能（赋能关系）

培训指导为技术技能的习得提供方法论。如利用知识图谱工具构建能力图谱指导学习路径；“先培训再上岗”确保技术技能达标

技术技能 → 职业道德（实践关系）

技术技能是践行职业道德的载体。如只有掌握了数据安全技术，才能真正保护用户隐私

技术技能 → 培训指导（反馈关系）

技术技能的掌握程度反馈培训指导的有效性，驱动培训方案迭代

职业道德 ↔ 培训指导（融合关系）

培训指导本身需遵循职业道德；同时培训指导也是传播职业道德的主渠道

职业道德核心原则解析

一般伦理原则

核心目标：确立社会底线

1. **人类福祉**：将公众安全、健康及福祉置于技术发展的首位
2. **诚实守信**：保持专业诚信，不隐瞒已知风险，不误导用户
3. **公平公正**：避免算法歧视，确保技术应用的包容性与公平性
4. **避免伤害**：预防技术滥用，主动规避对社会的潜在负面影响
5. **尊重权益**：尊重法律、知识产权以及用户隐私，严守数据边界

职业伦理原则

核心目标：确立行业标准

1. **追求卓越**：持续精进技术能力，保持对高质量交付的追求
2. **保持专业**：遵循行业规范，维护职业声誉，保持客观中立
3. **同行评议**：确保研究成果的质量和可信度，维护学术和职业的公平和正义
4. **尽职尽责**：对岗位负责，确保系统稳定与安全
5. **维护专业形象**：维护计算机行业的形象与声誉，促进计算机技术的普及及推广

一般伦理原则与职业伦理原则的双重规范


目录

1. 职业道德
- 2. 终身学习**
3. 培训指导

数智升级，对人才培养与技能评价提出更高要求



华为职业认证：终身学习



技术发展现状

- 迭代加速、跨界融合、技术颠覆成为常态，停止学习即被淘汰
- 从“碎片化输入”到“知识晶体”，真正的学习，是将外界的碎片重构成自身的“护城河”

目录

1. 职业道德
2. 终身学习
- 3. 培训指导**

角色升级：从技术能手到培训导师

“技术工作是把事做好，培训带教是把人带会”

	技术能手	培训导师
核心角色	解决特定技术问题	知识传递者、能力引导者、问题解决者
交付成果	高质量的代码与系统	独立规范上岗的专业人才
核心能力	专业硬技术、排障能力	会梳理知识、会标准示范、会纠错复盘



带教原则

实用为先

贴合岗位真实场景，不讲空话

实操为主

重动手，重细节，真操实练，夯实技术

问题导向

解决实操卡点与上岗痛点

全程闭环

课前有备

定目标，梳理重难点

课中有方

示范、纠错、控场、盯安全

课后有落


答疑、考核、建档、跟进成长

培训与指导

ADDIE：将A、D、D、I、E五个步骤综合起来考虑，形成系统，保障各个环节能进行及时有效的评估

SAM模型：提倡“快速迭代、小步快跑”，分为三阶段：准备、迭代设计、迭代开发

6D法则：以终为始，把培训的生命周期向后延伸，将“培训”转化为“商业结果”的全面流程



Analysis: 分析阶段

分析阶段是首要的环节，是确定培训目标、设计培训计划的前提，也是决定培训是否开展的关键因素

在培训的各个阶段都要有分析，通过问卷、约谈、电话等各种形式，了解对象、组织、课程的各方面需求



需求分析 (WHY/WHAT) :

组织需求 (公司层面) :

公司的战略目标是什么?
目前阻碍目标实现的“痛点”是什么?

岗位需求 (标准层面) :

目标岗位需要具备哪些核心胜任力?
标准的操作流程 (SOP) 或优秀员工的行为典范是怎样的?



需求对象分析 (WHO) :

基本属性 (画像) :

学员的年龄分布、学历、司龄、目前的岗位层级。

认知与经验起点:

他们对这个主题已经了解多少?
他们日常遇到的实际工作场景和痛点是什么?

学习动机与风格:

他们是主动想学，还是被公司强迫来的?



培训环境分析 (Where & How)

面授课堂: 教材需要配套 PPT、讲师手册、学员手册、通关演练通关单。

线上微课/E-learning: 教材需要拆解为结构化的“脚本”或“脚本大纲”，方便录制音频或制作动画。

混合式培训 (OMO) : 线上学理论 (教材偏精简、清单化)，线下做演练 (教材偏案例、工具化)。



培训内容分析 (Which)

知识类: 讲概念、原理 (要少而精)。

技能类: 讲步骤、方法、流程 (要多、要细、要有标准)。

态度类: 讲观念转变、企业文化 (要通过故事和案例来感染)。



培训资源分析 (With What)


师资资源: 有没有内部的业务专家 (SME) 作为内容源头?

素材资源 (现成原料) : 公司现有的 SOP 手册、过往的失败案例库、竞品资料、行业标准等。

Design：设计阶段

设计阶段要制订一份完成培训项目所必需的说明提纲。基本内容包括必须制定的目标、目的和评估任务
基于培训项目的相关决策和其它实施问题的体系结构，确定各项任务的顺序

单元



课程单元结构的关系

- 一是**相对独立型**，各学习单元在位置上可以互换
- 二是一个单元是构成另一个单元的基础，这种类型在序列上极为严密
- 三是各单元学习内容的联系成**综合型**，即有的是相互独立关系，也有的是严格序列关系

主题的组织方式 - 螺旋式

- 即根据培训对象的智力发展水平，让学员尽早有机会在不同程度上去接触和掌握某门学科的基本结构，以后随着学员在智力上的成熟，围绕基本结构不断加深内容深度，使学员对知识有更深刻和有意义的理解。



Development : 开发阶段

开发阶段的要点在于**开发创建教学材料**的方法和流程。根据之前总结的各干系方需求，开发培训教材（资料），设计好阶段性评估文件等。在这一阶段中，内容和材料从概念设计转变为可交付成果。

1: 收集素材

2: 组织课程内容

- 内容编写
- 案例编制
- 角色扮演设计



检查错误


- 标题
- 段落
- 句子
- 表格
- 图形
- 缩略语/术语
- 数与数量
- 标点符号
- 单位符号

思考时多按金字塔顺序，但表述要用倒金字塔顺序

Implement: 实施阶段

- **教学程序**: 从把学员引入某个专题, 到掌握某个目标为止向学员呈现教学时教学活动的程序、步骤
 - **教学方式**: 呈现教学时运用的手段、方法, 如分组讨论、独自阅读、个案研究、讲授、计算机模拟、小组协作项目等
- 认知学习的一个关键概念是在信息从**工作记忆**迁移至**长期记忆**时, 对信息进行提取或演练, 从而强化长期记忆


“三段八环六素”教学理论, 把学习过程分片, 根据不同技术场景, 适配不同教学活动, 提升学习效果。



Evaluation: 评估

主流评估模型：柯氏四级、菲利普斯五级、考夫曼五级、CIPP 模型等
行业地位：历经行业检验，**柯氏四级**时至今日仍是不可动摇的经典基石模型

层次	重点描述	衡量方法	评价人员
反应层	受训者满意程度：喜欢该项目吗？对培训人员和设施有什么意见吗？课程有用吗？	问卷	学员
学习层	受训者在培训前后，知识、技能、态度、行为方式方面的收获：有多大程度的提高？	笔试、实地操作和工作模拟	学员和培训人员
行为层	培训后，受训者行为的改进：行为有无不同？他们在工作是否使用了在培训中所学的知识？	问卷调查、面谈、直接观察、业绩检测、专题研究、实践计划	学员、学员上级、下属、同事、客户
结果层	受训者获得的经营业绩：组织是否因为培训变得更好？	问卷调查、业绩检测、业绩目标法	学员、学员上级



反应层评估 (Reaction)：评估被培训者的满意程度
学习层评估 (Learning)：测定被培训者的学习获得程度
行为层评估 (Behavior)：考察被培训者的知识运用程度
结果层评估 (Result)：计算培训创出的经济效益

思考题

1. （单选题）项目经理小张突然接到紧急通知，需要当晚在公司内网加班处理一份涉及公司**核心商业秘密与关键技术参数**的涉密文件。由于公司保密机房的专用有线计算机键盘出了故障，为了不耽误进度，小张决定采取一些临时措施。请问以下哪**一项行为是明确禁止**的？
 - A. 临时将这份涉密文件拷贝到自己带有 Wi-Fi 芯片和蓝牙功能的个人便携式笔记本电脑上处理。
 - B. 立即联系IT安全部门，申请对当前的涉密系统环境进行一次全面的安全性评估。
 - C. 调整工位，移步到未链接互联网、且切断一切外网物理信号的涉密专用计算机上处理。
 - D. 确保待在公司规定的受控办公室内，在无无关人员围观的闭环环境下处理该涉密资料。
2. （判断题）培训完成后，进行了结业考试，考试通过就代表学员完全掌握了这项技能。

- A
- 错

本章总结

- 本章讲述了从业者的成长路径
 - 坚守底线：牢记行为红线，确保技术向善
 - 持续学习：践行终身学习，应对瞬息万变
 - 培训指导：应用教学实践，传承优秀同路人

学习推荐

- 《 中 国 计 算 机 学 会 职 业 伦 理 与 行 为 守 则 》 :
https://www.ccf.org.cn/About_CCF/CCF_Constitution/2023-07-26/794450.shtml

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。
Bring digital to every person, home, and
organization for a fully connected,
intelligent world.

版权所有 © 华为技术有限公司 2026。

保留一切权利。

未经华为事先书面许可，任何人不得对本资料进行复制、修改、
整合、改编、翻译，也不得将本资料或其任何部分或基于本资
料的衍生作品提供、出售、转让、再许可给任何人用于华为
许可以外的任何其他用途。

Copyright © Huawei Technologies Co., Ltd. 2026.

All Rights Reserved.

Without prior written permission of Huawei, no one is
allowed to reproduce, modify, integrate, adapt, translate
this Document, or provide, sell, transfer, sublicense this
Document or any part of this Document or its derivative to
any third party for any other purpose otherwise permitted
by Huawei.

